

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Өгөгдлийн дүрслэл (Data visualization)
- Өгөгдлийн ойр байдал (Data proximity)





Өгөгдлийн дүрслэл

Өгөгдлийг дүрслэн харуулах нь өгөгдөл судлах хамгийн хүчирхэг аргуудын нэг юм.


- Хүмүүс нүдээр үзүүлж буй их хэмжээний мэдээлэлд дүн шинжилгээ хийх чадвар сайн хөгжсөн байдаг
- Ерөнхий хэв маяг, чиг хандлагыг илрүүлж чадна
- ***Outliers*** болон энгийн бус хэв маягийг илрүүлж чадна

Өгөгдлийн дүрслэл

- Дүрслэлийн аргууд
 - *Pixel-oriented techniques*
 - *Geometric projection techniques*
 - *Icon-based techniques*
 - *Hierarchical and graph-based technique*
 - *Standard Statistical Charts*
 - ...

Pixel-Oriented Visualization Techniques


- Шинж чанарын (*dimension*) утгыг дүрслэх энгийн арга бол пиксел (*pixel*).
 - Пикселийн өнгө нь шинж чанарын утгыг илэрхийлнэ.
 - *m* хэмжээст өгөгдлийн багцын хувьд хэмжээс бүрт нэг цонхыг дэлгэц дээр үүсгэдэг.
- Хэрэглэгчийн мэдээлийн хүснэгт
 - *Шинж чанарууд*: орлого, зээлийн хязгаар, гүйлгээний хэмжээ, нас
 - Бүх үйлчлүүлэгчдийн орлогыг өсөх дарааллаар эрэмбэлж, энэ дарааллыг ашиглан дөрвөн цонхонд хэрэглэгчийн өгөгдлийг байрлуулж болно.
 - Пикселийн өнгө: утга нь бага байх тусам сүүдэрлэх нь илүү хөнгөн байна.



Шинж чанаруудын пиксел хандлагат дүрслэл.

Pixel-Oriented Visualization Techniques

- **Heatmap (Дулааны зураглал).**
 - Өгөгдлийн утгуудын тархалт, нягтрал, хамаарлыг өнгөний ялгаагаар илэрхийлж, их утгатай хэсгийг тод, бага утгатай хэсгийг бүдэг өнгөөр харуулдаг дүрслэлийн арга юм.





Visualization of the Iris Correlation Matrix

Geometric Projection Visualization Techniques

- **Scatter plot (2D, 3D)**

- 2D → adding 3rd dimension
 - Color, shapes 
- 3D → adding 4th dimension
 - Color




Модны төрлөөр будсан цэгүүд

- Ферсон (шар) нь Милтон (цэнхэр) -ээс ерөнхийдөө өргөн
- Гэхдээ ижил диаметртэй бол богино байдаг.

Geometric Projection Visualization Techniques

- 4D<
 - *Scatter plot* үр дүнгүй байдаг.
- **Scatter-plot matrix**
 - *Scatter plot*-г өргөтгөсөн
 - n хэмжээст өгөгдлийн багцын хувьд шинж чанар бүрийг бусад бүх ш.ч-тай дүрслэн харуулах 2 хэмжээст scatter plot-уудын $n \times n$ сүлжээ юм.



Iris Plant data set

Гурван төрлийн цэцэг (classes):

Setosa

Virginica

Versicolour

Дөрвөн атрибутууд (non-class)


Sepal width, length

Petal width, length



Geometric Projection Visualization Techniques

- **Parallel coordinates**



Iris Plant data set

Гурван төрлийн цэцэг (classes):

Setosa

Virginica

Versicolour

Дөрвөн атрибутууд (non-class)



Sepal width, length

Petal width, length



Geometric Projection Visualization Techniques

- PCA (Principal Component Analysis), t-SNE
- Өгөгдлийг бага хэмжээст орон зай руу шилжүүлж, хамгийн чухал шинж чанаруудыг хадгална.




Icon-Based Visualization Techniques

- Дүрсэд суурилсан дүрслэлийн техник нь олон хэмжээст өгөгдлийн утгыг илэрхийлэхийн тулд жижиг дүрсүүдийг ашигладаг.
 - *Chernoff faces*
 - *Stick figures*
- Хүний нүдэнд хялбар харагдах, олон хэмжээст өгөгдлийг нэг дор харахад тохиромжтой.

Icon-Based Visualization Techniques

- **Chernoff faces**

- 18 хүртэлх хувьсагчтай (dimensions) олон хэмжээст өгөгдлийг хүний царай хэлбэрээр харуулдаг.
- Черноффын царай нь өгөгдлийн чиг хандлага, хэв маягийг илрүүлэхэд тусалдаг.
 - Хүний царайг ялгах чадварт тулгуурладаг
- Атрибут бүрийн утгууд нь нүүрний харгалзах шинж чанарыг тодорхойлдог
- Объект бүр тусдаа нүүр царай болж хувирдаг.



Chernoff faces. Нүүр бүр нь n хэмжээст өгөгдлийн цэгийг илэрхийлнэ ($n \leq 18$)


Data Feature	Facial Feature
sepal length	size of face
sepal width	forehead/jaw relative arc length
petal length	shape of forehead
petal width	shape of jaw

Icon-Based Visualization Techniques


- **Stick figures**

- Олон хэмжээст өгөгдлийг таван ширхэг саваа дүрс рүү буулгадаг.
- Дүрс бүр дөрвөн мөч (*limbs*), биетэй (*body*).
 - 2 хувьсагчийг X , Y тэнхлэг рүү буулгах
 - Үлдсэн хэмжээсийг мөчний урт, өнцөг рүү буулгах

- *Age, income*
- *gender, education,*



Stick Figure Icon





A Family of Stick Figures



income

Hierarchical Visualization Techniques

- Шаталсан дүрслэлийн аргууд нь бүх хэмжигдэхүүнийг дэд олонлогт (жишээ нь, дэд орон зай) хуваадаг.
- Өгөгдлийн бүтэц, хамаарал, бүлэглэлийг харуулна.




Visualizing Complex Data and Relations

- **Word clouds:** Энэ техник нь текст өгөгдлийн багц дахь үгсийн давтамжийг илэрхийлдэг
 - Үг бүрийг өгөгдлийн багц дахь давтамжаас нь хамааруулан жинлэдэг (*size, color*).



Өгөгдлийн хоорондох нарийн төвөгтэй харилцаа нь дүрслэлд хүндрэл учруулдаг.

- Зангилаа бүр - өвчин
- Зангилааны хэмжээ - өвчний тархалт
- Өвчнүүд хамааралтай бол 2 зангилаа ирмэгээр холбогдоно.
- Ирмэгийн өргөн – 2 өвчний хамаарал хэр байгааг илэрхийлнэ.








NHANES мэдээллийн багц, дор хаяж 20 настай хүмүүсийн
өвчний нөлөөллийн граф.

Өгөгдлийн дүрслэл

- Уламжлалт Статистик Дүрслэл (Standard Statistical Charts)

- Histogram*
- Box Plot*
- Scatter plot*
- Bar plot*
- Matrix plot*
- ...



Ижил төстэй болон ялгаатай байдлын ХЭМЖҮҮР

- Ижил төсөөтэй болон ялгаатай байдлыг дараах өгөгдөл олборлох арга техникт ашигладаг.
 - Кластер (**clustering**),
 - Хамгийн ойрын хөршийн ангилал (**nearest neighbor classification**),
 - Аномали (**anomaly**) илрүүлэх гэх мэт
- Ижил төсөөтэй болон ялгаатай байдлыг **ойр байдал** (**proximity**) гэсэн нэр томъёог ашиглан илэрхийлдэг.
- Хоёр объектын хоорондох **ойр байдал** нь хоёр объектын харгалзах атрибутуудын шинж чанаруудын ойролцоо байдлын функц.

Ижил төстэй болон ялгаатай байдлын ХЭМЖҮҮР

- Ижил төстэй байдлын хэмжүүр /Similarity/
 - 2 объектын ижил төстэй байдлын тоон хэмжүүр
 - Ижил төстэй байдал нь ихэвчлэн $[0, 1]$ байдаг.
 - 0 - ижил төстэй байдал байхгүй
 - 1 – бүрэн ижил төстэй
- Ялгаатай байдлын хэмжүүр /Dissimilarity/
 - 2 объектын ялгаатай байдлын тоон хэмжүүр
 - Ялгаатай байдал нь ихэвчлэн $[0, \infty]$ байдаг.
 - Хамгийн бага ялгаа нь ихэвчлэн 0 байдаг (Ижил төстэй бол 0)
 - Дээд хязгаар нь янз бүр байдаг.

Data Matrix & Dissimilarity Matrix

- Олон хэмжээст

- n объект (*persons, items, or courses*) $x_1 = (x_{11}, x_{12}, \dots, x_{1p})$
- p атрибут (*age, height, weight, or gender*) $x_2 = (x_{21}, x_{22}, \dots, x_{2p})$

- Кластер болон хамгийн ойрын хөршийн алгоритмууд нь ихэвчлэн дараах хоёр өгөгдлийн бүтцийн аль нэг дээр ажилладаг:

- Data matrix** (two-mode matrix)

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

Transformed

$$\begin{array}{c} 1 \\ 2 \\ 3 \\ \vdots \\ \cdot \\ n \end{array} \begin{bmatrix} 1 & 2 & 3 & \cdots & n \\ 0 & & & & \\ d(2, 1) & 0 & & & \\ d(3, 1) & d(3, 2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ d(n, 1) & d(n, 2) & \cdots & \cdots & 0 \end{bmatrix}$$

- Dissimilarity matrix** (one-mode matrix)

$$d(i, j) \approx 0$$

- highly similar or
- “near” each other

$$sim(i, j) = 1 - d(i, j)$$

Нэрлэсэн шинж чанар

Object Identifier	test-1 (nominal)	test-2 (ordinal)	test-3 (numeric)
1	code A	excellent	45
2	code B	fair	22
3	code C	good	64
4	code A	excellent	28

Холимог төрлийн шинж чанаруудыг агуулсан
жишээ өгөгдлийн хүснэгт

$$d(i, j) = \frac{p - m}{p}$$

m - i ба j ижил төлөвт байгаа шинж чанаруудын тоо
 p - объектыг дүрсэлсэн нэрлэсэн шинж чанаруудын
 нийт тоо

$$\begin{bmatrix} 0 & & & \\ d(2, 1) & 0 & & \\ d(3, 1) & d(3, 2) & 0 & \\ d(4, 1) & d(4, 2) & d(4, 3) & 0 \end{bmatrix}$$

Нэг номинал атрибут

- $p = 1$

if $i == j$

$$d(i, j) = 0$$

else

$$d(i, j) = 1$$

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ 1 & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

Хоёртын шинж чанар

- Хоёртын шинж чанарын ялгааг хэрхэн тооцоолох вэ?

- Тэгш хэмт 2-тын атрибут

- Symmetric binary dissimilarity

$$d(i, j) = \frac{r + s}{q + r + s + t}$$

- Тэгш хэмт бус 2-тын атрибут

- Хоёр 1-ийн тохирол (*a positive match*) нь хоёр 0-ээс (*a negative match*) илүү чухал гэж үзнэ.

- Asymmetric binary dissimilarity

$$d(i, j) = \frac{r + s}{q + r + s}$$

		Object j		
		1	0	sum
Object i	1	q	r	q + r
	0	s	t	s + t
	sum	q + s	r + t	p


Хоёртын шинж чанаруудын болзошгүй байдлын хүснэгт

Тоон шинж чанар

- **Distance**

- $r = 1$. City block (**Manhattan**, taxicab, L1 norm) distance.
- $r = 2$. Euclidean distance
- $r \geq 1$. Minkowski distance
- $r \rightarrow \infty$. Chebyshev / “supremum” (Lmax norm, L_∞ norm) distance

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{1/r}$$



Тоон шинж чанар

- Зай нь дараах математик шинж чанаруудыг хангадаг.

- **Эерэг байна.**

- $d(\mathbf{x}, \mathbf{y}) \geq 0$ for all $\mathbf{x}$ and $\mathbf{y}$
- $d(\mathbf{x}, \mathbf{y}) = 0$ if $\mathbf{x} = \mathbf{y}$

- **Тэгш хэмтэй**

- $d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x})$ for all $\mathbf{x}$ and $\mathbf{y}$.

- **Гурвалжингийн тэгш бус байдал**

- $d(\mathbf{x}, \mathbf{z}) \leq d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z})$ for all points $\mathbf{x}$, $\mathbf{y}$, and $\mathbf{z}$.

- Шинж чанар бүрт ач холбогдлоор нь жин өгөх

- *weighted Euclidean distance*

$$d(i, j) = \sqrt{w_1|x_{i1} - x_{j1}|^2 + w_2|x_{i2} - x_{j2}|^2 + \dots + w_m|x_{ip} - x_{jp}|^2}.$$

- Бусад зайн хэмжүүрүүдэд хэрэглэж болно.

Тоон шинж чанар

$$\max_h x_h = 64 \quad \min_h x_h = 22.$$

$$d_{12} = \frac{|45 - 22|}{64 - 22} = \frac{23}{42} = 0.55$$

$$\begin{bmatrix} 0 & & & \\ 0.55 & 0 & & \\ 0.45 & 1.00 & 0 & \\ 0.40 & 0.14 & 0.86 & 0 \end{bmatrix}$$

- Тоон шинж чанаруудын хувьд утгуудыг $[0.0, 1.0]$ интервалд буулгаж нормалчилна.

$$d_{ij}^{(f)} = \frac{|x_{if} - x_{jf}|}{\max_h x_{hf} - \min_h x_{hf}}$$

Object Identifier	test-1 (nominal)	test-2 (ordinal)	test-3 (numeric)
1	code A	excellent	45
2	code B	fair	22
3	code C	good	64
4	code A	excellent	28

Холимог төрлийн шинж чанаруудыг агуулсан жишээ өгөгдлийн хүснэгт

Ординал шинж чанар

1. Утга бүрийг түүний зэрэглэлийн утгаар солих $M_f = 3$.
 - fair-1, good-2, excellent-3
 - 3, 1, 2, 3
2. Ординаль атрибут бүр өөр өөр тооны төлөвтэй байж болох тул шинж чанар тус бүрийн мужийг $[0.0, 1.0]$ дээр буулгах шаардлагатай бөгөөд ингэснээр атрибут бүр ижил жинтэй байх болно.
 - Fair: $(1-1)/(3-1) = 0$
 - Good: $(2-1)/(3-1) = 0.5$
 - Excellent: $(3-1)/(3-1) = 1$
 - $\{1, 0, 0.5, 1\}$
3. Евклидийн зайг тооцоолох
 - $d(2, 1) = 1$
 - $d(4, 2) = 1$ Хамгийн их ялгаатай

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

Object Identifier	test-1 (nominal)	test-2 (ordinal)	test-3 (numeric)
1	code A	excellent	45
2	code B	fair	22
3	code C	good	64
4	code A	excellent	28

Холимог төрлийн шинж чанаруудыг агуулсан жишээ өгөгдлийн хүснэгт

$$\begin{bmatrix} 0 & & & \\ 1.0 & 0 & & \\ 0.5 & 0.5 & 0 & \\ 0 & 1.0 & 0.5 & 0 \end{bmatrix}$$


Dissimilarity -Холимог шинж чанарууд

- Өөр өөр шинж чанаруудыг нэг ялгаатай байдлын матрицад нэгтгэж, бүх шинж чанаруудыг нэг нийтлэг хуваарьт оруулах [0.0, 1.0].

$$d(i, j) = \frac{\sum_{f=1}^p \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p \delta_{ij}^{(f)}}$$

- a)* i объект эсвэл j объектын хувьд f шинж чанарын хэмжилт байхгүй (*missing*) үед
- b)* $x_{if} = x_{jf} = 0$ ба f нь тэгш хэмт бус хоёртын шинж чанар үед

- c)* Бусад үед $\rightarrow \delta_{ij}^{(f)} = 1$


$$\delta_{ij}^{(f)} = 0$$

Dissimilarity -Холимог шинж чанарууд

Object Identifier	test-1 (nominal)	test-2 (ordinal)	test-3 (numeric)
1	code A	excellent	45
2	code B	fair	22
3	code C	good	64
4	code A	excellent	28

$$d(i, j) = \frac{\sum_{f=1}^p \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p \delta_{ij}^{(f)}}$$

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ \boxed{1} & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & & & \\ 1.0 & 0 & & \\ \boxed{0.5} & 0.5 & 0 & \\ 0 & 1.0 & 0.5 & 0 \end{bmatrix} \begin{bmatrix} 0 & & & \\ 0.55 & 0 & & \\ \boxed{0.45} & 1.00 & 0 & \\ 0.40 & 0.14 & 0.86 & 0 \end{bmatrix}$$



$$\begin{bmatrix} 0 & & & \\ 0.85 & 0 & & \\ \boxed{0.65} & 0.83 & 0 & \\ 0.13 & 0.71 & 0.79 & 0 \end{bmatrix}$$

3 атрибут бүрийн хувьд: $\delta_{ij}^{(f)} = 1$

$$d(3, 1) = \frac{1(1) + 1(0.50) + 1(0.45)}{3} = 0.65.$$

1 болон 4-р объектууд хамгийн их адилхан
1 болон 2-р объектууд хамгийн бага адилхан

Cosine Similarity

- Баримт бичиг нь мянга мянган шинж чанартай байж болно
 - Баримт бичгийг илэрхийлэх нэр томъёоны давтамжийн вектор нь өндөр хэмжээст, сийрэг байдаг.
 - Уламжлалт зайн хэмжүүрүүд ийм сийрэг тоон өгөгдөлд сайнаар нөлөөлдөггүй.

Document Vector or Term-Frequency Vector

Document	team	coach	hockey	baseball	soccer	penalty	score	win	loss	season
<i>Document1</i>	5	0	3	0	2	0	0	2	0	0
<i>Document2</i>	3	0	2	0	1	1	0	1	0	1
<i>Document3</i>	0	7	0	2	1	0	0	3	0	0
<i>Document4</i>	0	1	0	0	1	2	2	0	3	0

Cosine Similarity

Document Vector or Term-Frequency Vector

Document	team	coach	hockey	baseball	soccer	penalty	score	win	loss	season
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

$$\mathbf{x} = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0)$$


$$\mathbf{y} = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)$$

$$\begin{aligned}\mathbf{x}^t \cdot \mathbf{y} &= 5 \times 3 + 0 \times 0 + 3 \times 2 + 0 \times 0 + 2 \times 1 + 0 \times 1 + 0 \times 0 + 2 \times 1 \\ &\quad + 0 \times 0 + 0 \times 1 = 25\end{aligned}$$

$$\|\mathbf{x}\| = \sqrt{5^2 + 0^2 + 3^2 + 0^2 + 2^2 + 0^2 + 0^2 + 2^2 + 0^2 + 0^2} = 6.48$$

$$\|\mathbf{y}\| = \sqrt{3^2 + 0^2 + 2^2 + 0^2 + 1^2 + 1^2 + 0^2 + 1^2 + 0^2 + 1^2} = 4.12$$

$$\text{sim}(\mathbf{x}, \mathbf{y}) = 0.94$$



$\cos(90) = 0 \rightarrow$ no match

$\cos(0) = 1 \rightarrow$ the greater the match between vectors

БАЯРЛАЛАА

Data mining and machine learning

