

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Өгөгдлийн урьдчилсан боловсруулалт (Data preprocessing)


Өгөгдлийн чанар

- Өгөгдлийн чанарт нөлөөлөх дараах олон хүчин зүйл байдаг.
 - Үнэн зөв байдал / **accuracy**
 - Бүрэн бүтэн байдал / **completeness**
 - Нийцтэй байдал / **consistency**
 - Цаг хугацаандаа байх / **timeliness**
 - Үнэмшилтэй байдал / **believability**
 - Тайлбарлах чадвар / **interpretability**

Өгөгдлийн урьдчилсан боловсруулалт

- Өгөгдлийг урьдчилан боловсруулах хэд хэдэн арга байдаг.
 - Өгөгдөл цэвэрлэх / **Data cleaning**
 - Шуугиан устгах, үл нийцэх өгөгдлийг засах
 - Өгөгдөл нэгтгэх / **Data integration**
 - Олон эх сурвалжаас авсан өгөгдлийг нэгтгэх
 - Өгөгдлийг багасгах / **Data reduction**
 - Нэгтгэх, илүүдэл шинж чанарыг арилгах зэргээр өгөгдлийн хэмжээг бууруулах
 - Өгөгдлийн хувиргалт / **Data transformations**
 - Нормалчлах $\rightarrow [0,1]$ мужруу буулгах

Өгөгдлийн урьдчилсан боловсруулалт



1. Өгөгдөл цэвэрлэх

- Дутуу утгуудыг бөглөх (*filling*)
- Шуугиантай өгөгдлийг тэгшитгэх (*smoothing*)
- Хэвийн бус утгуудыг илрүүлэх, устгах (*identifying, removing*)
- Нийцгүй байдлыг шийдвэрлэх (*resolving*)

1. Өгөгдөл цэвэрлэх – Missing value

1.1 Missing value

- Бичлэгийг устгах
- Хэрэв шинж чанар нь зорилтот хувьсагчтай тийм ч их хамааралгүй бол баганыг бүхэлд нь устгана.

Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	N/A	N/A	95%
8	Lite	76	77%
9	Fast+	180	N/A

← Delete
← Delete
← Delete



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
5	Lite	76	70%
6	Fast+	155	10%
8	Lite	76	77%

1. Өгөгдөл цэвэрлэх – Missing value

1.1 Missing value

- Дутуу утгыг гараар бөглөх
- Дутуу утганд зориулж тогтмол ашиглах
 - “*Unknown*” эсвэл $-\infty$, энгийн боловч үр дүнтэй биш
- Төвийн хандлагын хэмжүүрийг ашиглах
- Өгөгдсөн бичлэгтэй ижил ангилалд (*class*) хамаарах бүх түүврийн дундаж болон медианыг ашиглах
- Хамгийн их магадлалтай утгыг ашиглах

1. Өгөгдөл цэвэрлэх – Noisy data

1.2 Noisy data

- Санамсаргүй алдаа
- Хэвийн биш утга (***Outlier***) мөн шуугиан байж болно.
 - Статистикийн техникүүд (*boxplots, scatter plots*)
 - Өгөгдлийн дүрслэл (*data visualization*)
- Тоон атрибут (*price*)
 - Шуугианыг арилгахын тулд өгөгдлийг хэрхэн тэгшитгэх (***smooth***) вэ?

1. ӨГӨГДӨЛ ЦЭВЭРЛЭХ – Noisy data

Data smoothing techniques

- Binning

- *Тэнцүү давтамжтай сав*
(*Equal-frequency bins*)
 - Smoothing by bin means
 - Smoothing by bin medians
 - Smoothing by bin boundaries
- *Тэнцүү өргөнтэй сав*
(*Equal-width bins*)

Sorted data for *price* (in dollars): 4, 8, 15, 21, 21, 24, 25, 28, 34

Partition into (equal-frequency) bins:

Bin 1: 4, 8, 15

Bin 2: 21, 21, 24

Bin 3: 25, 28, 34

Smoothing by bin means:

Bin 1: 9, 9, 9

Bin 2: 22, 22, 22

Bin 3: 29, 29, 29

Smoothing by bin boundaries:

Bin 1: 4, 4, 15


Bin 2: 21, 21, 24

Bin 3: 25, 25, 34

1. Өгөгдөл цэвэрлэх – Noisy data

Data smoothing techniques

- Clustering
 - *Outlier* илрүүлэх болон устгах



Хот дахь хэрэглэгчийн байршилтай холбоотой
график

1. Өгөгдөл цэвэрлэх – Зөрчил илрүүлэх

1.3 Зөрчил илрүүлэх

- Зөрчлийг илрүүлэхэд **metadata** хэрэглэх
 - *Mean, median, mood* олох
 - Өгөгдөл тэгш хэмтэй эсвэл хазайлттай
 - Бүх утгууд хүлээгдэж буй хязгаарт багтаж байна уу?
 - Атрибут бүрийн стандарт хазайлт хэд вэ?
 - *Outlier* илрүүлж тэмдэглэх
 - Upper limit= $\bar{X}+2\times SD$ Lower limit= $\bar{X}-2\times SD$

1. Өгөгдөл цэвэрлэх – Зөрчил илрүүлэх

1.3 Зөрчил илрүүлэх

- Атрибутын илүүдлийг шалгах
- Кодчиллын нийцгүй хэрэглээ болон Үл нийцэх өгөгдлийн дүрслэлийг шалгах
 - Жишээ нь: Огноо - “2010/12/25” ба “25/12/2010”
- Дүрмүүдийг шалгах
 - **Unique rule**
 - **Consecutive rule**
 - **Null rule**

1. Өгөгдөл цэвэрлэх – Зөрчил илрүүлэх

1.3 Зөрчил илрүүлэх

- **Хэрэгслүүдийг ашиглан илрүүлэх**
 - *Өгөгдлийн цэвэрлэгээний хэрэгслүүд (Data scrubbing tools)*
 - Өгөгдөл дэх алдааг илрүүлж, засахад домэйний энгийн мэдлэг ашигладаг.
 - *Өгөгдлийн аудитын хэрэгслүүд (Data auditing tools)*
 - Дүрэм, харилцааг илрүүлэхийн тулд өгөгдөлд дүн шинжилгээ хийж, ийм нөхцөлийг зөрчсөн өгөгдлийг илрүүлэх замаар зөрчлийг олж илрүүлдэг.
 - *Гадны лавлагаа ашиглан гараар засах*
 - Өгөгдөл оруулах явцад гарсан алдааг цаасан дээрээс шалган засах

2. ӨГӨГДӨЛ НЭГТГЭХ

2.1 Энтитиг тодорхойлох асуудал

- Өгөгдлийн олборлолт нь ихэвчлэн өгөгдлийг нэгтгэхийг шаарддаг.
- Болгоомжтой хийгдсэн нэгтгэх процесс нь өгөгдлийн багц дахь **илүүдэл** болон **зөрчлийг** багасгах, мөн зайлсхийхэд тусална.
- Олон эх сурвалжаас авсан ижил төстэй энтитинүүдийг хэрхэн тохируулах вэ?
 - Нэг өгөгдлийн санд – *customer_id*, өөр өгөгдлийн санд – *cust_number* → ижил атрибут эсэх
- **Metadata** нь өгөгдлийг нэгтгэх явцад гарч болох алдаанаас зайлсхийхэд тусална.

2. ӨГӨГДӨЛ НЭГТГЭХ


2.2 Илүүдэл ба корреляцийн шинжилгээ

- Нэгтгэх үед тохиолддог өөр нэг асуудал бол *илүүдэл*.
 - *Derivable data*: Атрибут нь өөр атрибут эсвэл атрибутын багцаас үүсэлтэй бол энэ нь илүүдэл байж болно.
- Корреляцийн шинжилгээгээр зарим илүүдлийг илрүүлж болно.
 - Нэг атрибут нөгөөг хэр хүчтэй илэрхийлж байгааг хэмжинэ.
 - *Нэрлэсэн атрибут*: Хи-квадрат тест (χ^2)
 - *Тоон атрибут*: Корреляцийн коэф болон коварианс

2. ӨГӨГДӨЛ НЭГТГЭХ

χ^2 Correlation Test – Нэрлэсэн атрибут

- **Null Hypothesis (H_0)** – 2 хувьсагчийн хооронд мэдэгдэхүйц хамаарал байхгүй.
- **Alternative Hypothesis (H_a)** – 2 хувьсагчийн хооронд мэдэгдэхүйц хамаарал байна.
- Туршилтын Хи квадратыг тооцоолно.
- χ^2 критикал утгыг статистик туршилтын үр дүнтэй харьцуулна.
 - Критикал утга нь тэг таамаглалыг үгүйсгэх альфа түвшний босго юм.
 - Альфагийн хувьд түгээмэл хэрэглэгддэг утгууд нь **0.05**, **0.01** эсвэл **0.10** байна.
- Чөлөөт зэрэг (df) нь ангиллуудын тооноос нэгийг хассанаар тодорхойлогдоно.



Хи квадратын тархалт тэгш хэмт бус, хазайсан байдаг.

2. ӨГӨГДӨЛ НЭГТГЭХ

χ^2 Correlation Test – Нэрлэсэн атрибут

- A болон B атрибутууд – c болон r ялгаатай утгуудтай

$a_1, a_2, \dots, a_c$

$b_1, b_2, \dots, b_r$

- $o_{ij} - (A_i, B_j)$ хамтдаа ажиглагдсан давтамж

- $e_{ij} - (A_i, B_j)$ хүлээгдэж буй давтамж

- n – өгөгдлийн бичлэгийн тоо

- $count(A = a_i)$ - A атрибутын a_i утгатай байгаа бичлэгийн тоо

- $count(B = b_j)$ - B атрибутын b_j утгатай байгаа бичлэгийн тоо

- Туршилтын Хи квадратыг тооцоолно.

$$\chi^2 = \sum_{i=1}^c \sum_{j=1}^r \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

$$e_{ij} = \frac{count(A = a_i) \times count(B = b_j)}{n}$$

2. ӨГӨГДӨЛ НЭГТГЭХ

χ^2 Correlation Test – Нэрлэсэн атрибут

- Жишээ

- Судалгаанд 1500 хүн оролцсон.
- **Preferred reading:** fiction, non-fiction
- **Gender:** male, female

2 × 2 Contingency Table Data

	<i>male</i>	<i>female</i>	<i>Total</i>
<i>fiction</i>	250 (90)	200 (360)	450
<i>non_fiction</i>	50 (210)	1000 (840)	1050
Total	300	1200	1500

Note: Are *gender* and *preferred_reading* correlated?

Хи-квадрат магадлалын хүснэгт

Чөлөөт зэрэг	Магадлал			
	0.1	0.05	0.01	0.001
1	2.71	3.84	6.64	10.83
2	4.6	5.99	9.21	13.82
3	6.25	7.82	11.34	16.27
4	7.78	9.49	13.28	18.46

$$e_{11} = \frac{\text{count}(\text{male}) \times \text{count}(\text{fiction})}{n} = \frac{300 \times 450}{1500} = 90$$

$$\chi^2 = \frac{(250 - 90)^2}{90} + \frac{(50 - 210)^2}{210} + \frac{(200 - 360)^2}{360} + \frac{(1000 - 840)^2}{840}$$

$$= 284.44 + 121.90 + 71.11 + 30.48 = 507.93.$$

- **Чөлөөт зэрэг:** $(2-1)(2-1)=1$ $[(r - 1) \times (c - 1)]$
- **0.001** магадлалын түвшинд таамаглалыг үгүйсгэхэд шаардлагатай χ утга нь **10.828** байна.
- 2 атрибут эдгээр хүмүүсийн хувьд хүчтэй хамааралтай байна.

2. ӨГӨГДӨЛ НЭГТГЭХ

Ковариаци – Тоон атрибут

- Ковариаци нь хоёр хувьсагчийн хамт өөрчлөгдөх түвшинг хэмждэг.
 - $> 0 \rightarrow$ эерэг хамаарлыг илэрхийлнэ
 - Нэг хувьсагчийн утга өсөхөд нөгөө хувьсагчийн утга мөн өсөх хадлагатай байдаг.
 - $< 0 \rightarrow$ сөрөг хамаарлыг илэрхийлнэ
 - Нэг хувьсагчийн утга өсөх тусам нөгөө хувьсагч буурах хандлагатай байдаг
 - 2 хувьсагч биеэ даасан буюу хамааралгүй үед $\rightarrow covariance = 0$
 - Эсрэгээрээ буюу $covariance = 0$ байх 2 атрибут биеэ даасан биш байж болно.

$$covariance(\mathbf{x}, \mathbf{y}) = s_{xy} = \frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$$

$$Cov(A, B) = E(A \cdot B) - \bar{A}\bar{B}.$$

$$\begin{aligned} \bar{x} &= \frac{1}{n} \sum_{k=1}^n x_k \text{ is the mean of } \mathbf{x} \\ \bar{y} &= \frac{1}{n} \sum_{k=1}^n y_k \text{ is the mean of } \mathbf{y} \end{aligned}$$

2. ӨГӨГДӨЛ НЭГТГЭХ

Коварианс – Тоон атрибут

- Жишээ

- *AllElectronics, HighTech*
- 5 цагийн хугацаанд ажиглагдсан хувьцааны үнэ
- Хэрэв хувьцаанууд нь ижил салбарын чиг хандлагад өртвөл үнэ нь хамтдаа өсөх үү эсвэл буурах уу?

Stock Prices for *AllElectronics* and *HighTech*

<i>Time point</i>	<i>AllElectronics</i>	<i>HighTech</i>
t1	6	20
t2	5	10
t3	4	14
t4	3	5
t5	2	5

$$E(\text{AllElectronics}) = \frac{6 + 5 + 4 + 3 + 2}{5} = \frac{20}{5} = \$4$$

$$E(\text{HighTech}) = \frac{20 + 10 + 14 + 5 + 5}{5} = \frac{54}{5} = \$10.80.$$

$$\begin{aligned} \text{Cov}(\text{AllElectronics}, \text{HighTech}) &= \frac{6 \times 20 + 5 \times 10 + 4 \times 14 + 3 \times 5 + 2 \times 5}{5} - 4 \times 10.80 \\ &= 50.2 - 43.2 = 7. \end{aligned}$$

2. ӨГӨГДӨЛ НЭГТГЭХ

Корреляцийн коэффициент – Тоон атрибут

- Корреляци нь объект хоорондын шугаман хамаарлын хүч, чиглэлийг хэмждэг, ковариацийн нормалчлагдсан хувилбар.
 - $-1 \leq \text{corr}(x, y) \leq 1$
 - $\text{corr}(x, y) > 0 \rightarrow x, y$ эерэг хамааралтай, утга өндөр байх тусам хүчтэй хамааралтай
 - $\text{corr}(x, y) < 0 \rightarrow x, y$ сөрөг хамааралтай

$$\text{corr}(\mathbf{x}, \mathbf{y}) = \frac{\text{covariance}(\mathbf{x}, \mathbf{y})}{\text{standard_deviation}(\mathbf{x}) * \text{standard_deviation}(\mathbf{y})} = \frac{s_{xy}}{s_x s_y},$$

$$\text{standard_deviation}(\mathbf{x}) = s_x = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (x_k - \bar{x})^2}$$

$$\text{standard_deviation}(\mathbf{y}) = s_y = \sqrt{\frac{1}{n-1} \sum_{k=1}^n (y_k - \bar{y})^2}$$

2. ӨГӨГДӨЛ НЭГТГЭХ

2.3 Бичлэгийн (*tuple*) давхардал

- Атрибутын давхардлыг илрүүлэхээс гадна бичлэгийн түвшинд давхардлыг илрүүлэх шаардлагатай.

2.4 Өгөгдлийн утгын зөрчлийг илрүүлэх, шийдвэрлэх

- Өгөгдлийг нэгтгэх нь өгөгдлийн утгын зөрчлийг мөн илрүүлж, шийдвэрлэх хамаарна.
- Өөр эх сурвалжуудаас ирсэн атрибутын утга өөр байж болно.
 - Хуваарь, кодчилол
 - Өндөр – метр, инч

3. Өгөгдлийг багасгах

- Асар их хэмжээний өгөгдөл дээр олборлолт хийх нь их хугацаа шаардах тул боломжгүй байдаг.
- Анхны өгөгдлийн хэмжээнээс хамаагүй бага боловч түүний бүрэн бүтэн байдлыг хадгалж чадах өгөгдлийн багцын багасгасан дүрслэл
 - Үр дүнтэй
 - Бараг ижил үр дүнг олж авна
- Өгөгдлийг багасгах стратеги
 - Хэмжээст байдлыг багасгах / *dimensionality reduction*
 - Тоо хэмжээг багасгах / *numerosity reduction*

3. Өгөгдлийг багасгах


- **3.1 Хэмжээст байдлыг багасгах**
- *Principal components analysis (PCA)*
 - Энэ нь анхны өгөгдлийг жижиг орон зайд хувиргах буюу проекцлох
- *Attribute subset selection*
 - Хамааралгүй, сул хамааралтай эсвэл илүүдэл шинж чанаруудыг илрүүлж устгах

3. Өгөгдлийг багасгах

- **3.1 Хэмжээст байдлыг багасгах**

- *Principal components analysis (PCA)*

- Өгөгдлийн хамгийн чухал өөрчлөлтийг агуулсан проекцийг олох
- Анхны өндөр хэмжээст өгөгдөл нь маш бага хэмжээст орон зайд проекцлогдож, хэмжээсийг багасгадаг.
- Зөвхөн тоон өгөгдөл дээр ажиллана.



3. Өгөгдлийг багасгах

- **3.1 Хэмжээст байдлыг багасгах**

- *Principal components analysis (PCA)*

- ***Standardization***: Бүх хувьсагч ижил масштабтай байхыг баталгаажуулдаг.
- ***Covariance Matrix***: Стандартчилсан өгөгдлийн ковариацийн матрицыг тооцоол. Ковариацийн матриц нь бүх хос хувьсагчийн хоорондын хамаарлыг тодорхойлдог.
- ***Eigenvalue Decomposition***: Ковариацийн матрицын хувийн утга болон хувийн векторуудыг тооцоолно.
- ***Selection of Principal Components***: Хувийн утгуудыг буурахаар эрэмбэлж, үндсэн бүрэлдэхүүн хэсгүүдийг бүрдүүлэхийн тулд хамгийн том k хувийн утгуудад харгалзах дээд k хувийн векторуудыг сонгоно.
- ***Projection***: Өгөгдлийн багцын багасгасан хэмжээст дүрслэлийг олж авахын тулд сонгосон үндсэн бүрэлдэхүүн хэсгүүдэд анхны өгөгдлийг буулгах/хувиргах.

БАЯРЛАЛАА

Data mining and machine learning

