

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС




Агуулга

- Ангилал / Classification
- Шийдвэрийн мод / Decision tree

Process (1): Model Construction

- **Data classification**


- *learning step*
- *classification step*



Process (2): Using the Model in Prediction

- **Data classification**

- *learning step*
- *classification step*



Шийдвэрийн мод – Decision tree

- **Эцэг зангилаа /Root node/:** оролтын ирмэг байхгүй, 0 болон түүнээс олон гаралтын ирмэгтэй
- **Дотоод зангилаа /Internal nodes/:** оролтын нэг ирмэгтэй, 2 болон түүнээс дээр гаралтын ирмэгтэй
 - Атрибут дээрх тестийг заана
 - Ирмэгүүд нь тестийн үр дүнг заана
- **Навч эсвэл төгсгөлийн зангилаа /Leaf or terminal nodes/:** оролтын нэг ирмэгтэй, гаралтын ирмэг байхгүй
 - Ангиллын шошго





Figure 4.4. A decision tree for the mammal classification problem.

Шийдвэрийн модны жишээ

categorical
categorical
continuous
class

ID	Home Owner	Marital Status	Annual Income	Defaulted Borrower
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes


Training Data



Model: Decision Tree

Туршилтын өгөгдөлд загварыг ашиглах

Start from the root of tree.




Test Data

Home Owner	Marital Status	Annual Income	Defaulted Borrower
No	Married	80K	?

Туршилтын өгөгдөлд загварыг ашиглах

Test Data


Home Owner	Marital Status	Annual Income	Defaulted Borrower
No	Married	80K	?



Туршилтын өгөгдөлд загварыг ашиглах

Test Data

Home Owner	Marital Status	Annual Income	Defaulted Borrower
No	Married	80K	?



Assign Defaulted to "No"


Шийдвэрийн модны ангиллын даалгавар

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?


Test Set



Decision Tree Induction


- **Алгоритмууд:**
 - *Hunt's Algorithm (one of the earliest)*
 - *ID3, C4.5*
 - *CART*
 - *SLIQ, SPRINT*

Хантын алгоритм




(7,3)


(a)



(b)



(c)



(d)

ID	Home Owner	Marital Status	Annual Income	Defaulted Borrower
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Шийдвэрийн модны индукцийн дизайны асуудлууд

- Шийдвэрийн модны сургалтын алгоритм нь дараах хоёр асуудлыг шийдвэрлэх ёстой.
- **Сургалтын бичлэгүүдийг хэрхэн хуваах ёстой вэ?**
 - Атрибут шалгах
 - Атрибутын төрлөөс хамаарна
 - Үнэлэх хэмжүүр
- **Хуваах процедурыг хэрхэн зогсоох ёстой вэ?**
 - Бүх бичлэгүүд нэг ангилалд хамаарах эсвэл тухайн атрибутын ижил утгатай бол
 - Цааш хуваах атрибут байхгүй, эсвэл тухайн хуваалтад бичлэг байхгүй
 - *Stop condition*: Модны хамгийн их гүнд хүрэх, зангилаан дахь тохиолдлуудын хамгийн бага тоонд хүрэх

Бинари атрибут /Binary/

- **Хоёртын атрибутыг шалгах**
 - Хоёр боломжит гаралтыг үүсгэдэг.





Figure 4.8. Test condition for binary attributes.

Номинал атрибут /Nominal/

Номинал атрибутыг шалгах нөхцөл


□ Multi-way split:

- Атрибутын ялгаатай утгуудын тоотой ижил тооны хуваалт хэрэглэх



□ Binary split:

- Зарим шийдвэрийн модны алгоритмууд /*CART*/ k атрибутын утгын хоёртын хуваалтыг үүсгэх бүх $2^{k-1} - 1$ тохиолдлыг авч үздэг.
- Утгуудыг 2 дэд бүлэгт хуваана




Ординал атрибут /Ordinal/

Ординал атрибутыг шалгах нөхцөл



- Multi-way split:

- Атрибутын ялгаатай утгуудын тоотой ижил тооны хуваалт хэрэглэх



- Binary split:

- Утгуудыг 2 дэд бүлэгт хуваана
- Атрибутын утгуудын дарааллын шинж чанарыг хадгалах




Үргэлжилсэн атрибут /Continuous/


Үргэлжилсэн утгатай атрибутыг шалгах нөхцөл

- Аргууд

- **Discretization:** Ординал ангиллын шинж чанарыг бий болгох
 - Тухайн мужийг олохдоо **equal width, equal frequency** зэрэг аргуудыг хэрэглэж болно
- **Binary Decision:** $(A < v)$ or $(A \geq v)$
 - Бүх боломжит хуваалтыг авч үзээд хамгийн сайн зүсэлтийг олно.



(i) Binary split



(ii) Multi-way split




Хамгийн сайн хуваалтыг тодорхойлох

Хуваахаас өмнө:

□ 0 ангиллын бичлэг -10

□ 1 ангиллын бичлэг – 10

Ангиллын тархалт (0.5, 0.5)



Which test condition is the best?

Customer Id	Gender	Car Type	Shirt Size	Class
1	M	Family	Small	C0
2	M	Sports	Medium	C0
3	M	Sports	Medium	C0
4	M	Sports	Large	C0
5	M	Sports	Extra Large	C0
6	M	Sports	Extra Large	C0
7	F	Sports	Small	C0
8	F	Sports	Small	C0
9	F	Sports	Medium	C0
10	F	Luxury	Large	C0
11	M	Family	Large	C1
12	M	Family	Extra Large	C1
13	M	Family	Medium	C1
14	M	Luxury	Extra Large	C1
15	F	Luxury	Small	C1
16	F	Luxury	Small	C1
17	F	Luxury	Medium	C1
18	F	Luxury	Medium	C1
19	F	Luxury	Medium	C1
20	F	Luxury	Large	C1

Хамгийн сайн хуваалтыг тодорхойлох

- *Greedy* арга:
 - Хамгийн сайн хуваалтыг сонгох нь ихэвчлэн *child* зангилааны бохирдлын зэрэг дээр суурилдаг.
 - Илүү цэвэр ангиллын тархалттай зангилаануудыг илүүд үздэг
- Зангилааны бохирдлыг хэмжих шаардлагатай:
 - Хамгийн их бохирдолтой - Ангиллын тархалт (0.5, 0.5)
 - Цэвэр буюу тэг бохирдолтой - Ангиллын тархалт (0, 1)

C0: 5
C1: 5

High degree of impurity

C0: 9
C1: 1

Low degree of impurity

Атрибут сонгох хэмжүүр

- Атрибут сонгох түгээмэл хэмжүүрүүд (*attribute selection measures*)
 - *Information Gain*
 - *Gain Ratio*
 - *Gini index*

Мэдээллийн ашиг - Information Gain

- **ID3** нь мэдээллийн ашгийг атрибут сонгох хэмжүүр болгон ашигладаг.
 - Хамгийн өндөр мэдээллийн ашигтай атрибутыг сонгох
- **$Info(D)$** - **D** дэх бичлэгийг ангилахад шаардагдах хүлээгдэж буй мэдээлэл (**entropy**)
 - p_i - C_i ангилалд **D** -ийн дурын бичлэг хамаарах магадлал

$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i)$$

- **$Info_A(D)$** - **A** атрибутаар хуваалт хийхэд **D** дэх бичлэгийг ангилахад шаардагдах мэдээлэл

$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j)$$

- **Мэдээллийн ашиг** - анхны мэдээллийн шаардлага болон шинэ шаардлага хоорондын зөрүү.

$$Gain(A) = Info(D) - Info_A(D)$$

Мэдээллийн ашиг - Information Gain

• Жишээ

- Бүх атрибут дискрет утгатай
- *class label attribute* $\rightarrow$ *buys_computer*
 - Yes - 9, no - 5

- Шаардагдах хүлээгдэж буй мэдээлэл

$$Info(D) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0.940 \text{ bits}$$

- *Age* атрибут

- Youth (5) $\rightarrow$ yes - 2, no - 3
- Middle_aged (4) $\rightarrow$ yes - 4, no - 0
- Senior (5) $\rightarrow$ yes - 3, no - 2

$$Info_{age}(D) = \frac{5}{14} \times \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{4}{14} \times \left(-\frac{4}{4} \log_2 \frac{4}{4} \right) + \frac{5}{14} \times \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) = 0.694 \text{ bits}$$

- Мэдээллийн ашиг $Gain(age) = Info(D) - Info_{age}(D) = 0.940 - 0.694 = 0.246 \text{ bits}$

AllElectronics customer database

RID	age	income	student	credit_rating	Class: buys_computer
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

$$Gain(income) = 0.029 \text{ bits}$$

$$Gain(student) = 0.151 \text{ bits}$$

$$Gain(credit_rating) = 0.048 \text{ bits}$$

Ашгийн харьцаа - Gain Ratio

- **C4.5** нь **ID3**-ийн дутагдалтай талыг шийдэхийг оролддог ашгийн харьцаа гэж нэрлэгддэг мэдээллийн ашгийн өргөтгөлийг ашигладаг.
- Энэ нь **Info(D)**-тэй ижил төстэй байдлаар тодорхойлсон "**split information**"-ийн утгыг ашиглан мэдээллийн ашгийг нормалчилдаг.

$$SplitInfo_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2 \left(\frac{|D_j|}{|D|} \right)$$

- **D** дэх бичлэгийн нийт тоог гаралтан дахь бичлэгийн тоотой харгалзан үзнэ.

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}$$

- Хамгийн их ашгийн харьцаатай атрибутыг хуваах атрибутаар сонгоно.

АШГИЙН харьцаа - Gain Ratio

- **Жишээ**

- **Income** атрибут

- Low - 4
 - Medium - 6
 - High - 4

<i>RID</i>	<i>age</i>	<i>income</i>	<i>student</i>	<i>credit_rating</i>	<i>Class: buys_computer</i>
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

$$SplitInfo_{income}(D) = -\frac{4}{14} \times \log_2 \left(\frac{4}{14} \right) - \frac{6}{14} \times \log_2 \left(\frac{6}{14} \right) - \frac{4}{14} \times \log_2 \left(\frac{4}{14} \right) = 1.557$$

$$Gain(income) = 0.029$$

$$GainRatio(income) = 0.029/1.557 = 0.019$$

Жини индекс - Gini index

$$Gini(D) = 1 - \sum_{i=1}^m p_i^2$$

- Жини индексийг *CART*, *SLIQ*, *SPRINT* алгоритмуудад ашигладаг.
- Жини индекс нь өгөгдлийн багцын хуваалтын бохирдлын хэмжүүр.
- Жини индекс нь атрибут бүрийн хувьд хоёртын хуваагдлыг авч үздэг. (D_1 , D_2 өгөгдлийн багц болгон хуваана.)
 - Олон салаатай хуваалтад ч мөн хэрэглэж болно
- A атрибут нь дискрет утгатай, v ялгаатай утгатай
 - 2^v дэд багц үүсэх боломжтой.
 - {low, medium, high}, {low, medium}, {low, high}, {medium, high}, {low}, {medium}, {high}, {}
- A атрибут дээрх хамгийн сайн 2-тын хуваалтыг олохын тулд бүх боломжит дэд багцуудыг шалгана.

$$Gini_A(D) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

$$\Delta Gini(A) = Gini(D) - Gini_A(D)$$

Жини индекс - Gini index

- **Жишээ**

- *class label attribute* $\rightarrow$ *buys_computer*

- *Yes* - 9, *no* - 5

- ***D*** дэх бохирдлын хэмжээ

$$Gini(D) = 1 - \left(\frac{9}{14}\right)^2 - \left(\frac{5}{14}\right)^2 = 0.459.$$

- ***Income*** атрибут

- *{low, medium}* – 10

- *Yes* - 7, *no* - 3

- *{high}* – 4

- *Yes* – 2, *no* - 2

<i>RID</i>	<i>age</i>	<i>income</i>	<i>student</i>	<i>credit_rating</i>	<i>Class: buys_computer</i>
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

$$Gini_{income \in \{low, medium\}}(D) = \frac{10}{14} Gini(D_1) + \frac{4}{14} Gini(D_2) = \frac{10}{14} \left(1 - \left(\frac{7}{10}\right)^2 - \left(\frac{3}{10}\right)^2 \right) + \frac{4}{14} \left(1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 \right) = 0.443 = Gini_{income \in \{high\}}(D)$$

Жини индекс - Gini index

- **Жишээ**

$$Gini(D) = 1 - \left(\frac{9}{14}\right)^2 - \left(\frac{5}{14}\right)^2 = 0.459.$$

- *Income*

- {low, medium}, {high} → Gini index = 0.443 → **best binary split**
 - {low, high}, {medium} → Gini index = 0.458
 - {medium, high}, {low} → Gini index = 0.450

- *Age*

- {youth, senior}, {middle aged} → Gini index = **0.357** → **best binary split**

- *Student* болон *credit_rating* хоёулаа хоёртын атрибутууд

- Gini index = 0.367 Gini index = 0.429

- *Age* атрибутын 2-тын хуваагдал нь **D** дэх бичлэгүүдийн бохирдлыг хамгийн их хэмжээгээр бууруулна.

$$0.459 - 0.357 = 0.102$$

Үргэлжилсэн утгатай атрибут: Жини индекс тооцоолох

- Үр дүнтэй тооцоолол: Атрибут бүрт зориулж,
 - Утган дээр нь үндэслэн атрибутыг эрэмбэл
 - gini index тооцоол
 - Хамгийн бага gini index-тэй хуваалтын цэгийг сонго

Cheat		No		No		No		Yes		Yes		Yes		No		No		No		No			
Sorted Values Split Positions	→	Annual Income																					
		60		70		75		85		90		95		100		120		125		220			
		55		65		72		80		87		92		97		110		122		172		230	
		<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>	<=	>
	Yes	0	3	0	3	0	3	0	3	1	2	2	1	3	0	3	0	3	0	3	0	3	0
	No	0	7	1	6	2	5	3	4	3	4	3	4	3	4	4	3	5	2	6	1	7	0
	Gini	0.420		0.400		0.375		0.343		0.417		0.400		<u>0.300</u>		0.343		0.375		0.400		0.420	

Атрибут сонгох хэмжүүр

- **Мэдээллийн ашиг (*ID3*)**
 - Олон тооны утгатай атрибутуудад хэвийлттэй.
 - Модны дотоод зангилаа бүрт хоёроос илүү хүүхэд зангилаа байж болно.
- **Ашгийн харьцаа (*C4.5*)**
 - Дээрх асуудлыг шийддэг ч зарим тохиолдолд цөөн хуваалтыг сонгох хандлагатай.
 - Өгөгдлийн багцыг хуваасны дараа үүссэн хуваалтуудын хэмжээ ихээхэн ялгаатай байх.
 - Модны дотоод зангилаа бүрт хоёроос илүү хүүхэд зангилаа байж болно.
- **Жини индекс (*CART*)**
 - Мэдээллийн ашигтай харьцуулахад олон утгатай атрибутын хэвийлт бага.
 - Хоёртын мод (*binary tree*) үүсгэдэг.

Хэт тохируулагдах (*Overfitting*)

- Загвар хэт тохируулагдахаас сэргийлж модыг тайрдаг.
 - *Pre-pruning*
 - *Post-pruning*

Модыг тайрах

- ***Урьдчилан тайралт (Pre-pruning)***

- Модыг байгуулж байгаа процессыг эрт зогсоосноор модыг тайрдаг.
- Тодорхой нөхцөлд зангилаа хуваагдахаас урьдчилан сэргийлэхийн тулд мод байгуулах явцад зогсоох шалгуурыг тавьдаг.
- *Мэдээллийн ашиг, Жини индекс* гэх мэт хэмжүүрүүдийг ашиглан хуваагдлын сайн чанарыг хэмжиж болно.
 - Хэрэв зангилаа дахь бичлэгүүдийг хуваах нь сайн чанарын хэмжүүрийн босго утгаас доогуур бол хуваалтыг зогсоох буюу тайрах
 - Босго утгыг сонгох хэцүү
- Зогсоох үед зангилаа нь навч зангилаа болно.

Модыг тайрах

- *Дараах тайралт (Post-pruning)*

- **CART:** cost-complexity pruning algorithm

- Модыг бүрэн ургуулсны дараа хялбаршуулах замаар хэт тохируулахаас сэргийлэх арга

- **Тайралт**

- **Модны төвөгтэй байдал болон алдааны түвшинг** тооцдог.
 - Сургалтын өгөгдлийн буруу ангилагдсан бичлэгүүдийн хувь
 - Модны навчны тоогоор илэрхийлэгддэг модны нарийн төвөгтэй байдлыг хэмжинэ.
 - Мод илүү их навчтай байх тусам илүү төвөгтэй гэж үздэг.
 - $\alpha \rightarrow$ төвөгтэй байдлыг шийтгэх коэффициент

$$R_{\alpha}(T) = R(T) + \alpha |T|$$

Модыг тайрах

Жишээ: Post-pruning

Class = Yes	20
Class = No	10
Error = 8/30	


Misclassification rate (subtree) = $9/30$

$$R(\text{subtree}) = 9/30 + 0.01 \times 4 = 0.34$$


Misclassification rate (pruned) = $8/30$

$$R(\text{pruned}) = 8/30 + 0.01 \times 1 = 0.27$$

PRUNE!



Модыг тайрах



Модыг тайрах

- **ID3** → pruning байхгүй
 - ID3 үргэлж өгөгдлийг бүрэн ангилах хүртэл мод ургуулдаг → үүний сул тал нь **overfitting** их үүсдэг.
 - Жижиг өгөгдлийн туршилтад зориулж анх санал болгогдсон
- Pruning ойлголтыг C4.5 болон дараагийн CART зэрэг алгоритмуудад хөгжүүлсэн
 - **C4.5** → Error-based post-pruning (Алдаанд суурилсан тайрах арга)
 - *Статистик аргаар* алдааны түвшинг тооцоолж, сургалтын өгөгдөл дээр тулгуурлан тайрах эсэхээ шийддэг
 - **CART** → Cost-complexity pruning (Зардал-төвөгтэй байдлын тайралт)
 - Сургалтын алдаа болон модны төвөгтэй байдлын хослолд суурилдаг
 - Баталгаажуулалтын багц эсвэл хөндлөн баталгаажуулалтын аргаар

БАЯРЛАЛАА

Data mining and machine learning

