

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга


- Кластерийн шинжилгээ (Cluster Analysis)

Кластерийн шинжилгээ (Cluster analysis)

- Өгөгдсөн объектуудын багцыг бүлэгт байгаа объектууд нь өөр хоорондоо төстэй (эсвэл холбоотой), бусад бүлгийн объектуудаас ялгаатай (эсвэл хамааралгүй) байхаар бүлэгт байрлуулах.
- Ижил төстэй болон ялгаатай байдал
 - Объектуудыг дүрсэлсэн шинж чанарын утгууд дээр үндэслэн үнэлэх
 - Ихэвчлэн зайн хэмжүүрийг ашиглана.

Кластер доторх
зайг багасгасан

Кластер
хоорондын зай
хамгийн их байна





Кластерийн үндсэн аргууд



- Кластерийн олон аргууд байдаг.
 - Эдгээрийг ангилах нь төвөгтэй байдаг.
 - Зарим кластерын алгоритмууд нь хэд хэдэн кластерийн аргын санааг нэгтгэдэг тул ямар нэг ангилалд ангилах нь заримдаа хэцүү байдаг.
- Ерөнхийдөө гол суурь ангиллын аргуудыг дараах категориудад ангилж болно.
 - **Partitioning methods**
 - Эдгээр аргууд нь өгөгдлийн багцыг давхардалгүй кластерт хуваадаг.
 - **Hierarchical methods**
 - Кластеруудын шатлалыг илэрхийлсэн мод шиг бүтэц (дендрограм) үүсгэдэг.
 - **Density-based methods**
 - Эдгээр аргууд нь өгөгдлийн цэгүүдийн нягтрал дээр үндэслэн кластеруудыг тодорхойлдог.
 - **Grid-based methods**
 - Өгөгдлийн орон зайг хязгаарлагдмал тооны нүд эсвэл торны хуваалтуудад хуваах кластерын аргууд.

Хуваах аргууд (Partitioning Methods)

Unnested: Өгөгдлийн объектуудыг давхацдаггүй дэд бүлэгт (кластер) хуваах



Original Points



A Partitional Clustering

Хуваах аргууд (Partitioning Methods)







- Хамгийн энгийн, хамгийн үндсэн хувилбаруудын нэг.
 - Хэрэглэгчийн тодорхойлсон тооны кластеруудыг (k) олохыг оролддог.
- Хамгийн түгээмэл хэрэглэгддэг хуваалтын аргууд
 - *k-means*
 - *k-medoids*

K-means objective function

- Хуваалтын чанарыг үнэлэхэд *зорилтот функцийг* ашигладаг.
 - C_i кластерийн чанарыг кластер доторх өөрчлөлтөөр (хазайлтаар) хэмжиж болно.
- **Objective function:** *Sum of Squared Error (SSE)*
 - $dist()$ – 2 цэгийн хоорондох Евклидийн зай
 - C_i кластер, c_i – төвийн цэг
 - p – объект/цэг, k - кластерууд

$$E = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

K-means Clustering



K-means Clustering – Дэлгэрэнгүй

- Энгийн давтагдах алгоритм.

Анхны төвийн цэгүүдийг санамсаргүй сонго;

Давтах

{ Хамгийн ойрын төвийн цэгт цэгүүдийг хуваарилах;


Кластерийн төвийн цэгүүдийг дахин тооцоолох

}


Төвийн цэгүүдийг өөрчлөгдөхгүй болох хүртэл.

- Төвийн цэг нь (ихэвчлэн) кластер дахь цэгүүдийн дундаж (*mean*) юм.
- Эхний цөөн хэдэн давталтад ихэнх нийлэмж (*convergence*) тохиолдоно.

Анхны төвийн цэгийн санамсаргүй сонголт



Анхны төвийн цэгийн санамсаргүй сонголт



АНХНЫ ТӨВИЙН ЦЭГҮҮДИЙН АСУУДЛЫН ШИЙДЭЛ

- **Олон удаа ажиллуулах** (*ялгаатай анхны төвийн цэгүүдтэйгээр*)
 - Хамгийн бага *SSE*-тэй кластеруудын багцыг сонгох
 - Туслах боловч магадлал бага
- **Зарим стратегийг ашиглах** (*Анхны төвийн цэгүүдийг сонгоход*)
 - *K-means++* нь энэ сонголтыг хийх найдвартай арга
 - *Hierarchical clustering* ашиглах
- ***Bisecting K-means***
 - Эхлэх асуудалд тийм ч өртөмтгий биш
 - *K-means* алгоритмын өөр хувилбар

K-means++

- Анхны төвийн цэгүүдийг сонгосны дараа *k-means* алгоритмыг эхлүүлэх
- Тооцооллын хувьд өртөг өндөр ч, дараагийн алхам болох *k-means* алгоритм нь илүү хурдан нийлэгждэг.

Одоо байгаа центройдтой хамгийн ойрын зайг олно


$$D(x_i) = \min_j \text{EuclideanDistance}(x_i, C_j)$$

Зайг ашиглан магадлалыг гаргах - зай хол цэг сонгогдох магадлал өндөр, ойр цэг багатай





$$P(x_i) = \frac{D(x_i)^2}{\sum_k D(x_k)^2}$$

Санамсаргүй сонголт

- Магадлалын тархалтаас санамсаргүйгээр нэг цэгийг сонгоно.
- Хол зайтай цэг сонгогдох магадлал өндөр



Bisecting K-means



[C,D,E,F]

K-means Clustering

- *k-means* арга нь объектуудын дундаж утга тодорхойлогдох үед л зөвхөн хэрэглэгдэх боломжтой.
- *k-modes* нь *k-means* аргын нэг хувилбар
 - Дундаж утгыг (*mean*) хамгийн их давтагдсан утгаар (*mode*) солих замаар нэрлэсэн өгөгдлийг бүлэглэж, *k-means* аргыг өргөжүүлдэг.
- *k-prototype*
 - Тоон болон нэрлэсэн утгуудтай (*mixed*) өгөгдөл дээр кластер үүсгэхэд *k-means* болон *k-modes* аргууд нь нэгтгэгдэж болно.

K-prototype

- Euclidean, Manhattan distance → numerical data
- matching_distance → categorical data.
- Objective function

$$J = \sum \text{distance}(x_i, z_j) + \gamma * \sum \text{dissimilarity}(x_i, c_k)$$

- distance(xi, zj) - Euclidean distance for numerical data
- dissimilarity(xi, ck) - dissimilarity measure for categorical data
- γ - категориаль өгөгдлийн жин

Clustering Algorithm	Used in (Data types)
K-means	Numerical
K-modes	Categorical
K-prototype (K-means + K-modes)	Mixed (Numerical + Categorical)

K-means Clustering

- *Сул тал*
 - Кластерийн тоо болох *k*-н утгыг тодорхойлох шаардлагатай
 - Өөр өөр хэмжээтэй (*size*) кластеруудыг илрүүлэхэд тохиромжгүй.
 - Өөр өөр нягтралтай (*density*) кластеруудыг илрүүлэхэд тохиромжгүй.
 - Гүдгэр биш хэлбэр хэлбэртэй кластеруудыг илрүүлэхэд тохиромжгүй.
 - Шуугиан (*noise*) болон *outlier* утгуудад мэдрэмтгий.
 - Бага хэмжээтэй өгөгдлийн дундаж утганд эдгээр утгуудын нөлөөлөл их.

k-Medoids: A Representative Object-Based Technique

- *K-means* алгоритмын *outlier* утганд хэт мэдрэг байдлыг хэрхэн бууруулах вэ?
 - Дундаж утгыг лавлах утга болгон ашиглахын оронд кластеруудыг **төлөөлөх бодит объектуудыг** сонгох
 - Кластер бүрт нэг **төлөөлөх объект** сонгох
 - Өгөгдлийн багц дахь бодит өгөгдлийн цэг
- p объект бүр болон түүний харгалзах **төлөөлөх объект** хоорондын ялгаатай (*dissimilarities*) байдлын нийлбэрийг багасгах зарчим дээр үндэслэх хуваах арга нь гүйцэтгэгдэнэ.
 - *Absolute-error criterion*:

$$E = \sum_{i=1}^k \sum_{p \in C_i} \text{dist}(p, o_i)$$

k-Medoids: A Representative Object-Based Technique

- **Partitioning Around Medoids (PAM) алгоритм**

1. Өгөгдлийн цэгээс k медоидийг санамсаргүй сонгоно.
2. k кластерийг үүсгэхийн тулд өгөгдлийн цэг бүрийг хамгийн ойрын медоидод хуваарилна.
3. Бүх кластеруудын хувьд өгөгдлийн цэг бүр болон түүний хуваарилагдсан медоид хоорондын нийт ялгааг тооцоолох
4. Бүх кластер дээр, кластер бүрийн медоидыг тухайн кластер доторх бүх өгөгдлийн цэгтэй сольж шалгана.
5. Шинэ тохиргооны хувьд нийт ялгаатай байдлыг тооцоолж, нийт ялгаа нь хамгийн бага байгаа үр дүнг сонгож, шинэ медоидоор сонгоно.
6. Шинэчлэгдсэн медоидууд дээр өгөгдлийг дахин оноож шинэ кластерийг байгуулна.
7. Медоидууд өөрчлөгдөхөө болих хүртэл 2-6 алхмыг давтана.

k-Medoids: A Representative Object-Based Technique

- **k-means, k-medoids** – аль нь сайн бэ?
 - Шуугиан (*noise*), *outlier* хүчин зүйлүүдэд *k-medoids* илүү тэсвэртэй.
 - Гэвч *k-medoids* тооцооллын хувьд илүү өртөг өндөр.
 - 2 арга хоёулаа кластерийн тоог зааж өгөхийг шаарддаг.
 - *k-medoids* арга бага өгөгдөл дээр сайн ажилладаг.

k-Medoids: A Representative Object-Based Technique

- **CLARA (Clustering Large Applications)**

- Энэ нь *PAM* алгоритмын өргөтгөл
- Том өгөгдлийн багцыг боловсруулахад ашигладаг кластерийн алгоритм
- Өгөгдлийн багцаас санамсаргүй байдлаар түүвэрлэж, энэ түүвэрт *PAM* алгоритмыг ашигладаг.
 - Олдсон медоид нь зөвхөн түүвэрт суурилсан байх болно.
- Олдсон медоидыг бүх өгөгдөл дээр үнэлнэ.
 - Бүх n цэгийг хамгийн ойр медоид руу оноож, нийт зардлыг бодно.
- Үүнийг хэд хэд давтаж олон кластеруудын багцыг олж авах ба хамгийн сайныг сонгох.

k-Medoids: A Representative Object-Based Technique

- **CLARA (Clustering Large Applications)**

- Хамгийн сайн байж болох медоид нь түүвэрлэлтэд сонгогдоогүй бол хамгийн сайн кластерийг олж чадахгүй.
- *CLARA*-н чанарыг хэрхэн сайжруулах вэ?

- **CLARANS**

- **Clustering Large Applications based upon RANdomized Search**
- Өгөгдлийн багцаас k объектуудыг медоидод зориулж *самамсаргүйгээр* сонгоно.
- *Санамсаргүй* байдлаар одоогийн идэвхтэй медоид x -г одоогийн медоид биш y объектыг сонгож, тэдгээрийг солих
- *Absolute-error* шалгуурыг сайжруулвал x, y –г хооронд нь солих
- Санамсаргүй хайлтыг L удаа хийдэг.
- Энэ процесс олон удаа давтагдах

БАЯРЛАЛАА

Data mining and machine learning

