

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Өгөгдлийн урьдчилсан боловсруулалт (Data preprocessing)
 - Үргэлжлэл

3. Өгөгдлийг багасгах

- **3.1 Хэмжээст байдлыг багасгах**

- *Attribute subset selection*


- Өгөгдлийн багц нь олон зуун атрибут агуулж болох боловч ихэнх нь олборлолтонд хамааралгүй эсвэл шаардлагагүй байж болно.
 - **Илүүдэл шинж чанарууд**
 - Илүүдэл шинж чанарууд нь нэг буюу хэд хэдэн шинж чанарт агуулагдах мэдээллийн ихэнхийг эсвэл бүгдийг нь давхардуулан агуулсан байдаг
 - **Үл хамаарах шинж чанарууд**
 - Өгөгдөл олборлох ажилд хэрэгтэй мэдээлэл агуулаагүй

3. Өгөгдлийг багасгах

- 3.1 Хэмжээст байдлыг багасгах

- *Attribute subset selection*

- Атрибутын дэд олонлогийн сонголт
 - Хамааралгүй эсвэл илүүдэл шинж чанаруудыг арилгах замаар өгөгдлийн багцын хэмжээг бууруулдаг.



3. Өгөгдлийг багасгах

- **Filter method**

- Статистик тест ашиглан шинж чанаруудын оноонд тулгуурлан шинж чанаруудыг хасах арга
- Энэ оноо нь тэдгээрийн зорилтот гаралттай хэр зэрэг хамааралтай болохыг харуулдаг.
- Шинж чанар бүрийг дараах статистик тестийн үр дүнгээр үнэлдэг.
 - *Information gain, Fisher's score, Chi-square, Pearson correlation*
- Шинж чанаруудыг оноогоор нь эрэмбэлж, бага оноотойг хасна.
- Тооцооллын хувьд хямд бөгөөд хурдан байдаг.
- Мөн өндөр хэмжээст өгөгдөлтэй ажиллахад тохиромжтой.

3. Өгөгдлийг багасгах

- **Wrapper method**

- Машин сургалтын алгоритмын гүйцэтгэлд үзүүлэх нөлөөлөл дээр үндэслэн шинж чанаруудыг сонгодог.
- Ялгаатай шинж чанарын дэд багцуудыг үүсгэх
- Машин сургалтын алгоритмыг эдгээр шинж чанаруудыг агуулсан өгөгдөл дээр сургах
- Загварыг үнэлэх, хамгийн сайн үр дүн өгч байгаа шинж чанаруудыг сонгох

3. Өгөгдлийг багасгах

- **Embedded methods**

- Шинж чанаруудыг автоматаар сонгохын тулд машин сургалтын загваруудыг ашигладаг.
- Энэ техник нь сургалтын явцад хамгийн сайн шинж чанарууд сонгогдох болно.
- Загвар өөрөө сургалтын явцад ямар шинж чанар чухал болохыг олж мэддэг.

3. Өгөгдлийг багасгах

• 3.1 Хэмжээст байдлыг багасгах

• Attribute construction (Attribute creation)

- Зарим тохиолдолд бусад атрибут дээр үндэслэн шинэ атрибут үүсгэдэг.
- Энэ нь өндөр хэмжээст өгөгдлийн бүтцийн нарийвчлал, ойлголтыг сайжруулахад тусалдаг.
 - Жнь: *height, width* $\rightarrow$ *area*
- Атрибутуудыг нэгтгэж, шинэ атрибут үүсгэх нь атрибутуудын хоорондын хамаарлын талаар дутуу мэдээллийг арилгаж, мэдлэгийг илрүүлэхэд хэрэгтэй.

3. Өгөгдлийг багасгах

3.2 Тоо хэмжээг багасгах



- Өгөгдлийн дүрслэлийн өөр, жижиг хэлбэрийг сонгох замаар өгөгдлийн хэмжээг багасгах
 - Өгөгдлийн багасгасан дүрслэлийг хадгалах
 - *Histograms, sampling,*

3. Өгөгдлийг багасгах

3.2 Тоо хэмжээг багасгах

- *Histograms*

- *A* атрибутаг зориулж гистограм нь *A* өгөгдлийн тархалтыг хэсэгчлэн авч үзсэн дэд олонлогт (*buckets or bins*) хуваадаг.
 - *singleton buckets* – зөвхөн нэг атрибутын утга/давтамжийг дүрсэлдэг
 - Ихэвчлэн өгөгдсөн атрибутын тасралтгүй мужийг илэрхийлдэг.
- **Жишээ:** *AllElectronics* - н түгээмэл зарагддаг бараа бүтээгдэхүүний үнийн жагсаалт (эрэмбэлэгдсэн)
 - 1, 1, 5, 5, 5, 5, 5, 8, 8, 10, 10, 10, 10, 12, 14, 14, 14, 15, 15, 15, 15, 15, 15, 18, 18, 18, 18, 18, 18, 18, 18, 18, 20, 20, 20, 20, 20, 20, 20, 20, 20, 21, 21, 21, 21, 25, 25, 25, 25, 28, 28, 30, 30, 30.
- Өгөгдлийг хувин болгон хувааж, хувин тус бүрийн дунджийг хадгална.



3. Өгөгдлийг багасгах


3.2 Тоо хэмжээг багасгах

- **Sampling**

- Түүврийн төрөл

- Энгийн санамсаргүй түүвэр / *Simple random sampling*

- Аливаа нэг зүйлийг сонгох магадлал ижил байна.
- Орлуулах замаар дээж авах (Simple random sample with replacement - SRSWR)
 - Объектууд түүвэрт сонгогдсон ч тэднийг өгөгдлийн бүтэн багцаас устгадаггүй.
 - Энэ үед объект нэгээс олон удаа сонгогдож болно.
 - Сонгогдох боломж тэгш, түүврийн хэмжээтэй харьцуулахад популяци их, орлуулах болон орлуулахгүйгээр түүвэрлэлтийн ялгаа бага байх үед
- Орлуулахгүйгээр дээж авах (Simple random sample without replacement - SRSWOR)
 - Тухайн объект бүрийг сонгохдоо түүнийг өгөгдлийн бүтэн багцаас устгана.
 - Сонгогдох боломж тэгш, түүвэрт давхардсан сонголт хийхгүй байхыг хүсэх үед



3. Өгөгдлийг багасгах


3.2 Тоо хэмжээг багасгах

- Sampling

- Түүврийн төрөл

- *Cluster*

- Нийт өгөгдлийг тусдаа бүлэг буюу кластер болгон хуваах ба дараа нь эдгээр кластеруудаас санамсаргүй түүврийг сонгоно.



3. Өгөгдлийг багасгах


3.2 Тоо хэмжээг багасгах

- Sampling

- Түүврийн төрөл

- Үелсэн түүвэрлэлт / *Stratified sampling*

- Өгөгдлийг тодорхой шинж чанарт тулгуурлан хэд хэдэн хэсэгт хуваагаад, дараа нь хуваасан хэсэг бүрээс санамсаргүй түүврийг авдаг.




3. Өгөгдлийг багасгах

3.2 Тоо хэмжээг багасгах

- **Aggregation**

- 2 эсвэл түүнээс олон атрибутуудыг (эсвэл объектуудыг) нэг атрибут руу (эсвэл объект) нэгтгэх
- Хэмжээсийг (*scale*) өөрчлөх
 - *Cities* → *regions, states, countries*
 - *Days* → *weeks, months, years*
 - (365 days → 12 months)
- *AllElectronics*-ийн 2008-2010 оны улирлын борлуулалт
- Улирлын борлуулалтаас илүү жилийн борлуулалтыг сонирхож байна.



Aggregated Data

4. Өгөгдөл хувиргах


- Өгөгдлийг олборлоход тохиромжтой хэлбэрт шилжүүлэх
- **Өгөгдөл хувиргах стратеги**
 - *Smoothing*
 - Өгөгдлөөс шуугиан арилгах
 - *Attribute construction*
 - Олборлолтонд туслахын тулд өгөгдсөн шинж чанаруудаас шинэ шинж чанаруудыг бүтээх
 - *Aggregation*
 - Өгөгдлийг нэгтгэх
 - *Normalization*
 - Атрибутын өгөгдлийг $[-1.0, 1.0]$, $[0.0-1.0]$ гэх мэт жижиг мужид багтахаар масштаблах.

4. Өгөгдөл хувиргах

- Өгөгдөл хувиргах стратеги

- *Discretization*

- Тоон шинж чанарын түүхий утгыг (жишээ нь, нас) **интервалын шошго** (жишээ нь, 0-10, 11-20 гэх мэт) эсвэл **концепцийн шошго** (жишээ нь, залуучууд, насанд хүрэгчид, ахмад настууд) -аар сольж ялгах.



- Нэрлэсэн өгөгдөлд илүү өндөр түвшний шаталсан **концепцийн шошго** үүсгэх
 - *Street* → *city, country*

4. Өгөгдөл хувиргах

- **Өгөгдөл хувиргах стратеги – Normalization**

- Хэрэглэсэн хэмжилтийн нэгж нь өгөгдлийн шинжилгээнд нөлөөлж болно.
 - *Height: meter → inch*
 - *Weight: kilograms → pound*
 - Шинж чанарыг жижиг нэгжээр илэрхийлэх нь тухайн шинж чанарын хувьд илүү том хүрээг бий болгодог → жин эсвэл нөлөө ихэснэ.
- Хэмжилтийн нэгжийн сонголтоос хамааралтай байхаас зайлсхийхийн тулд өгөгдлийг нормалчлах эсвэл стандартчилах шаардлагатай.
- Өгөгдлийг хэвийн болгох нь бүх шинж чанаруудад ижил жин өгөхийг оролддог.

4. Өгөгдөл хувиргах

- **Өгөгдөл хувиргах стратеги – Normalization**

- Өгөгдлийг хэвийн болгох олон арга байдаг.

- *min-max normalization*
- *z-score normalization*
- *normalization by decimal scaling.*

- n ажиглалтын утга бүхий A тоон атрибут $v_1, v_2, \dots, v_n$

4. Өгөгдөл хувиргах

- Өгөгдөл хувиргах стратеги – Normalization (**min-max normalization**)

$$v'_i = \frac{v_i - \min_A}{\max_A - \min_A} (\text{new_max}_A - \text{new_min}_A) + \text{new_min}_A$$

- **Жишээ:**

- Орлогын дээд болон доод утга: \$12000, \$98000
- Буулгах муж: [0.0, 1.0]
- Нормалчлах утга: \$73,600

$$\frac{73,600 - 12,000}{98,000 - 12,000} (1.0 - 0) + 0 = 0.716$$

4. Өгөгдөл хувиргах

- Өгөгдөл хувиргах стратеги – Normalization (**Z-score normalization**)
 - A атрибутын дундаж болон стандарт хазайлт дээр үндэслэн нормалчилдаг.
 - *min-max normalization* ашиглахад *outlier* давамгайлах үед

$$v'_i = \frac{v_i - \bar{A}}{\sigma_A}$$

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 = \left(\frac{1}{N} \sum_{i=1}^N x_i^2 \right) - \bar{x}^2$$

- Жишээ:
 - Орлого атрибутын дундаж болон стандарт хазайлт: \$54000, \$16000
 - Нормалчлах утга: \$73,600
- Дундаж үнэмлэхүй хазайлт

$$\frac{73,600 - 54,000}{16,000} = 1.225$$

$$s_A = \frac{1}{n} (|v_1 - \bar{A}| + |v_2 - \bar{A}| + \dots + |v_n - \bar{A}|)$$

$$v'_i = \frac{v_i - \bar{A}}{s_A}$$

4. Өгөгдөл хувиргах

- Өгөгдөл хувиргах стратеги – Normalization (**Normalization by decimal scaling**)
 - A атрибутын хамгийн их абсолют утгаас хамаарна.

$$v'_i = \frac{v_i}{10^j}$$

$$\max(|v'_i|) < 1$$

- **Жишээ:**

- A атрибутын муж: $[-986, 917]$
- A атрибутын хамгийн их абсолют утга: 986
- Бүх утгыг 1000-д хуваана ($j = 3$)

$$-986 \rightarrow -0.986$$

$$917 \rightarrow 0.917$$

4. Өгөгдөл хувиргах

- **Өгөгдөл хувиргах стратеги – Discretization**

- Тасралтгүй атрибутыг (*continuous*) категорийн атрибут (*categorical attribute*) болгон хувиргах үйл явц юм.
- Ангилал (*classification*) эсвэл холбоо хамаарлын (*association*) шинжилгээнд ашигладаг атрибутуудад ихэвчлэн ашигладаг.
- Тасралтгүй атрибутыг категорийн атрибут болгон хувиргах
 - Хэдэн категоритой болохыг шийдэх
 - Эдгээр ангилалд тасралтгүй шинж чанарын утгыг хэрхэн буулгахыг тодорхойлох.
 - Хэрэв категорийн атрибут нь олон тооны утгатай (категори) эсвэл зарим утга нь ховор тохиолддог бол зарим утгыг нэгтгэх замаар категорийн тоог багасгах нь өгөгдөл олборлох тодорхой ажлуудад ашигтай байж болно.


- **Binning**

4. Өгөгдөл хувиргах

- **Өгөгдөл хувиргах стратеги – Нэрлэсэн өгөгдлийн ойлголтын шатлал үүсгэх**
 - Нэрлэсэн өгөгдөл нь олон тооны өвөрмөц утгатай байж болох бөгөөд энэ нь өгөгдөлд дүн шинжилгээ хийх, хадгалахад хүндрэл учруулдаг.
 - Хэрэглэгчид эсвэл домэйны мэргэжилтнүүд өгөгдлийн багц доторх **атрибутуудын шатлал** эсвэл дарааллыг тодорхой тодорхойлдог.
 - *street < city < state < country*
 - **Утгуудыг** шаталсан ангилал руу хуваах
 - *{Urbana, Champaign, Chicago} < Illinois*
 - Зөвхөн **хэсэгчилсэн багц шинж чанаруудын** тодорхойлолт
 - *street < city (not others)*
 - **Ялгаатай утгуудын тоонд** дүн шинжилгээ хийх замаар шатлалыг (эсвэл атрибутын түвшинг) автоматаар үүсгэх
 - *{street, city, state, country}*

4. Өгөгдөл хувиргах

- Өгөгдөл хувиргах стратеги – Нэрлэсэн өгөгдлийн ойлголтын шатлал үүсгэх



БАЯРЛАЛАА

Data mining and machine learning

