

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Байесын ангилагч / Bayes Classification
- Дүрэмд суурилсан ангилагч / Rule-Based Classification

Байесын теорем

- X - өгөгдлийн бичлэг гэж үзье.
 - Байесын нэр томъёонд, X -г "нотлох баримт" гэж үздэг.
 - Энэ нь n атрибутын багц дээр хийсэн хэмжилтээр тодорхойлогддог.
- H - өгөгдлийн бичлэг X нь C ангилалд хамаарах таамаглал гэж үзье.
- Ангиллын асуудлын хувьд:
 - $P(H|X)$ магадлал
 - “*Нотлох баримт*” эсвэл ажиглагдсан X өгөгдөл өгөгдөхөд H таамаглал байх магадлалыг тодорхойлохыг хүсэж байна.
 - Ө.х X шинж чанарын тодорхойлолт өгөгдөхөд, X нь C ангилалд байх магадлал

Байесын теорем

- $P(H)$ - *prior probability*, приор буюу H -н өмнөх магадлал
 - Аливаа өгөгдөл, нотлох баримтыг харгалзан үзэхээс өмнө үйл явдал эсвэл таамаглалд хуваарилагдсан магадлал
- $P(H|X)$ - *posterior probability*, X дээр нөхцөлтэй H -ийн постериор буюу нөхцөлт магадлал
 - Шинэ нотлох баримт, өгөгдлийг харгалзан үзсэний дараа ямар нэгэн үйл явдал, таамаглал гарах магадлал
- $P(H|X)$ магадлал нь $P(H)$ магадлалаас илүү их мэдээлэлд (хэрэглэгчийн мэдээлэл) суурилдаг бөгөөд $P(H)$ нь X -с хамааралгүй.

Байесын теорем

- $P(X|H)$ - *likelihood*, H үйл явдал болсон үед X ажиглагдах нь хэр үндэслэлтэй вэ?
Ажиглалтын мэдээлэл
- $P(X)$ - *evidence*, Нотолгоо, бүх нөхцөлд энэ мэдээлэл ирэх боломж
- Дээр дурьдсан магадлалуудыг хэрхэн тооцох вэ?
 - $P(H)$, $P(X|H)$, $P(X)$ – эдгээр нь өгөгдсөн өгөгдлөөс тооцоологдож болно.
- **Байесын теорем** нь $P(H)$, $P(X|H)$, $P(X)$ -ээс **$P(H|X)$** -ийг тооцоолох аргыг өгдгөөрөө ач холбогдолтой.

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)}$$

$$P(H | X_1 X_2 \dots X_n) = \frac{P(X_1 X_2 \dots X_d | H) P(H)}{P(X_1 X_2 \dots X_d)}$$

Байесын ангилагч

1 • D – сургалтын бичлэгүүдийн багц

• Бичлэг бүр n атрибуттай $X = (x_1, x_2, \dots, x_n)$

• n атрибут $A_1, A_2, \dots, A_n$

• m ангилалтай $C_1, C_2, \dots, C_m$

2 • X бичлэг өгөгдөхөд, X дээр нөхцөлтэй *хамгийн өндөр* постериор магадлал бүхий ангилал руу X –г хамааруулна.

$$P(C_i|X) > P(C_j|X) \quad \text{for } 1 \leq j \leq m, j \neq i$$

• Байесын теорем

$$P(C_i|X) = \frac{P(X|C_i)P(C_i)}{P(X)}$$

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)}$$

Байесын ангилагч

- Байесын теорем

$$P(C_i|X) = \frac{P(X|C_i)P(C_i)}{P(X)}$$

- 3
- $P(X)$ нь бүх ангиллын хувьд тогтмол

- $P(X|C_i)P(C_i)$ – *maximize*
- $P(C_i)$ - мэдэгдэхгүй бол ангиллууд ижил магадлалтай

$$P(C_1) = P(C_2) = \dots = P(C_m) \rightarrow P(X|C_i) - \textit{maximize}$$

- Ангиллын приор магадлал

$$P(C_i) = |C_{i,D}|/|D|$$

$|C_{i,D}|$ - D өгөгдлийн багц дахь C_i ангиллын бичлэгийн тоо

Байесын ангилагч

- Байесын теорем

$$P(C_i|X) = \frac{P(X|C_i)P(C_i)}{P(X)}$$

4

- Олон атрибуттай өгөгдлийн багц өгөгдөхөд $P(X|C_i)$ -г тооцоолоход тооцооллын хувьд зардал ихтэй болно.
- Тооцооллыг багасгахын тулд **class-conditional independence** энгийн таамаглалыг дэвшүүлсэн.
 - Тухайн бичлэгийн ангилал өгөгдөхөд, атрибутуудын утгууд нэг нь нөгөөгөөсөө нөхцөлт хамааралгүй.
 - Шинж чанаруудын хооронд хамаарал байхгүй.

$$P(X|C_i) = \prod_{k=1}^n P(x_k|C_i) = P(x_1|C_i) \times P(x_2|C_i) \times \cdots \times P(x_n|C_i)$$

Байесын ангилагч

- Атрибут тус бүрийн хувьд атрибут нь **категори** эсвэл **тасралтгүй** утгатай эсэхийг шалгана.
 - A_k категор утгатай атрибут:
 - $P(x_k|C_i)$ нь D өгөгдлийн багц дахь A_k атрибут дахь x_k утгатай C_i ангилалд байгаа бичлэгүүдийн тоог D өгөгдлийн багц дахь C_i ангилалд байгаа бичлэгүүдийн тоонд хувааж олно.
 - A_k үргэлжилсэн утгатай атрибут:
 - Үргэлжилсэн утгатай атрибутыг ихэвчлэн μ дундаж утга болон σ стандарт хазайлт бүхий Гауссын тархалттай гэж үздэг.

$$g(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



$$P(x_k|C_i) = g(x_k, \mu_{C_i}, \sigma_{C_i})$$

Байесын ангилагч

5

- X бичлэг ямар ангилалд байгааг таамаглахын тулд
 - C_i ангилал бүр дээр $P(X|C_i)P(C_i)$ тооцож, хамгийн өндөр магадлалтай ангилалд хамруулна.

$$P(X|C_i)P(C_i) > P(X|C_j)P(C_j) \quad \text{for } 1 \leq j \leq m, j \neq i.$$

Байесын ангилагч

- Жишээ

- Дараах бичлэгийн хувьд ангиллыг олъё.

$X = (age = youth, income = medium, student = yes, credit_rating = fair)$

- Maximize

$$P(X|C_i)P(C_i), \text{ for } i = 1, 2.$$

- Ангилал бүрийн приор магадлал

$$P(buys_computer = yes) = 9/14 = 0.643$$

$$P(buys_computer = no) = 5/14 = 0.357$$

$$P(X|C_i)P(C_i), \text{ for } i = 1, 2.$$

<i>RID</i>	<i>age</i>	<i>income</i>	<i>student</i>	<i>credit_rating</i>	<i>Class: buys_computer</i>
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

Байесын ангилагч

- Жишээ

- Дараах бичлэгийн хувьд ангиллыг олъё.

$X = (age = youth, income = medium, student = yes, credit_rating = fair)$

- Атрибут бүрийн хувьд

$$P(age = youth \mid buys_computer = yes) = 2/9 = 0.222$$

$$P(age = youth \mid buys_computer = no) = 3/5 = 0.600$$

$$P(income = medium \mid buys_computer = yes) = 4/9 = 0.444$$

$$P(income = medium \mid buys_computer = no) = 2/5 = 0.400$$

$$P(student = yes \mid buys_computer = yes) = 6/9 = 0.667$$

$$P(student = yes \mid buys_computer = no) = 1/5 = 0.200$$

$$P(credit_rating = fair \mid buys_computer = yes) = 6/9 = 0.667$$

$$P(credit_rating = fair \mid buys_computer = no) = 2/5 = 0.400$$

<i>RID</i>	<i>age</i>	<i>income</i>	<i>student</i>	<i>credit_rating</i>	<i>Class: buys_computer</i>
1	youth	high	no	fair	no
2	youth	high	no	excellent	no
3	middle_aged	high	no	fair	yes
4	senior	medium	no	fair	yes
5	senior	low	yes	fair	yes
6	senior	low	yes	excellent	no
7	middle_aged	low	yes	excellent	yes
8	youth	medium	no	fair	no
9	youth	low	yes	fair	yes
10	senior	medium	yes	fair	yes
11	youth	medium	yes	excellent	yes
12	middle_aged	medium	no	excellent	yes
13	middle_aged	high	yes	fair	yes
14	senior	medium	no	excellent	no

$$P(X|C_i)P(C_i), \text{ for } i = 1, 2.$$

Байесын ангилагч

$$\begin{aligned}P(X|buys_computer = yes) &= P(age = youth | buys_computer = yes) \\&\quad \times P(income = medium | buys_computer = yes) \\&\quad \times P(student = yes | buys_computer = yes) \\&\quad \times P(credit_rating = fair | buys_computer = yes) \\&= 0.222 \times 0.444 \times 0.667 \times 0.667 = 0.044.\end{aligned}$$

$$P(X|buys_computer = no) = 0.600 \times 0.400 \times 0.200 \times 0.400 = 0.019.$$

$$P(X|buys_computer = yes)P(buys_computer = yes) = 0.044 \times 0.643 = 0.028$$

$$P(X|buys_computer = no)P(buys_computer = no) = 0.019 \times 0.357 = 0.007$$

Байесын ангилагч нь X бичлэгийн хувьд **buys_computer = YES** гэж таамаглана.

$$X = (age = youth, income = medium, student = yes, credit_rating = fair)$$

Байесын ангилагч

- Хэрэв магадлалын утга 0 гарвал яах вэ?

- Ангиалал бүрийн хувьд $P(X|C_i)$ тооцоолно.

- $P(X|C_i)P(C_i)$ - maximize болгохын тулд

- Жишээ: 2 ангилалтай, $buys_computer = yes$, $buys_computer = no$

- X : student = yes $P(X|buys_computer = yes)$ $P(X|buys_computer = no)$

$$P(student = yes|buys_computer = no) = 0?$$

$$P(x_k|C_i)? \rightarrow 0$$

- Бусад постериор магадлалын нөлөөг хүчингүй болгодог.

$$\begin{aligned} P(X|buys_computer = yes) &= P(age = youth | buys_computer = yes) \\ &\times P(income = medium | buys_computer = yes) \\ &\times P(student = yes | buys_computer = yes) \\ &\times P(credit_rating = fair | buys_computer = yes) \\ &= 0.222 \times 0.444 \times 0.667 \times 0.667 = 0.044. \end{aligned}$$

Байесын ангилагч

- **Хэрэв магадлалын утга 0 гарвал яах вэ?**
 - Сургалтын өгөгдлийн багц D нь маш том гэвэл шаардлагатай тоо бүрт нэгийг нэмбэл тооцоолсон магадлалын утганд өчүүхэн төдий өөрчлөлт гарна.
 - Гэвч магадлалын утгыг тэг болохоос зайлсхийх боломжтой.
 - Магадлалыг тооцоолох энэхүү техникийг Францын математикч Пьер Лапласын нэрээр нэрлэсэн.
 - *Laplacian correction* эсвэл *Laplace estimator*

Байесын ангилагч

- **Жишээ (Laplacian correction)**

- $D = 1000$ бичлэг
- $income = \text{low}$ (0); $income = \text{medium}$ (990); $income = \text{high}$ (10)
- Лапласын залруулга ашиглахгүй
0; 0.990 (990/1000); 0.010 (10/1000);
- Лапласын залруулга ашиглах

$$\frac{1}{1003} = 0.001, \frac{991}{1003} = 0.988, \text{ and } \frac{11}{1003} = 0.011$$

Дүрэмд суурилсан ангилагч

- Дүрэмд суурилсан ангилагч нь ангилалд зориулж *IF-THEN* дүрмийн багцыг ашиглан ангилдаг.
- Сурсан загвар нь *IF-THEN* дүрмийн багцаар дүрслэгддэг.

IF condition THEN conclusion.

- Жишээ. Дүрэм *R1*

R1: IF age = youth AND student = yes THEN buys_computer = yes.

R1: (age = youth) $\wedge$ (student = yes) $\Rightarrow$ (buys_computer = yes).

- **IF – Дүрмийн урьдчилсан нөхцөл** (*rule antecedent* эсвэл *precondition*)
 - Логик холбоос хэрэглэн хэд хэдэн атрибутын тестээс бүрдэж болно.
- **THEN – Дүрмийн үр дагавар** (*rule consequent*)
 - Ангилал (*class*)

Дүрэмд суурилсан ангилагч

- Хэрэв тухайн бичлэгийн атрибутууд нь дүрмийн урьдчилсан нөхцөлийг хангаж байвал
 - Дүрмийн **урьдчилсан нөхцөл** хангагдсан
 - Энэ дүрэм нь бичлэгийг **хамарч** байна гэж хэлнэ.

R1: (Give Birth = no) $\wedge$ (Can Fly = yes) $\rightarrow$ **Birds**

R2: (Give Birth = no) $\wedge$ (Live in Water = yes) $\rightarrow$ **Fishes**

R3: (Give Birth = yes) $\wedge$ (Blood Type = warm) $\rightarrow$ **Mammals**

R4: (Give Birth = no) $\wedge$ (Can Fly = no) $\rightarrow$ **Reptiles**

R5: (Live in Water = sometimes) $\rightarrow$ **Amphibians**

Name	Blood Type	Give Birth	Can Fly	Live in Water	Class
hawk	warm	no	yes	no	?
grizzly bear	warm	yes	no	no	?

R1 дүрэм нь шонхор (hawk) хамарна $\Rightarrow$ **Bird**

R3 дүрэм нь саарал баавгай (grizzly bear) хамарна $\Rightarrow$ **Mammal**

Дүрэмд суурилсан ангилагч

$R1: (age = youth) \wedge (student = yes) \Rightarrow (buys_computer = yes).$

- R дүрмийг *хамрах хүрээ* болон *нарийвчлалаар* нь үнэлж болно.

$$coverage(R) = \frac{n_{covers}}{|D|}$$

$$accuracy(R) = \frac{n_{correct}}{n_{covers}}$$

- n_{covers} - R дүрмээр хамарсан бичлэгийн тоо
 - Дүрэмд хамрагдсан бичлэгийн хувь
- $n_{correct}$ - R дүрмээр зөв ангилагдсан бичлэгийн тоо
 - Дүрмээр зөн ангилсан бичлэгийн хувь
- $|D|$ - D өгөгдлийн багц дахь бичлэгийн тоо.

Дүрэмд суурилсан ангилагч

R1: (Give Birth = no) $\wedge$ (Can Fly = yes) $\rightarrow$ Birds

R2: (Give Birth = no) $\wedge$ (Live in Water = yes) $\rightarrow$ Fishes

R3: (Give Birth = yes) $\wedge$ (Blood Type = warm) $\rightarrow$ Mammals

R4: (Give Birth = no) $\wedge$ (Can Fly = no) $\rightarrow$ Reptiles

R5: (Live in Water = sometimes) $\rightarrow$ Amphibians

Name	Blood Type	Give Birth	Can Fly	Live in Water	Class
lemur	warm	yes	no	no	?
turtle	cold	no	no	sometimes	?
dogfish shark	cold	yes	no	yes	?

- **Lemur** нь **R3** дүрмийг идэвхжүүлэх тул энэ нь **Mammals** (хөхтөн амьтан) гэж ангилагдана.
- **Turtle** нь **R4** болон **R5** дүрмүүдийг хоёуланг нь идэвхжүүлнэ.
 - **Reptiles**-Мөлхөгчид, **Amphibians** - Хоёр нутагтан
- **Dogfish shark** эдгээр дүрийн алийг нь ч идэвхжүүлэхгүй.

Дүрмийн багцийн шинж чанар

- **Харилцан үгүйсгэсэн дүрмүүд / Mutually exclusive rules**
 - Нэгэн зэрэг үнэн байж болохгүй дүрмүүд юм.
 - Хэрэв дүрмийн аль нэг нь үнэн бол нөгөө дүрэм нь худал байх ёстой.
 - Бичлэг бүр хамгийн ихдээ нэг дүрмээр тухайн ангилалд хамаарна.
- **Бүхэлд нь хамарсан дүрмүүд /Exhaustive rules**
 - Дүрмүүд нь атрибутуудын утгуудын бүх боломжит үр дүнг хамарсан байна.
 - Бичлэг бүр хамгийн багадаа нэг дүрмээр тухайн ангилалд хамаарна.

Дүрмийн багцийн шинж чанар

- **Дүрмүүд нь харилцан үгүйсгэсэн дүрэм биш бол / Not mutually exclusive**
 - Бичлэг нь нэгээс олон дүрмийг идэвхжүүлж болно.
 - Нэгээс олон дүрэм хангагдсан, тус бүр ялгаатай ангиллыг буцаадаг бол?
 - Шийдэл?
 - Ordered rule set
 - Unordered rule set – use voting schemes
- **Дүрмүүд нь бүхэлд нь хамарсан дүрэм биш бол / Non exhaustive**
 - Бичлэг нь ямар ч дүрмийг идэвхжүүлэхгүй байж болно.
 - Х бичлэгээр ямар ч дүрмийн нөхцөл хангагдаагүй бол?
 - Шийдэл?
 - **Default rule – нөхцөл хоосон, бусад бүх дүрэм хангагдаагүй үед IF () THEN Class = default class**
 - Хамгийн их байгаа ангилал
 - Эсвэл ямар ч дүрэмд хамаараагүй бичлэгүүдийн дийлэнх байгаа ангилал

Дүрэмд суурилсан ангилагч

- **Нэгээс олон дүрэм хангагдсан**
 - Хэмжээгээр эрэмбэлэх (**size ordering scheme**)
 - Дүрмийн урьдчилсан нөхцөлийн хэмжээгээр (**rule antecedent size**) нь идэвхжих дүрмүүд илүү давуу эрхтэй байна.
 - Хамгийн хатуу шаардлага бүхий дүрэмд илүү ач холбогдол өгнө.
 - Ө.х хамгийн олон атрибутын тест бүхий дүрэм
 - Дүрмээр эрэмбэлэх (**rule ordering scheme**)
 - Эрэмбэлэлт нь ангилалд суурилсан эсвэл дүрэмд суурилсан байж болно.
 - **class-based** эсвэл **rule-based**

Дүрэмд суурилсан ангилагч

- Дүрмээр эрэмбэлэх (**rule ordering scheme**)
 - Ангилалд суурилсан эрэмбэлэлт (**class-based ordering**)
 - Ангиллуудын тархалтын дарааллаар эрэмбэлдэг.
 - Эсвэл ангилал бүрт ногдох буруу ангиллын зардлаар тэдгээрийг ангилж болно.
- Дүрэмд суурилсан ангиллын ихэнх систем нь ангилалд суурилсан дүрэм эрэмбэлэх стратегийг ашигладаг.

Class-based Ordering

(Refund=Yes) ==> No

(Refund=No, Marital Status={Single, Divorced},
Taxable Income<80K) ==> No

(Refund=No, Marital Status={Married}) ==> No

(Refund=No, Marital Status={Single, Divorced},
Taxable Income>80K) ==> Yes

Дүрэмд суурилсан ангилагч

- Дүрмээр эрэмбэлэх (**rule ordering scheme**)
 - Дүрэмд суурилсан эрэмбэлэлт (**rule-based ordering**)
 - Дүрмийн зарим **чанарын** хэмжүүрээр - *нарийвчлал, хамрах хүрээ, хэмжээ* (урьдчилсан нөхцөл дэх атрибутын тестийн тоо)
 - Эсвэл тухайн домайны мэргэжилтнүүдийн зөвлөгөөн дээр үндэслэнэ.

Rule-based Ordering

(Refund=Yes) ==> No

(Refund=No, Marital Status={Single,Divorced},
Taxable Income<80K) ==> No

(Refund=No, Marital Status={Single,Divorced},
Taxable Income>80K) ==> Yes

(Refund=No, Marital Status={Married}) ==> No

Дүрэмд суурилсан ангилагчийг байгуулах

- **Шууд арга:**

- Өгөгдлөөс дүрмийг шууд задлах
- Жишээ нь: *RIPPER*, *CN2*

- **Шууд бус арга:**

- Бусад ангиллын загвараас (жишээ нь, шийдвэрийн мод, мэдрэлийн сүлжээ гэх мэт) дүрмийг задлах.
- Жишээ нь: *C4.5rules*

Шууд арга: Sequential Covering Algorithm

Input:


- D , a data set of class-labeled tuples;
- Att_vals , the set of all attributes and their possible values.

Output: A set of IF-THEN rules.


Method:

- (1) $Rule_set = \{\}$; // initial set of rules learned is empty
- (2) **for each** class c **do**
- (3) **repeat**
- (4) $Rule = \mathbf{Learn_One_Rule}(D, Att_vals, c)$;
- (5) remove tuples covered by $Rule$ from D ;
- (6) $Rule_set = Rule_set + Rule$; // add new rule to rule set
- (7) **until** terminating condition;
- (8) **endfor**
- (9) return $Rule_Set$;

Жишээ: Sequential Covering




(i) Original Data




(ii) Step 1

Жишээ: Sequential Covering



(iii) Step 2



(iv) Step 3

Дүрмийг хэрхэн сурах вэ?

- Дүрмийг өсгөх стратеги / Rule-Growing Strategy


- Стратеги: *general-to-specific*

age, income, education level, residence, credit rating

- Beam search
- Learn One Rule* → Greedy search
- Дүрмийн чанарын хэмжүүр нь нарийвчлал байсан гэж үзье.


IF *income* = *high* THEN *loan_decision* = *accept*.

IF *income* = *high* AND *credit_rating* = *excellent* THEN *loan_decision* = *accept*.



Дүрмийн чанарын хэмжүүр

- Дүрэм боловсруулах явцад ямар холболтыг нэмэх (эсвэл хасах) шаардлагатайг тодорхойлохын тулд үнэлгээний хэмжүүр шаардлагатай.
- Нарийвчлал (*accuracy*) ??
 - Дүрмийн хамрах хүрээг харгалздаггүй.
- **Жишээ нь:**
 - *loan_decision = accept* эсвэл *reject*
 - **Rule r1:** 38 *accept*, 2 *reject* жишээг хамарна.
 - **Rule r2:** 2 *accept* жишээг багтаасан бөгөөд *reject* жишээ байхгүй.
 - *r1* ба *r2*-ийн нарийвчлал нь 95% ба 100% байна.



Rules for the class *loan_decision = accept*, showing *accept* (a) and *reject* (r) tuples.

Дүрмийн чанарын хэмжүүр

- Дараах аргууд нь ижил зарчмаар ажилладаг, өөр алгоритмууд.
 - **CN2**
 - *Entropy (Information gain), beam search*
 - *Харьцангуй удаан*
 - **RIPPER** /сүүлийн үеийн арга/
 - *Foils's Information gain, pruning, greedy search*
 - *Хурдан, том өгөгдлийн багц дээр сайн*

Дүрмийн чанарын хэмжүүр

- Энтропи

R: IF condition THEN class = c. R': IF condition' THEN class = c

- Энтропи бага байх тусам condition' сайн байна гэж үзнэ.
- Энтропи нь тухайн нэг ангиллын олон тооны бичлэгүүдийг хамарсан, бусад ангиллуудын цөөн бичлэгүүдийг хамарсан нөхцөлийг илүүд үздэг.

Дүрмийн чанарын хэмжүүр

- **FOIL - First Order Inductive Learner**

- Мөн мэдээллийн ашиг дээр суурилдаг арга
- *Хамрах хүрээ болон нарийвчлалыг* хоёуланг нь харгалзан үздэг дүрмийн чанарын хэмжүүр.
- Энэ нь өндөр нарийвчлалтай, олон эерэг бичлэгийг хамарсан дүрмийг илүүд үздэг.
- ***R0***: $\{A\} \Rightarrow \text{class}$ (анхны дүрэм)
- ***R1***: $\{A \text{ and } B\} \Rightarrow \text{class}$ (***B*** холбоос нэмсний дараах дүрэм)

$$\text{Gain}(R_0, R_1) = pos_1 \times \left[\log_2 \left(\frac{pos_1}{pos_1 + neg_1} \right) - \log_2 \left(\frac{pos_0}{pos_0 + neg_0} \right) \right]$$

pos*₀**: ***R0 – p хамарсан эерэг тохиолдлуудын тоо

neg*₀**: ***R0 – p хамарсан сөрөг тохиолдлуудын тоо

pos*₁**: ***R1 - p хамарсан эерэг тохиолдлуудын тоо

neg*₁**: ***R1 - p хамарсан сөрөг тохиолдлуудын тоо

FOIL_Gain > 0: Холбоос нэмэх нь дүрмийг сайжруулж байна

FOIL_Gain их → **сайн дүрэм**

Дүрмийн чанарын хэмжүүр

- Дүрмийг тайрах

- *Learn One Rule*

- Дүрмүүд нь сургалтын өгөгдөл дээр сайн ажиллаж болох боловч өөр өгөгдөл дээр муу байна.
 - Үүнийг шийдэхийн тулд дүрмийг тайрч болно.

- Баталгаажуулалтын бие даасан багц дээр үндэслэн дүрмийг тайрах


- Хамгийн сүүдлийн холбоосыг арилгах замаар дүрмийг тайрна

$$FOIL_Prune(R) = \frac{pos - neg}{pos + neg}$$

- *pos/neg* нь *R*-д хамрагдсан эерэг/сөрөг багцуудын тоо юм.
 - Хэрэв *R*-ийн тайрсан хувилбарт *FOIL_Prune* илүү өндөр байвал зөв ангилалт нэмэгдсэн, *R* дүрмийг тайрна.

Шууд бус арга: Шийдвэрийн мод

- Жишээ



R1: IF <i>age</i> = <i>youth</i>	AND <i>student</i> = <i>no</i>	THEN <i>buys_computer</i> = <i>no</i>
R2: IF <i>age</i> = <i>youth</i>	AND <i>student</i> = <i>yes</i>	THEN <i>buys_computer</i> = <i>yes</i>
R3: IF <i>age</i> = <i>middle_aged</i>		THEN <i>buys_computer</i> = <i>yes</i>
R4: IF <i>age</i> = <i>senior</i>	AND <i>credit_rating</i> = <i>excellent</i>	THEN <i>buys_computer</i> = <i>yes</i>
R5: IF <i>age</i> = <i>senior</i>	AND <i>credit_rating</i> = <i>fair</i>	THEN <i>buys_computer</i> = <i>no</i>

БАЯРЛАЛАА

Data mining and machine learning

