

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213


Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Загварын хэт болон дутуу тохируулга
- Загварын үнэлгээ болон сонголт
 - Ангилагчийн таамаглах нарийвчлалын хэмжүүрүүд
 - Ангилагчийн гүйцэтгэлийг үнэлэх техникүүд
- Ангиллын нарийвчлалыг сайжруулах техникүүд


Загварын хэт ба дутуу тохируулга



Баталгаажуулалтын багц

Сургалтын өгөгдлийг 2 хэсэгт хуваана:

- *Сургалтын багц (Training set):*
 - Загварыг байгуулахад хэрэглэнэ
- *Баталгаажуулалтын багц (Validation set)*
 - validation set != test set



Ангилагчийн гүйцэтгэлийг хэмжих хэмжүүрүүд

Classification Performance Metrics

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

<i>Measure</i>	<i>Formula</i>
accuracy, recognition rate	$\frac{TP + TN}{P + N}$
error rate, misclassification rate	$\frac{FP + FN}{P + N}$
sensitivity, true positive rate, recall	$\frac{TP}{P}$
specificity, true negative rate	$\frac{TN}{N}$
precision	$\frac{TP}{TP + FP}$
F , F_1 , F -score, harmonic mean of precision and recall	$\frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$
F_β , where β is a non-negative real number	$\frac{(1 + \beta^2) \times \text{precision} \times \text{recall}}{\beta^2 \times \text{precision} + \text{recall}}$

Хэдийгээр нарийвчлал нь тодорхой хэмжүүр боловч "нарийвчлал" гэдэг үгийг ангилагчийн урьдчилан таамаглах чадварыг илэрхийлэх ерөнхий нэр томъёо болгон ашигладаг болохыг анхаарна уу.

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

- Үнэлгээний бусад хэмжүүрүүдэд хэрэглэгддэг нэр томъёо
 - **True positives (TP):** Ангилагчаар зөв шошгологдсон эерэг бичлэгүүдийн тоо
 - **True negatives(TN):** Ангилагчаар зөв шошгологдсон сөрөг бичлэгүүдийн тоо
 - **False positives (FP):** Ангилагчаар эерэг гэж шошгологдсон сөрөг бичлэгүүдийн тоо
 - Ангилагчийн `buys_computer = yes` таамагласан `buys_computer = no` ангиллын бичлэгүүд
 - **False negatives (FN):** Ангилагчаар сөрөг гэж шошгологдсон эерэг бичлэгүүдийн тоо
 - Ангилагчийн `buys_computer = no` таамагласан `buys_computer = yes` ангиллын бичлэгүүд
- **Төөрөгдлийн матриц:** ялгаатай ангиллын бичлэгүүдийг хэр сайн таньсан болохыг харуулах хэрэгсэл.

		Predicted class		
Actual class		<i>yes</i>	<i>no</i>	Total
	<i>yes</i>	<i>TP</i>	<i>FN</i>	<i>P</i>
	<i>no</i>	<i>FP</i>	<i>TN</i>	<i>N</i>
	Total	<i>P'</i>	<i>N'</i>	<i>P + N</i>

Confusion matrix

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

- *Ангилагчийн таних түвшин (recognition rate)*

$$accuracy = \frac{TP + TN}{P + N}$$

		Predicted class			
			<i>yes</i>	<i>no</i>	Total
Actual class	<i>yes</i>		<i>TP</i>	<i>FN</i>	<i>P</i>
	<i>no</i>		<i>FP</i>	<i>TN</i>	<i>N</i>
Total			<i>P'</i>	<i>N'</i>	<i>P + N</i>

- *Ангилагчийн алдааны хувь эсвэл буруу ангиллын хувь хэмжээ*

$$error\ rate = \frac{FP + FN}{P + N}$$

$$error\ rate = 1 - accuracy(M)$$

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

- **Ангиллын тэнцвэргүй байдлын асуудал**

- Иймээс ангилагч нь эерэг бичлэгүүдийг (*cancer = yes*) болон сөрөг бичлэгүүдийг (*cancer = no*) тус тус хэр сайн таньж байгааг шалгах өөр хэмжүүр хэрэгтэй.

- **Sensitivity** – Зөв тодорхойлсон эерэг бичлэгүүдийн эзлэх хувь
- **Specificity** – Зөв тодорхойлсон сөрөг бичлэгүүдийн эзлэх хувь

$$sensitivity = \frac{TP}{P}$$

$$specificity = \frac{TN}{N}$$

		Predicted class		
		<i>yes</i>	<i>no</i>	
Actual class	<i>yes</i>	<i>TP</i>	<i>FN</i>	<i>P</i>
	<i>no</i>	<i>FP</i>	<i>TN</i>	<i>N</i>
Total		<i>P'</i>	<i>N'</i>	<i>P + N</i>

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

- *precision* болон *recall* хэмжүүрүүдийг ангилалд мөн өргөн хэрэглэгдэг.

- ***Precision*** – яг нарийн таарах (*exactness*) байдлын хэмжүүр

- Эерэг гэж шошгологдсон бичлэгүүдийн хэдэн хувь нь эерэг байсан

$$precision = \frac{TP}{TP + FP}$$

- ***Recall*** - бүрэн байдлын (*completeness*) хэмжүүр

- Эерэг бичлэгүүдийн хэдэн хувь нь эерэг гэж шошгологдсон

- *Recall* $\approx$ *Sensitivity* (Зөв тодорхойлсон эерэг бичлэгүүдийн эзлэх хувь)

$$recall = \frac{TP}{TP + FN} = \frac{TP}{P}$$

		Predicted class		
		<i>yes</i>	<i>no</i>	Total
Actual class	<i>yes</i>	<i>TP</i>	<i>FN</i>	<i>P</i>
	<i>no</i>	<i>FP</i>	<i>TN</i>	<i>N</i>
	Total	<i>P'</i>	<i>N'</i>	<i>P + N</i>

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

- *precision* болон *recall* ашиглах өөр нэг арга бол эдгээрийг нэг хэмжүүр болгон нэгтгэх юм.

- F ($F1$ score, F score)

$$F = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

$$F_{\beta} = \frac{(1 + \beta^2) \times \text{precision} \times \text{recall}}{\beta^2 \times \text{precision} + \text{recall}}$$

- F_{β}

- β сөрөг биш бодит тоо

- F_1 – нь *precision* болон *recall* –д ижил ач холбогдол өгдөг.
- F_2 - *recall* нь *precision*-с 2 дахин их жинтэй
- $F_{0.5}$ - *precision* нь *recall* -с 2 дахин их жинтэй

Ангилагчийн гүйцэтгэлийг үнэлэх хэмжүүр

- **Үнэлгээний хэмжүүрүүд**


- *Accuracy* – Өгөгдлийн ангиллууд тэгш хуваарилагдсан үед тохиромжтой.
- Бусад хэмжүүрүүд - Ангиллууд тэгш бус хуваарилагдсан үед тохиромжтой.
 - *Sensitivity* эсвэл *recall*
 - *Specificity*
 - *Precision*
 - F
 - F_{β}

Ангилагчийн гүйцэтгэлийг үнэлэх аргууд

Holdout & Cross Validation & Bootstrap Methods

“*Holdout*” болон “*Random subsampling*” аргууд

- Энэ хэсэгт ангилагчийн нарийвчлалын найдвартай тооцоог олж авахад чиглэсэн аргуудад анхаарлаа хандуулна.
- ***Holdout***: өгөгдлийн тодорхой хэсгийг хадгалах үйл явцыг хэлнэ.
 - *Training set* – $2/3$, загварыг сургахад
 - *Test set* – $1/3$, загварын нарийвчлалыг тооцоолоход, санамсаргүй сонгоно
- ***Random subsampling***
 - *Holdout* аргыг k удаа давтана.
 - Нарийвчлалын ерөнхий тооцоог давталт бүрээр олж авсан нарийвчлалуудын дунджаар авна.



“*Cross-Validation*” арга

- ***Cross-validation***

- Өгөгдлийг ойролцоогоор тэнцүү хэмжээтэй k дэд хэсгүүдэд хуваана.
- Сургалт болон тестийг k удаа хийнэ.
- $k-1$ сургалтад, үлдсэн нэг нь тестэд хэрэглэгдэнэ.
- Өмнөх аргуудтай адилгүй, түүвэр бүр сургалтад ижил тоогоор, тестэд нэг удаа л ашиглагдана.
- Нийт алдааг бүх гүйлтийн алдааг нэгтгэн гаргана.
- Нарийвчлалын ерөнхий тооцоог давталт бүрээр олж авсан нарийвчлалуудын дунджаар авна.

- ***Leave-one-out***

- $k = n$ (n өгөгдөл дэх бичлэгийн тоо)
- Сургалтад аль болох их өгөгдлийг ашиглах давуу талтай
- Уг процедурыг N удаа давтах нь тооцоолоход үнэтэй байдаг.

- ***Stratified cross-validation***

- Өгөгдлийг ойролцоогоор тэнцүү хэмжээтэй k дэд хэсгүүдэд хуваана.
- Дэд хэсэг бүрт агуулагдах ангилал бүрийн жишээний хувь нь анхны өгөгдлийн багц дахь тухайн ангиллын хувьтай аль болох ойролцоо байна.



3-fold cross validation

Bootstrap арга

- Жижиг өгөгдлийн багцтай сайн ажилладаг.
- ***.632 bootstrap***
 - d бичлэг бүхий өгөгдлийн багцыг d удаа түүвэрлэн сургалтын багцыг үүсгэнэ.
 - Сургалтын багцад ороогүй өгөгдлийн бичлэгүүд нь тестийн багцыг бүрдүүлдэг.
 - Анхны өгөгдлийн 63.2% нь сургалтын багцад ордог бөгөөд үлдсэн 36.8% нь тестийн багцыг бүрдүүлдэг.
 - Дээж авах процедурыг k удаа давтана, загварын ерөнхий нарийвчлал:

$$Acc(M) = \frac{1}{k} \sum_{i=1}^k (0.632 \times Acc(M_i)_{test_set} + 0.368 \times Acc(M_i)_{train_set})$$

Загвар сонгох, загваруудыг харьцуулах

Model selections, comparing

Статистикийн ач холбогдлын тест

- $M1$ ба $M2$ гэсэн 2 ангилагчийн аль нь илүү вэ?
- $\overline{err}(M_1)$ болон $\overline{err}(M_2)$ авахын тулд *10-fold cross validation* ашиглах
- Хэрэв 2 алдааны түвшний ялгаа нь зүгээр л тохиолдлоос үүдэлтэй бол яах вэ?
 - Статистикийн ач холбогдлын тест (*test of statistical significance*)
- **Статистикийн ач холбогдлын тест**
 - Бүлгүүд хооронд ажиглагдсан ялгаа нь статистикийн ач холбогдолтой эсэх, эсвэл санамсаргүй тохиолдлоор үүссэн эсэхийг тодорхойлох хэрэгсэл.

Статистикийн ач холбогдлын тест

- Хэрвээ нэг л тестийн багц байгаа бол: **pairwise comparison**

- 10-fold cross-validation, $err(M_1)_i$ болон $err(M_2)_i$, [$err(M) = 1 - accuracy(M)$]
- 10 алхмын дараа, дундаж алдааг $\overline{err}(M_1)$ болон $\overline{err}(M_2)$
- *t-test (Student's t-test)*:
 - Var – 2 загварын ялгааны дисперс

$$t = \frac{\overline{err}(M_1) - \overline{err}(M_2)}{\sqrt{var(M_1 - M_2)/k}}$$

$$var(M_1 - M_2) = \frac{1}{k} \sum_{i=1}^k [err(M_1)_i - err(M_2)_i - (\overline{err}(M_1) - \overline{err}(M_2))]^2$$

- Хэрвээ 2 тестийн багц байгаа бол: **non-paired t-test**

$$var(M_1 - M_2) = \sqrt{\frac{var(M_1)}{k_1} + \frac{var(M_2)}{k_2}},$$

k_1 & k_2 нь M_1 & M_2 -н хөндлөн баталгаажуулалтын түүврүүдийн тоо


Статистикийн ач холбогдлын тест

- M_1 & M_2 мэдэгдэхүйц ялгаатай юу?
 - t тооцоол. Ач холбогдлын түвшнийг сонго (жишээ нь, $sig = 5\%$)
 - t -distribution хүснэгтийг харах:
 - $k-1$ (жишээ нь, 9) чөлөөт зэрэгт харгалзах t утгыг хайж ол.
 - t -distribution тэгш хэмтэй:
 - **confidence limit** $z=sig/2$ (жишээ нь , 0.025) байх утгыг тархалтын хүснэгтээс хайх
 - **If $t > \text{critical value}$ эсвэл $t < -\text{critical value}$**
 - t утга нь таамаглалыг үгүйсгэх мужид унана
 - **Reject null hypothesis** (M_1 & M_2 алдааны түвшнүүд ижил)
 - Дүгнэлт: M_1 & M_2 хооронд статистикийн ач холбогдол бүхий ялгаа байна.
- **Эсрэг тохиолдолд, дүгнэлт $\rightarrow$ Ялгаа байхгүй.**

ROC curve

- **ROC** (*Receiver Operating Characteristics*) муруй
 - Ангиллын загваруудыг нүдээр **харьцуулах** зориулалттай.
- Хоёртын ангиллын загварын гүйцэтгэлийг үнэлэхэд хэрэглэгддэг график дүрслэл
 - **Ангилал тэнцвэртэй үед**
- *True Positive Rate (TPR)* - *False Positive Rate (FPR)*
 - Босго бүрт харгалзах TPR болон FPR утгын муруй

$$\text{TPR} = \text{TP} / (\text{TP} + \text{FN}) = \text{TP} / \text{P}$$
$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN}) = \text{FP} / \text{N}$$




- ROC муруйн доорх талбай нь загварын нарийвчлалын хэмжүүр юм.
- Диагональ шугамд ойртох тусам (өөрөөр хэлбэл, талбай нь 0.5-тай ойр байх тусам) загвар нь нарийвчлал багатай болно.
- Төгс нарийвчлалтай загварын хувьд талбай 1.0 байна.

Ангиллын нарийвчлалыг сайжруулах техникүүд

Ангиллын нарийвчлалыг сайжруулах техникүүд

- **Ensemble methods**

- Урьдчилан таамаглах гүйцэтгэлийг сайжруулахын тулд олон загваруудын хослолыг хэрэглэдэг.
- $M_1, M_2, \dots, M_k$, k тооны сурсан загваруудыг нэгтгэх, сайжруулсан M^* загвар бий болгох зорилготой.



Ангиллын нарийвчлалыг сайжруулах техникүүд

- **Түгээмэл хэрэглэгддэг аргууд**
 - *Bagging*: ангилагчдын цуглуулгын таамаглалыг дундажлах
 - *Boosting*: ангилагчдын цуглуулгын жинлэсэн санал
 - *Random Forest*

Bagging: Bootstrap Aggregation

- Сургалт

- d бичлэгтэй D өгөгдлийн багц өгөгдөхөд
- i алхам бүрт D -с түүвэрлэсэн (*with replacement*) d бичлэгтэй D_i сургалтын өгөгдлийн багц үүсгэнэ. (*bootstrap*)
- D_i сургалтын өгөгдлийн багц бүр дээр M_i загварыг сургана.



Bagging: Bootstrap Aggregation

- **Classification**

- M_i загвар бүр өөрийн таамаглалыг буцаана.
- M^* нь саналыг тоолж, хамгийн олон санал авсан ангиллыг X -д онооно

- **Prediction**

- Өгөгдсөн тестийн бичлэгийн хувьд таамаглал бүрийн дундаж утгыг авах замаар тасралтгүй утгын таамаглалд хэрэглэж болно.

Boosting

- **Хэрхэн ажилладаг вэ?**

- Сургалтын бичлэг бүрт жин өгнө.
- k ангилагчдыг дараалан сургана.
 - Шинэ загвар бүр өмнөх загваруудын буруу ангилагдсан жишээн дээр анхаарлаа хандуулдаг.
- M^* нь тусдаа ангилагч бүрийн саналыг нэгтгэдэг.
 - Ангилагчийн санал бүр дэх жин нь түүний нарийвчлалаас хамаардаг.



Boosting - AdaBoost (Adaptive Boosting)

$$error(M_i) = \sum_{j=1}^d w_j \times err(X_j)$$

- M_i загварын алдааны түвшин
 - $err(X_j)$ - X_j бичлэгийн буруу ангиллын алдаа, буруу бол 1, эсрэг тохиолдолд 0
 - M_i -ийн буруу ангилсан D_i -д байгаа бичлэг тус бүрийн жинг нэгтгэн гаргана.
 - M_i алдааны түвшин нь сургалтын багцын жинг хэрхэн шинэчлэхэд нөлөөлдөг.
- Алгоритм дууссаны дараа X бичлэгийг эдгээр ангилагчдын нэгдлийг ашиглан хэрхэн ангилах вэ?
 - Ангилагч бүрийн таамаглалд хэр сайн гүйцэтгэлтэй загвараас нь шалтгаалж жин өгдөг.
 - M_i ангилагчийн саналын жин: $\log \frac{1 - error(M_i)}{error(M_i)}$
 - Ангилал c бүрийн хувьд
 - X бичлэгийн хувьд c ангилал гэж гаргасан загвар бүрийн жингийн нийлбэрийг бодох
 - Жингийн нийлбэр хамгийн өндөр гарсан ангиллыг сонгох

Random Forests

- Загваруудын нэгдэл дэх ангилагч бүр нь шийдвэрийн мод, иймээс ангилагчдын цуглуулга нь “*forest*” юм.
- Хуваагдлыг тодорхойлохын тулд зангилаа бүр дээр атрибутуудын санамсаргүй сонголтыг хэрэглэн модыг үүсгэдэг.
- Дараа нь бие даасан модны таамаглалуудыг нэгтгэн
 - Олонхийн саналыг эцсийн таамаглал болгон авна.
 - Үргэлжилсэн утга байвал дундаж утгыг нь авах
- Цөөн атрибутыг авч үздэг тул маш том өгөгдлийн багц дээр үр дүнтэй.

Ангилал нь тэнцвэргүй өгөгдлийн багцын ангилал

- Ангилал нь тэнцвэргүй өгөгдлийн ангиллын нарийвчлалыг сайжруулах
 - *Oversampling*
 - Эерэг бичлэгүүдийг дахин түүвэрлэх замаар сургалтын багц эерэг болон сөрөг бичлэгүүдийг ижил тоогоор агуулна.
 - *Undersampling*
 - Эерэг болон сөрөг бичлэгүүдийг ижил тоотой болох хүртэл сөрөг бичлэгүүдийн тоог бууруулах буюу санамсаргүйгээр устгана.
 - *Threshold moving*
 - *Ensemble techniques*

БАЯРЛАЛАА

Data mining and machine learning

