

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213


Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- **Ангилагчууд**
 - Хамгийн ойрын хөршийн ангилагч / *K-Nearest Neighbor (KNN)*

Хамгийн ойрын хөршийн ангилагч



Хамгийн ойрын хөршийн ангилагч


- Өгөгдсөн тестийн багцыг түүнтэй ижил төстэй сургалтын багцуудтай харьцуулах замаар суралцахад үндэслэдэг.
- Сургалтын бичлэгүүд n атрибуттай.
 - Бичлэг бүр n *хэмжээст* орон зай дахь цэг байдлаар дүрслэгдэнэ.
 - Сургалтын бичлэгүүд нь n *хэмжээст* загварын орон зайд хадгалагдана.
- Үл мэдэгдэх бичлэг өгөгдөхөд
 - Уг бичлэгтэй хамгийн ойр байгаа k сургалтын бичлэгийг загварын орон зайд хайдаг.
 - Эдгээр k сургалтын бичлэгүүд нь үл мэдэгдэх бичлэгийн хамгийн ойрын хөрш юм.

Хамгийн ойрын хөршийн ангилагч

- “*Closeness*” – Евклидийн зай гэх мэт зайн хэмжүүрээр тодорхойлогддог.
 - 2 цэгийн хоорондох *Евклидийн зай*
 - $X_1 = (x_{11}, x_{12}, \dots, x_{1n}) \quad X_2 = (x_{21}, x_{22}, \dots, x_{2n})$
- $$\text{dist}(X_1, X_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$
- Зайг олохын өмнө ихэвчлэн хувьсагчдыг нормчилдог (өгөгдлийн урьдчилсан боловсруулалт).
 - *Min-max normalization*:
 - Үл мэдэгдэх бичлэгийг түүний хамгийн ойрын k хөршийн дагуу хамгийн нийтлэг байгаа ангилалд хуваарилдаг.


Хамгийн ойрын хөршийн ангилагч

Unknown record



- Дараахь зүйлийг шаарддаг.
 - Шошгологдсон бичлэгүүдийн багц
 - Хос бичлэгүүдийн хоорондын зай/ижил төстэй байдлыг тооцоолоход зориулагдсан ойрын хэмжүүр
 - Жнь, Евклидийн зай
 - Олж авах хамгийн ойрын хөршүүдийн тоо болох k -ийн утга
 - Үл мэдэгдэх бичлэгийн ангиллын шошгыг тодорхойлохын тулд хамгийн ойрын K хөршүүдийн ангийн шошгыг ашиглах арга (жишээ нь, олонхи санал)

Хамгийн ойрын хөршийн ангилагч



(a) 1-nearest neighbor


(b) 2-nearest neighbor

(c) 3-nearest neighbor

Нэг жишээний хамгийн ойрын 1, 2, 3 хөршүүд.

Хамгийн ойрын хөршийн ангилагч

- k -н хамгийн сайн утгыг хэрхэн сонгох вэ?
 - Хэрэв k хэтэрхий бага бол, шуугианд (*noise points*) мэдрэмтгий
 - Хэрэв k хэтэрхий том бол, хөрш нь бусад ангиллын цэгүүдийг агуулна.
- Үүнийг туршилтаар тодорхойлж болно.
 - $k = 1$, ангилагчийн алдааны түвшинг (*error rate*) тооцоолохын тулд тестийн багцыг хэрэглэнэ.
 - Дахин нэг хөрш нэмэхийн тулд алхам тутамд k -н утгыг 1-р нэмэгдүүлэн энэ процессыг давтана.
 - Хамгийн бага алдааг өгөх k -н утгыг сонгох



Тестийн дээжийн ангиллын шошгыг хэрхэн тодорхойлох вэ?

- ***Олонхийн санал***

$$\text{Majority Voting: } y' = \operatorname{argmax}_v \sum_{(\mathbf{x}_i, y_i) \in D_z} I(v = y_i),$$

- k -хамгийн ойрын хөршүүдийн дунд ангиллын шошгоны олонхийн саналыг авах
- Хамгийн их давтамжтай ангиллууд тэнцсэн тохиолдолд тэнцсэн ангиллуудаас аль нэгийг санамсаргүй сонгох
 - Олон ангилал тэнцсэн тохиолдолд үр дүн муутай

- ***Зайнаас хамаарсан жигнэсэн санал***

$$\text{Distance-Weighted Voting: } y' = \operatorname{argmax}_v \sum_{(\mathbf{x}_i, y_i) \in D_z} w_i \times I(v = y_i).$$

- Хөрш тус бүрт зайнаас хамаарч $w = 1/d^2$ жинг бодно.
- k хөршүүдийн ангиллын жигнэсэн нийлбэрийг тооцоолж, жингийн нийлбэр хамгийн их ангиллыг шинэ ажиглалтад онооно.
- Энэ арга нь шинэ ажиглалтад илүү ойр байгаа хөршүүдэд илүү их ач холбогдол өгдөг.

Хамгийн ойрын хөршийн ангилагч

- Тоон бус нэрлэсэн шинж чанаруудын хувьд зайг хэрхэн тооцоолох вэ?
 - Хамгийн энгийн арга бол *Hamming distance*
 - $X1$ болон $X2$ -н харгалзах атрибутын утгууд
 - Ижил бол 0
 - Өөр бол 1

Хамгийн ойрын хөршийн ангилагч

- Сургалтын болон тестийн багц дахь дутуу утгууд (**missing value**)
 - Ойр байдлын тооцоололд (*Proximity computations*) ихэвчлэн бүх атрибутууд байх шаардлагатай.
 - Бичлэгийг устгах → Дутуу утгатай бичлэг их бол үр дүн муу
 - Дутуу утгыг орлуулах → *mean, median, mode*
 - Жинхэнэ утгыг үнэн зөв тусгахгүй байж болно.

БАЯРЛАЛАА

Data mining and machine learning

