

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга


- Холбоо хамаарлын шинжилгээ (Association Analysis)

Холбоо хамаарлын шинжилгээ

- *AllElectronics* борлуулалтын менежер
 - Үйлчлүүлэгч (*PC, digital camera*)
 - *PC, digital camera* → ямар бүтээгдэхүүнийг байнга худалдан авдаг талаарх мэдээлэл хэрэгтэй.
- Энэ тохиолдлын олборлохыг хүсэж буй мэдлэг
 - Байнга тохиолддог хэв маяг (*frequent patterns*)
 - Холбоо хамаарлын дүрэм (*association rules*)

Холбоо хамаарлын шинжилгээ

- Байнга тохиолддог зүйлсийн багцыг олборлох
 - Зах зээлийн сагсны шинжилгээ
 - Маркетингийн стратеги боловсруулах
 - Тавиурын менежмент
 - Борлуулалтыг нэмэгдүүлэх



Холбоо хамаарлын дүрэм

- Холбоо хамаарлын дүрэм
 - Том өгөгдлийн багц дахь ялгаатай зүйлсийн хоорондын харилцаа, хэв маягийг тодорхойлдог өгөгдөл олборлох техник.
 - Өгөгдлийн багц дахь зүйлсийн хоорондын харилцааг тайлбарлах дүрмийг тодорхойлохыг эрэлхийлдэг.
- Дүрэм нь дараах зүйлээс бүрдэнэ.
 - Өмнөх зүйл (*antecedent*) – Дүрмийн зүүн талын хэсэг
 - Үр дагавар (*consequent*) - Дүрмийн баруун талын хэсэг

Холбоо хамаарлын дүрмийн жишээ

$\{\text{Diaper}\} \rightarrow \{\text{Beer}\},$
 $\{\text{Milk, Bread}\} \rightarrow \{\text{Eggs, Coke}\},$
 $\{\text{Beer, Bread}\} \rightarrow \{\text{Milk}\},$

Market-Basket transactions

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Холбоо хамаарлын дүрэм

□ Дүрмийн үнэлгээний хэмжүүр

– *support* болон *confidence* дүрмийн *ашиг тустай* болон *баталгаатай (унгэлтэй)* байдлыг тус тусад нь тусгаж харуулдаг.

– *Support (s)*

◆ X ба Y аль алиныг нь агуулсан гүйлгээний хэсэг

– *Confidence (c)*

◆ X агуулсан гүйлгээнд Y дэх зүйлс хэр олон удаа гарч байгааг хэмждэг

□ Босго утгуудыг хангасан дүрмийг хүчтэй гэж үзнэ.

– $support \geq minsup\ threshold$

– $confidence \geq minconf\ threshold$


Холбоо хамаарлын дүрэм

- Холбоо хамаарлын дүрэм олборлох асуудлыг *байнга тохиолддог зүйлсийг олборлох* асуудал болгон тооцооллыг бууруулж болно.
- **Холбоо хамаарлын дүрэм олборлох 2 алхамт арга**
 1. *Бүх байнга тохиолддог зүйлсийн багцыг олох*
 - Багц бүр нь дор хаяж урьдчилан тодорхойлсон min_sup тоотой адил олон удаа тохиолдох
 2. *Байнга давтагддаг зүйлсийн багцаас хүчтэй дүрмийг үүсгэх*
 - *Confidence* өндөр дүрмүүдийг үүсгэх
 - Эдгээр дүрмүүд нь min_sup , min_conf хангасан байх ёстой.

(1) Байнга тохиолддог зүйлсийн багцыг үүсгэх

- **Brute-force арга:**

- Торны бүтэц дэх багц бүр нь нэр дэвшигч багцууд (байнга тохиолддог) байна.
- Нэр дэвшигч бүрийн *support* утгыг олох



- Нэр дэвшигч бүрийг гүйлгээ бүртэй харьцуулна.
- $O(NMw)$ харьцуулалт шаардана => **Үнэтэй, учир нь $M = 2^d$!!!**

Байнга тохиолддог зүйлсийн багцыг үүсгэх стратеги

А. Нэр дэвшигчийн тоог багасгах (M)

- Нийт хайлт: $M=2^d$
- M багасгахын тулд тайрах техникийг ашиглах


В. Харьцуулалтын тоог багасгах (NM)

- Нэр дэвшигчид эсвэл гүйлгээг хадгалахын тулд үр ашигтай өгөгдлийн бүтцийг ашиглах
- Нэр дэвшигч бүрийг гүйлгээ бүртэй харьцуулах шаардлагагүй

(A) Нэр дэвшигчийн тоог багасгах

- *Aprior* алгоритм (*priori knowledge*)
 - Байнга тохиолддог зүйлсийн багцын шинж чанаруудын өмнөх мэдлэгийг ашигладаг.
 - *k-itemsets* нь $(k + 1)$ -*itemsets* судлахад хэрэглэгддэг.
 - *Apriori property* хэрэглэн хайлтын орон зайг багасгадаг.
- *Apriori property*
 - Байнга тохиолддог зүйлсийн багцын бүх дэд олонлог нь мөн байнга давтагдах ёстой.
 - Тухайн багцын *support* утга нь түүний дэд багцын *support* утгаас хэзээ ч хэтрэхгүй
 - Хэрэв багц шалгалтыг давж чадаагүй бол түүний бүх супер олонлогууд мөн адил шалгалтад тэнцэхгүй.
 - Үүнийг *antimonotone* шинж чанар гэдэг.

Apriori property



Apriori алгоритм

- F_k : Байнга тохиолдох k -зүйлсийн багцууд
- L_k : k -зүйлсийн багцын нэр дэвшигч
- **Алгоритм**
 - $k=1$
 - $F_1 = \{\text{Байнга тохиолдох 1-зүйлийн багцууд}\}$ үүсгэх
 - F_k хоосон болох хүртэл давтах
 - **Нэр дэвшигчийг үүсгэх**: F_k -ээс L_{k+1} үүсгэх
 - **Нэр дэвшигчийг тайрах**: L_{k+1} дэх ховор тохиолддог k урттай дэд олонлогуудыг агуулсан нэр дэвшигчийн багцыг тайрах
 - **Support тоолох**: L_{k+1} дэх нэр дэвшигч бүрийн *support* -г өгөгдлийн багцыг сканнердаж тоол
 - **Нэр дэвшигчийг устгах**: L_{k+1} дэх ховор тохиолдох нэр дэвшигчийг устгаж, байнга тохиолдох нэр дэвшигчдийг үлдээх $\Rightarrow F_{k+1}$

(B) Харьцуулалтын тоог багасгах


- Нэр дэвшигч багц бүрийн *support* утгыг тодорхойлохын тулд гүйлгээний өгөгдлийн санг сканердах
 - Нэр дэвшигч багц бүрийг гүйлгээ болгонтой тааруулах ёстой бөгөөд энэ нь зардал ихтэй ажиллагаа юм

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Beer, Bread, Diaper, Eggs
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Bread, Coke, Diaper, Milk

Itemset
{ Beer, Diaper, Milk}
{ Beer,Bread,Diaper}
{Bread, Diaper, Milk}
{ Beer, Bread, Milk}

Харьцуулалтын тоог багасгах

- Харьцуулалтын тоог багасгахын тулд нэр дэвшигчдийн багцыг хэш бүтцэд (*hash structure*) хадгал
- Гүйлгээ бүрийг нэр дэвшигч бүртэй харьцуулахын оронд түүнийг хувин дотор байгаа нэр дэвшигчидтэй харьцуул




Support counting: Жишээ

3 урттай 15 нэр дэвшигчийн багц байгаа гэж бодъё:

{1 4 5}, {1 2 4}, {4 5 7}, {1 2 5}, {4 5 8}, {1 5 9}, {1 3 6}, {2 3 4}, {5 6 7}, {3 4 5}, {3 5 6}, {3 5 7}, {6 8 9}, {3 6 7}, {3 6 8}

Эдгээр багцын хэд нь (1, 2, 3, 5, 6) гүйлгээгээр дэмжигддэг вэ?




Hash Tree хэрэглэн дэмжлэгийн тоог тоолох

3 урттай 15 нэр дэвшигчийн багц байгаа гэж бодъё:

{1 4 5}, {1 2 4}, {4 5 7}, {1 2 5}, {4 5 8}, {1 5 9}, {1 3 6}, {2 3 4}, {5 6 7}, {3 4 5}, {3 5 6}, {3 5 7}, {6 8 9}, {3 6 7}, {3 6 8}


Хэрэгтэй зүйлс:

- Hash function
- Max leaf size: Навч зангилаанд хадгалагдах багцын хамгийн их тоо (хэрэв нэр дэвшигчийн багцын тоо хамгийн их хэмжээнээс хэтэрсэн бол зангилааг хуваах)



hash function, $h(p) = p \bmod 3$

Max leaf size = 3



(2) Байнга давтагддаг зүйлсийн багцаас дүрэм үүсгэх

- ***D*** өгөгдлийн сан

1. Гүйлгээний байнга тохиолддог зүйлсийн багцуудыг олох
2. Тэдгээрээс хүчтэй холбоо хамаарлын дүрмийг олох нь хялбар байдаг.

- *minimum support* болон *minimum confidence* хоёуланг нь хангах

$$confidence(A \Rightarrow B) = P(B|A) = \frac{support_count(A \cup B)}{support_count(A)}$$

- Жишээ: $X = \{I1, I2, I5\}$ – Байнга давтагддаг зүйлсийн багц

- X – с үүсэж болох холбоо хамаарлын дүрмүүд: $\{I1, I2\}$, $\{I1, I5\}$, $\{I2, I5\}$, $\{I1\}$, $\{I2\}$, $\{I5\}$

<i>TID</i>	<i>List of item IDs</i>
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3

$\{I1, I2\} \Rightarrow I5$,	$confidence = 2/4 = 50\%$
$\{I1, I5\} \Rightarrow I2$,	$confidence = 2/2 = 100\%$
$\{I2, I5\} \Rightarrow I1$,	$confidence = 2/2 = 100\%$
$I1 \Rightarrow \{I2, I5\}$,	$confidence = 2/6 = 33\%$
$I2 \Rightarrow \{I1, I5\}$,	$confidence = 2/7 = 29\%$
$I5 \Rightarrow \{I1, I2\}$,	$confidence = 2/2 = 100\%$

min_conf = 70%

Хүчтэй дүрмүүд: 2, 3, 6


Дүрэм үүсгэх

- Ерөнхийдөө, *confidence* нь *antimonotone* шинж чанаргүй байдаг.
 $c(ABC \rightarrow D)$ нь $c(AB \rightarrow D)$ –с их эсвэл бага байж болно.
- Гэвч нэг ижил багцаас үүсгэсэн дүрмүүдийн *confidence* *antimonotone* шинж чанартай байна.
 - Жнь., $\{A, B, C, D\}$ байнга тохиолддог 4 зүйлийн багц гэж үзье:

$$c(ABC \rightarrow D) \geq c(AB \rightarrow CD) \geq c(A \rightarrow BCD)$$

Apriori алгоритм: Дүрэм үүсгэх

Lattice of rules



Apriori алгоритмд нөлөөлөх хүчин зүйлүүд

- **Хамгийн бага дэмжлэгийн босго сонгох (minimum support threshold)**
- **Өгөгдлийн багцын хэмжээс (зүйлүүдийн тоо)**
- **Өгөгдлийн сангийн хэмжээ**
- **Гүйлгээний дундаж өргөн**

БАЯРЛАЛАА

Data mining and machine learning

