

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Холбоо хамаарлын шинжилгээ (Association Analysis)


Их хэмжээний өгөгдлийн багцын бэрхшээл

- Их хэмжээний өгөгдлийн багц
 - *min_sup* хангасан асар олон тооны байнга тохиолддог зүйлүүдийн багц үүсэх боломжтой.
 - Ялангуяа *min_sup* босгыг багаар өгсөн үед
 - Тухайн олонлог байнга тохиолддог бол түүний дэд олонлогууд мөн адил
 - Компьютер тооцоолох, хадгалахад дэндүү том багц үүсэх боломжтой.
- Энэ хүндрэлийг даван туулахад илүү авсаархан дүрслэл хэрэгтэй
 - *Closed frequent itemset*
 - *Maximal frequent itemset*

Хамгийн их давтамжтай зүйлсийн багц (Maximal Frequent Itemset)

Хэрэв багц нь байнга тохиолддог ба түүний ойрын супер багцуудын аль нь ч байнга тохиолддоггүй бол тухайн багцыг хамгийн их тохиолдолтой (**maximal frequent**) гэнэ.

TID	Items
1	a,b,d
2	a,c
3	a,b,c
4	a,d



- support count threshold = $2/4=50\%$
- Тухайн зүйл 2 болон түүнээс илүү гүйлгээнд тохиолдох ёстой.

Жишээ

Transactions	Items									
	A	B	C	D	E	F	G	H	I	J
	1									
	2									
	3									
	4									
	5									
	6									
	7									
	8									
	9									
	10									

Support threshold (by count) : 5

Frequent itemsets: {F}

Maximal itemsets: {F}

Support threshold (by count): 4

Frequent itemsets: {E}, {F}, {E,F}, {J}

Maximal itemsets: {E,F}, {J}

Support threshold (by count): 3

Frequent itemsets:

All subsets of {C,D,E,F} + {J}

Maximal itemsets:

{C,D,E,F}, {J}

Хаалттай байнга тохиолддог зүйлсийн багц (*Closed frequent itemset*)

- Хэрэв X -н ойрын супер багцуудын аль нь ч X -тэй ижил дэмжлэггүй (*support*) бол X багц хаалттай байна.
- Ядаж нэг ойрын супер багц нь X шиг дэмжигдсэн (*support*) бол X нь хаалттай биш.


TID	Items
1	{A,B}
2	{B,C,D}
3	{A,B,C,D}
4	{A,B,D}
5	{A,B,C,D}

Itemset	Support
{A}	4
{B}	5
{C}	3
{D}	4
{A,B}	4
{A,C}	2
{A,D}	3
{B,C}	3
{B,D}	4
{C,D}	3

Itemset	Support
{A,B,C}	2
{A,B,D}	3
{A,C,D}	2
{B,C,D}	2
{A,B,C,D}	2

Maximal Frequent vs Closed Frequent Itemsets

TID	Items
1	ABC
2	ABCD
3	BCE
4	ACDE
5	DE



Жишээ-1

		Items									
Transactions		A	B	C	D	E	F	G	H	I	J
	1										
	2										
	3										
	4										
	5										
	6										
	7										
	8										
	9										
	10										

Itemsets	Support (counts)	Closed itemsets
{C}	3	✓
{D}	2	
{C,D}	2	✓

Жишээ-2

Items

Transactions

	A	B	C	D	E	F	G	H	I	J
1										
2										
3										
4										
5										
6										
7										
8										
9										
10										

Itemsets	Support (counts)	Closed itemsets
{C}	3	✓
{D}	2	
{E}	2	
{C,D}	2	
{C,E}	2	
{D,E}	2	
{C,D,E}	2	✓

Загварын үнэлгээний аргууд

- **Аль загварууд сонирхолтой байна вэ?**
- Холбоо хамаарлын дүрэм олборлолтын ихэнх алгоритмууд нь дараах хэмжүүрүүдийг ашигладаг.
 - *Support, confidence*
- *min_sup*, *min_conf* нь олон тооны сонирхолгүй дүрмүүдийг судлахаас зайлсхийхэд тусалдаг.
 - Гэсэн хэдий ч үүсгэгдсэн олон тооны дүрмүүд нь хэрэглэгчид сонирхолгүй хэвээр байдаг.
 - Ялангуяа *min_sup* утгыг багаар авах үеийн олборлолтын үед ихэвчлэн тохиолддог.

Confidence сул тал

Customers	Tea	Coffee	...
C1	0	1	...
C2	1	0	...
C3	1	1	...
C4	1	0	...
...			

	<i>Coffee</i>	$\overline{Coffee}$	
<i>Tea</i>	150	50	200
$\overline{Tea}$	650	150	800
	800	200	1000

Association Rule: *Tea* → *Coffee*

Confidence $\cong P(Coffee|Tea) = 150/200 = 0.75$

$P(Coffee) = 800/1000 = 0.8$ (*support*)

$P(Coffee|\overline{Tea}) = 650/800 = 0.8125$

Confidence сул тал

Customers	Tea	Honey	...
C1	0	1	...
C2	1	0	...
C3	1	1	...
C4	1	0	...
...			

	<i>Honey</i>	$\overline{Honey}$	
<i>Tea</i>	100	100	200
$\overline{Tea}$	20	780	800
	120	880	1000

Association Rule: *Tea* → *Honey*

- **Confidence** $\cong P(\text{Honey}|\text{Tea}) = 100/200 = 0.50$
- **Confidence** = 50%, Иймээс дүрэм нь сонирхолгүй байна.
- ГЭВЧ **$P(\text{Honey}) = 120/1000 = 0.12$** (*support*)

Жишээ: Lift

$$\boxed{\text{lift}(A, B) = \frac{P(A \cup B)}{P(A)P(B)}} \quad \text{Lift}(A, B) \begin{cases} = 1, & \text{if } A \text{ and } B \text{ are independent;} \\ > 1, & \text{if } A \text{ and } B \text{ are positively correlated;} \\ < 1, & \text{if } A \text{ and } B \text{ are negatively correlated.} \end{cases}$$

Association Rule: Tea $\rightarrow$ Coffee

$$\text{Confidence} = P(\text{Coffee}|\text{Tea}) = 150/200 = 0.75$$

$$\text{Гэвч } P(\text{Coffee}) = 0.8$$

$$\Rightarrow \text{Lift} = 0.15 / (0.2 \times 0.8) = 0.9375 (< 1, \text{ иймээс сөрөг хамааралтай})$$

	Coffee	<u>Coffee</u>	
Tea	150	50	200
<u>Tea</u>	650	150	800
	800	200	1000

Загварын үнэлгээний аргууд

Бусад хэмжүүр

- Олон хэмжүүр байдаг.
- Хэмжүүр бүр нь өгөгдлийн багц дахь зүйлсүүдийн хоорондын хамаарлыг өөр өөр өнцгөөс харуулдаг.
- Хэмжүүр бүр өөрийн давуу болон сул талуудтай.
- Өөр өөр төрлийн өгөгдлийн багц болон судалгааны асуултуудад тохиромжтой.
- Өгөгдлийн шинжээчид судалгааны асуултууд, өгөгдлийн багцын шинж чанар, шинжилгээний зорилгоос хамааран тохирох хэмжүүрийг сонгох хэрэгтэй.

Measure (Symbol)	Definition
Correlation (ϕ)	$\frac{N f_{11} - f_{1+} f_{+1}}{\sqrt{f_{1+} f_{+1} f_{0+} f_{+0}}}$
Odds ratio (α)	$(f_{11} f_{00}) / (f_{10} f_{01})$
Kappa (κ)	$\frac{N f_{11} + N f_{00} - f_{1+} f_{+1} - f_{0+} f_{+0}}{N^2 - f_{1+} f_{+1} - f_{0+} f_{+0}}$
Interest (I)	$(N f_{11}) / (f_{1+} f_{+1})$
Cosine (IS)	$(f_{11}) / (\sqrt{f_{1+} f_{+1}})$
Piatetsky-Shapiro (PS)	$\frac{f_{11}}{N} - \frac{f_{1+} f_{+1}}{N^2}$
Collective strength (S)	$\frac{f_{11} + f_{00}}{f_{1+} f_{+1} + f_{0+} f_{+0}} \times \frac{N - f_{1+} f_{+1} - f_{0+} f_{+0}}{N - f_{11} - f_{00}}$
Jaccard (ζ)	$f_{11} / (f_{1+} + f_{+1} - f_{11})$
All-confidence (h)	$\min \left[\frac{f_{11}}{f_{1+}}, \frac{f_{11}}{f_{+1}} \right]$

БАЯРЛАЛАА

Data mining and machine learning

