

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС




Агуулга

- Кластерийн шинжилгээ (үргэлжлэл)


Шаталсан аргууд

- Кластеруудын *Hierarchical* болон *Partitional* багцууд
 - **Partitional Clustering (unnested)**
 - Өгөгдлийн объектуудыг давхацдаггүй дэд бүлэгт (кластер) хуваах
 - **Hierarchical clustering (nested)**
 - Шаталсан мод хэлбэрээр зохион байгуулагдсан, бие биедээ багтсан бүлгүүдийн багц

Хуваалтын болон шаталсан аргууд



Partitional Clustering



Hierarchical Clustering


Нэгтгэх болон хуваах шаталсан кластерчлал

- Шаталсан кластерийн арга
 - Шаталсан кластер нь доороос дээш эсвэл дээрээс доош хэлбэрээр үүссэн эсэхээс 2 хуваагддаг.
 - Нэгтгэх
 - Хуваах
- **Нэгтгэх (Agglomerative Hierarchical Clustering)**
 - Доороос дээш чиглэсэн стратеги (*bottom-up strategy*)
- **Хуваах (Divisive Hierarchical Clustering)**
 - Дээрээс доош чиглэсэн стратеги (*top-down strategy*)

Нэгтгэх болон хуваах шаталсан кластерчлал


- **Жишээ**

- AGNES (AGglomerative NESting)
- DIANA (DIvisive ANAlysis)



Нэгтгэх болон хуваах шаталсан кластерчлал

- **Дэндограм (*Dendrogram*)** – модны бүтэц
 - Шаталсан кластерийн үйл явцыг илэрхийлэхэд ихэвчлэн ашиглагддаг.
 - Энэ нь объектууд хэрхэн хамтдаа бүлэглэгдэх (*agglomerative method*) эсвэл хуваагдаж (*divisive method*) байгааг алхам алхмаар харуулдаг.




Зайн хэмжүүр

- *Нэгтгэх* эсвэл *хуваах* аргаас үл хамааран кластер бүрийн хоорондын зайг хэмжих хэрэгцээ кластерт байдаг.
- *Agglomerative Clustering Algorithm*
 - **Гол санаа: Хамгийн ойрын кластеруудыг дараалан нэгтгэх**
 - **Үндсэн алгоритм**
 1. proximity matrix тооцоол
 2. Өгөгдлийн цэг бүрийг кластер болго
 3. **Давтах**
 4. Хамгийн ойрын 2 кластерийг нэгтгэх
 5. proximity matrix шинэчил
 6. **Зөвхөн нэг кластер үлдэх хүртэл**
 - Гол үйлдэл нь хоёр кластерын ойролцоо байдлыг (proximity) тооцоолох явдал юм
 - Кластер хоорондын зайг тодорхойлох янз бүрийн аргууд нь алгоритмуудыг ялгадаг.


Алхам 4

- Хамгийн ойрын хоёр кластерыг ($C2$ ба $C5$) нэгтгэж, ойрын матрицыг шинэчлэе




	C1	C2	C3	C4	C5
C1					
C2					
C3					
C4					
C5					

Proximity Matrix




Алхам 5

- *proximity matrix*-г хэрхэн шинэчлэх вэ?



		C1	C2 ∪ C5	C3	C4
C1			?		
C2 ∪ C5		?	?	?	?
C3			?		
C4			?		

Proximity Matrix



Зайн хэмжүүр

- Кластеруудын хоорондын зайг хэмжих өргөн хэрэглэгддэг 4 хэмжүүр.

nearest-neighbor clustering algorithm

Minimum distance: $dist_{min}(C_i, C_j) = \min_{p \in C_i, p' \in C_j} \{|p - p'|\}$

farthest-neighbor clustering algorithm

Maximum distance: $dist_{max}(C_i, C_j) = \max_{p \in C_i, p' \in C_j} \{|p - p'|\}$

- $|p - p'|$ - 2 цэгийн хоорондох зай
- $m_i - C_i$ кластерийн дундаж
- $n_i - C_i$ кластер дахь объектуудын тоо

Mean distance: $dist_{mean}(C_i, C_j) = |m_i - m_j|$


Average distance: $dist_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p \in C_i, p' \in C_j} |p - p'|$

Шаталсан кластерчлал: MIN эсвэл Single Link

- Хоёр кластерын ойролцоо байдал нь (*proximity*) өөр өөр кластеруудын хамгийн ойр хоёр цэг дээр суурилдаг.
 - Нэг хос цэгээр, өөрөөр хэлбэл нэг холбоосоор (*one link*) тодорхойлогддог.
- Жишээ:

$$\text{Sim}(C1, C2) = \text{Min Sim}(P_i, P_j)$$

$$P_i \in C1 \text{ \& } P_j \in C2$$



Distance Matrix:

	P1	P2	P3	P4	P5
P1	0				
P2	1.04139	0			
P3	0.59304	0.77369	0		
P4	0.46098	0.61612	0.30232	0	
P5	0.81841	0.32388	0.45222	0.35847	0

Шаталсан кластерчлал: MIN эсвэл Single Link

Кластер үүсгэсний дараа зайны матрицыг дахин тооцоол

	P1	P2	✓P3	P4	P5
P1	0				
P2	1.04139	0			
P3✓	0.59304	0.77369	0		
P4✓	0.46098	0.61612	0.30232	0	
P5	0.81841	0.32388	0.45222	0.35847	0

	P1	P2	P3,P4	P5
P1	0			
P2	1.04139	0		
P3,P4	0.46098	0.61612	0	
P5	0.81841	0.32388	0.35847	0

$$= \text{Min}(\text{dist}(P3,P4), P1) \rightarrow \text{Min}(\text{dist}(P3,P1), \text{dist}(P4,P1))$$

$$= \text{Min}(0.59304, 0.46098)$$

$$= 0.46098$$

$$= \text{Min}(\text{dist}(P3,P4), P2) \rightarrow \text{Min}(\text{dist}(P3,P2), \text{dist}(P4,P2))$$

$$= \text{Min}(0.77369, 0.61612)$$

$$= 0.61612$$

	P1	✓P2	P3,P4	P5
P1	0			
P2✓	1.04139	0		
P3,P4	0.46098	0.61612	0	
P5✓	0.81841	0.32388	0.35847	0

Шаталсан кластерчлал: MIN

	P1	P2	P3,P4	P5
P1	0			
P2	1.04139	0		
P3,P4	0.46098	0.61612	0	
P5	0.81841	0.32388	0.35847	0

= $\text{Min}(\text{dist}((P2,P5),P1)) \rightarrow \text{Min}(\text{dist}(P2,P1), \text{dist}(P5, P1))$

= $\text{Min}(1.04139, 0.81841)$

= 0.81841

	P1	P2,P5	P3,P4
P1	0		
P2,P5	0.81841	0	
P3,P4	0.46098	0.35847	0

= $\text{Min}(\text{dist}(((P3,P4),(P2,P5)), P1))$

= $\text{Min}(0.46098, 0.81841)$

= 0.46098

	P1	P2,P5,P3,P4
P1	0	
P2,P5,P3,P4	0.46098	0

= $\text{Min}(\text{dist}((P2,P5), (P3,P4))) \rightarrow \text{Min}(\text{dist}(P2,(P3,P4)), \text{dist}(P5,(P3,P4)))$


= $\text{Min}(\text{dist}(0.61612, 0.35847))$

= 0.35847


	P1	P2,P5	P3,P4
P1	0		
P2,P5	0.81841	0	
P3,P4✓	0.46098	0.35847	0

Шаталсан кластерчлал: MIN эсвэл Single Link


Дендрограм дахь босоо шугамын урт нь зайг харуулдаг. Жишээлбэл, P2, P5 цэгүүдийн хоорондох зай нь 0.32388 байна.



Шаталсан кластерчлал: MIN аргын давуу тал




Original Points




Six Clusters

Зууван бус хэлбэрийг боловсруулж чадна


Шаталсан кластерчлал: MIN аргын хязгаарлалт



Original Points




Two Clusters



Three Clusters


Шуугианд мэдрэмтгий

Шаталсан кластерчлал: MAX аргын давуу тал




Шуугианд бага өртөмтгий

Шаталсан кластерчлал: МАХ аргын хязгаарлалт



Original Points



Two Clusters

- Том кластеруудыг эвдэх хандлагатай
- Бөмбөрцөг хэлбэртэй кластер луу чиглэсэн


Шаталсан кластерчлал: Group Average

$$\text{dist}(\{3, 6, 4\}, \{1\}) = (0.22 + 0.37 + 0.23)/(3 * 1)$$


$$= 0.28$$

$$\text{dist}(\{2, 5\}, \{1\}) = (0.2357 + 0.3421)/(2 * 1)$$

$$= 0.2889$$



Nested Clusters



Dendrogram

Distance Matrix:

	p1	p2	p3	p4	p5	p6
p1	0.00	0.24	0.22	0.37	0.34	0.23
p2	0.24	0.00	0.15	0.20	0.14	0.25
p3	0.22	0.15	0.00	0.15	0.28	0.11
p4	0.37	0.20	0.15	0.00	0.29	0.22
p5	0.34	0.14	0.28	0.29	0.00	0.39
p6	0.23	0.25	0.11	0.22	0.39	0.00

Шаталсан кластерчлал: Group Average


- **Давуу тал**
 - Шуугианд бага өртөмтгий
- **Дутагдалтай тал**
 - Бөмбөрцөг хэлбэртэй кластер луу чиглэсэн

Шаталсан кластерчлал: Ward-ийн арга

- **Ward's method**

$$d(C_m, C_n) = \sum_{x_k \in C_m \cup C_n} d(x_k, \bar{x}(C_m \cup C_n)) - \sum_{x_i \in C_m} d(x_i, \bar{x}(C_m)) - \sum_{x_j \in C_n} d(x_j, \bar{x}(C_n))$$

Ward linkage



$$d(a, b) = \|a - b\|^2$$

ESS - sum of squares error

Алхам бүрт хоёр кластерыг нэгтгэсний дараах кластер доторх нийт хэлбэлзлийн өсөлтийг хамгийн бага байлгах зарчмаар аль кластеруудыг нэгтгэхийг сонгодог.

Шаталсан кластерчлал: Ward-ийн арга

- Шуугианд бага мэдрэмтгий
- Бөмбөрцөг хэлбэртэй кластер луу чиглэсэн
- *K-means* аргыг эхлүүлэхэд хэрэглэгдэж болно
 - Шаталсан кластерчлалаас үүссэн кластер бүрийн өгөгдлийн цэгүүдийн дундажийг тооцоолж центроидыг тодорхойлох
 - Эдгээр центроидууд нь K-means алгоритмын анхны кластерын төвүүд болдог.

Шаталсан кластерчлал: Time and Space requirements

- **Space complexity:** $O(N^2)$
 - N цэгүүдийн тоо
 - Өгөгдлийн цэгүүдийн тоо их байх үед шаталсан кластерын техникт шаардагдах зай маш өндөр байдаг.
- **Time complexity:** $O(N^3)$
 - Цаг хугацааны нарийн төвөгтэй байдал мөн маш өндөр байна.

Нягтад суурилсан аргууд

- *Хуваалтын* ба *шаталсан* аргууд нь бөмбөрцөг хэлбэртэй кластеруудыг олоход зориулагдсан.
 - Дурын хэлбэрийн кластеруудыг олоход бэрхшээлтэй байдаг.




- Дурын хэлбэрийн кластеруудыг олох
 - Кластерууд нь нягтрал багатай мужуудаар бие биеэсээ тусгаарлагдсан өндөр нягтралтай мужууд юм.

DBSCAN: Density-Based Clustering

- Density-Based Spatial Clustering of Applications with Noise


- Нягтад суурилсан кластерийн алгоритм

- Нягт = тодорхой радиус (**Eps-epsilon**) доторх цэгийн тоо
- Хэрэв *Eps* зайн дотор дор хаяж тодорхой тооны цэгүүд (*MinPts*) байгаа бол цэг нь гол цэг (**core point**) юм
 - Эдгээр нь кластерын дотоод хэсэгт байрлах цэгүүд юм.
 - Тухайн цэг өөрөө тоонд багтана.
- Хилийн цэг нь (**border point**) гол цэг биш, харин гол цэгийн ойролцоо байдаг.
- Шуугиан бүхий цэг нь (**noise point**) гол цэг эсвэл хилийн цэг биш аливаа цэгийг хэлнэ.




MinPts = 7

DBSCAN: Core, Border, Noise Points



DBSCAN


MinPts = 3



DBSCAN хэзээ сайн ажилладаг вэ?




Original Points



Clusters (dark blue points indicate noise)


- Янз бүрийн хэлбэр, хэмжээтэй кластеруудыг зохицуулах боломжтой
- Шуугианд (noise) тэсвэртэй

DBSCAN хэзээ сайн ажиллахгүй вэ?




Original Points

- Янз бүрийн нягтралтай байх
- Өндөр хэмжээст өгөгдөл



(MinPts=4, Eps=9.92).



(MinPts=4, Eps=9.75)

DBSCAN: *EPS* болон *MinPts* тодорхойлох

- *MinPts*


- Дүрмээр хамгийн бага *MinPts* утгыг өгөгдлийн багц дахь *d* хэмжээсийн тооноос гаргаж авч болно.

$$\textit{MinPts} \geq d + 1 \quad (d - \textit{dimension})$$

- *MinPts* = 1 байх нь ач холбогдолгүй. Учир нь цэг бүр кластер болно.
- *MinPts* ≤ 2, энэ тохиолдолд шаталсан кластертай ижил (*single link, hierarchical clustering, ε height*)
- Иймээс *MinPts* – н утгыг хамгийн багадаа 3 байхаар сонгох
- Шуугиан ихтэй өгөгдлийн багцын хувьд том утга нь ихэвчлэн илүү сайн байдаг бөгөөд илүү чухал кластеруудыг гаргах болно.
- Дүрмээр *MinPts* = 2·*d*-г ашиглаж болох боловч маш том өгөгдөл, шуугиан ихтэй өгөгдөл эсвэл давхардсан утгуудыг их агуулсан өгөгдөлд илүү том утгыг сонгох шаардлагатай байж болно.

DBSCAN: *EPS* болон *MinPts* тодорхойлох

- ***Epsilon* (ϵ)**
 - Хамгийн ойрын хөрш $k = \text{MinPts} - 1$ хүртэлх зайг эрэмбэлж зураад, дараа нь k -distance график хэрэглэснээр ϵ –н утгыг сонгож болно.
 - Цэг бүрийн хамгийн ойрын k хөрш хүртэлх зайны дунжийг тооцоолох явдал юм.
 - ϵ -ийн сайн утга нь энэ зурган дээр муруйн огцом өөрчлөгдөх цэг
 - Хэрэв ϵ -ийг хэтэрхий жижиг сонгосон бол өгөгдлийн ихэнх хэсэг нь кластер болохгүй.
 - Харин ϵ -ийн хэт өндөр утгатай бол кластерууд нэгдэж, ихэнх объектууд нэг кластерт байх болно.
 - Ерөнхийдөө ϵ -ийн жижиг утгыг илүүд үздэг.



Оновчтой **eps** утга нь
ойролцоогоор **0.15**
зайтай байна.

БАЯРЛАЛАА

Data mining and machine learning

