

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС



Агуулга

- Кластерийн шинжилгээний үнэлгээ

Кластерийн үнэлгээ

- **Кластер шинжилгээ**

- Үүссэн кластеруудын “*goodness*” хэрхэн үнэлэх вэ?
- Бидний олж буй кластерууд нь кластерийн алгоритмаар тодорхойлогддог.
- Тэгвэл яагаад тэднийг үнэлэхийг хүсэж байгаа юм бэ?
 - Шуугиан дахь хэв маягийг олохоос зайлсхийх
 - Кластер үүсгэх алгоритмуудыг харьцуулах
 - Кластеруудын 2 багцыг харьцуулах
 - Хоёр кластерийг харьцуулах


Кластерийн үнэлгээ

- **Кластерийн үнэлгээний гол ажлууд**

- Бүлэглэх хандлагыг үнэлэх/Кластер үүсэх магадал (*Assessing clustering tendency*)
- Өгөгдлийн багц дахь кластерийн тоог тодорхойлох (*Determining the number of clusters in a data set*)
- Кластерийн чанарыг хэмжих (*Measuring clustering quality*)

Бүлэглэх хандлагыг үнэлэх

- Кластерийн шинжилгээ нь өгөгдлийн **жигд бус** тархалтыг шаарддаг.
- Өгөгдлийн багц нь жигд тархалттай өгөгдлөөр үүсгэгдсэн байх магадлалыг тооцно.
- Үүнийг статистик тестээр шалгах боломжтой.
 - *Hopkins Statistic*
- **Тэг таамаглал (H_0)** - Өгөгдлийн цэгүүд нь жигд тархалтаар үүсгэгддэг (утгатай кластер байхгүй гэсэн үг)
- **Өөр таамаглал (H_A)** - Өгөгдлийн цэгүүд нь жигд тархалтгүй (утгатай кластер агуулсан)



Hopkins Statistic

Hopkins statistics: data X vs. random data

1. Select randomly m data points ($p_1, \dots, p_m$) from X
2. Generate randomly m data points ($q_1, \dots, q_m$) from Uniform distribution (with same range as X)
3. Calculate distances:
 - a. $d_X: p_1, \dots, p_m$ to points in X
 - b. $d_U: q_1, \dots, q_m$ to points in X
4. Hopkins statistic:

$$H = \frac{\sum_{i=1}^m d_{U,i}}{\sum_{i=1}^m d_{X,i} + \sum_{i=1}^m d_{U,i}}$$

$H \approx 1$: data highly clustered

$H = 0.5$: data random

$H \approx 0$: data uniform



Threshold = 0.5

Кластерийн тоог тодорхойлох

- Кластерийн оновчтой тоог тодорхойлох 2 үндсэн арга байдаг.
 - Домэйний мэдлэг (*Domain knowledge*)
 - Өгөгдөлд суурилсан арга (*Data-driven approach*)
- **Домэйний мэдлэг**
 - Жишээ нь, цахилдаг цэцгийн өгөгдлийн багц дээр кластер үүсгэх
 - 3 зүйлийн цэцэг (*setosa, virginica, versicolor*)
 - $k = 3$
- **Өгөгдөлд суурилсан арга** - Математик аргууд нь кластерийн оновчтой тоог олоход тусалдаг.
 - Эмпирик арга (*Empirical method*)
 - Тохойн арга (*Elbow method*)
 - Хөндлөн баталгаажуулалтын арга (*Cross validation method*)

Кластерийн тоог тодорхойлох


- Энгийн арга

- Кластерийн тоо $\approx \sqrt{n/2}$ (n цэгтэй өгөгдлийн багцын хувьд)
- Энэ арга нь зөвхөн **анхны үнэлгээ** өгөхөд тохиромжтой бөгөөд өгөгдлийн хэлбэр, түвшин зэргээс хамааран нарийвчлал бага байж болно.

- Elbow method

- $WCSS = \sum (x - c)^2$
 - $WCSS$ - Within-Cluster Sum of Squares
 - x – кластер дахь өгөгдлийн цэг
 - c – кластерийн төв

Elbow Technique



Кластерийн тоог тодорхойлох

- **Cross validation method**


- Өгөгдлийн багцыг m хэсэгт хуваах
- Кластерийн загварыг гаргахад $m - 1$ хэсгийг ашиглах
- Кластерийн чанарыг шалгахад үлдсэн хэсгийг хэрэглэх
 - Загвар нь туршилтын багцад хэр нийцэж байгааг хэмжихийн тулд
 - Туршилтын багцын цэг бүрийн хувьд хамгийн ойрхон төвийг олох
 - Туршилтын багц дахь бүх цэгүүд болон хамгийн ойрын төвүүдийн хоорондох квадрат зайны нийлбэрийг олох.
- Ямар ч k -н хувьд ($k > 0$), дээрх үйлдлийг m удаа давтах
- Чанарын хэмжүүрүүдийн дунджаар ерөнхий чанарыг тооцоолно.
- Ялгаатай k -н хувьд тухайн өгөгдөлд хамгийн сайн ерөнхий чанарын үзүүлэлттэй байгаа k -г сонгох

Кластерийн чанарыг хэмжих

- 2 арга байдаг: Гадаад (*extrinsic*) ба дотоод (*intrinsic*)
- *Extrinsic*: **supervised** → ground truth is available
 - Кластерын чанарын тодорхой хэмжүүрийг ашиглан кластерыг үнэн утгатай харьцуулах
 - Жишээ нь: *BCubed precision, BCubed recall metrics*
- *Intrinsic*: **unsupervised** → ground truth is unavailable
 - Кластерууд хэр сайн тусгаарлагдсан, мөн кластерууд хэр нягтаршилтай байгааг харгалзан кластерын сайн байгааг (*goodness*) үнэлэх
 - Жишээ нь: *Silhouette coefficient*


Supervised Measures

- Кластерын чанарын Q хэмжүүр нь дараах дөрвөн үндсэн шалгуурыг хангасан тохиолдолд үр дүнтэй байдаг.
 - Кластерийн нэг төрлийн байдал (*Cluster Homogeneity*)




Supervised Measures

- Кластерын чанарын Q хэмжүүр нь дараах дөрвөн үндсэн шалгуурыг хангасан тохиолдолд үр дүнтэй байдаг.
 - Кластерийн бүрэн байдал (*Cluster Completeness*)




Supervised Measures

- Кластерын чанарын Q хэмжүүр нь дараах дөрвөн үндсэн шалгуурыг хангасан тохиолдолд үр дүнтэй байдаг.
 - **Өөдөсний уут (*Rag Bag*)**
 - Эмх замбараагүй кластерт эмх замбараагүй байдлыг нэвтрүүлэх нь цэвэр кластерт эмх замбараагүй байдлыг нэвтрүүлэхээс бага хор хөнөөлтэй байдаг.




Supervised Measures

- Кластерын чанарын Q хэмжүүр нь дараах дөрвөн үндсэн шалгуурыг хангасан тохиолдолд үр дүнтэй байдаг.
 - **Кластерийн хэмжээ, тоо хэмжээ (*Clusters size vs. quantity*)**
 - Том кластер дахь жижиг алдаа нь жижиг кластер дахь олон тооны жижиг алдаанаас илүү байх ёстой.
 - Жижиг кластерийг хэсэг болгон хуваах нь том кластерийг хэсэг болгон хуваахаас илүү хор хөнөөлтэй.



Supervised Measures

- Кластерийн чанарын олон хэмжүүр нь эдгээр 4 шалгуурын заримыг хангадаг.
- Эдгээр 4 шалгуурын хангасан хэмжүүр
 - *BCubed precision*
 - *BCubed recall*



Supervised Measures

$$\text{Correctness}(\mathbf{o}_i, \mathbf{o}_j) = \begin{cases} 1 & \text{if } L(\mathbf{o}_i) = L(\mathbf{o}_j) \Leftrightarrow C(\mathbf{o}_i) = C(\mathbf{o}_j) \\ 0 & \text{otherwise.} \end{cases}$$

- *BCubed precision*

$$\text{Precision BCubed} = \frac{\sum_{i=1}^n \frac{\sum_{\mathbf{o}_j: i \neq j, C(\mathbf{o}_i) = C(\mathbf{o}_j)} \text{Correctness}(\mathbf{o}_i, \mathbf{o}_j)}{\|\{\mathbf{o}_j | i \neq j, C(\mathbf{o}_i) = C(\mathbf{o}_j)\}\|}}{n}.$$

- *BCubed recall*


$$\text{Recall BCubed} = \frac{\sum_{i=1}^n \frac{\sum_{\mathbf{o}_j: i \neq j, L(\mathbf{o}_i) = L(\mathbf{o}_j)} \text{Correctness}(\mathbf{o}_i, \mathbf{o}_j)}{\|\{\mathbf{o}_j | i \neq j, L(\mathbf{o}_i) = L(\mathbf{o}_j)\}\|}}{n}.$$

Unsupervised Measures: Cohesion & Separation


- **Cluster Cohesion:** Кластер дахь объектууд хоорондоо хэр нягт холбоотой болохыг хэмждэг.
- **Cluster Separation:** Кластер нь бусад кластеруудаас хэр ялгаатай эсвэл сайн тусгаарлагдсан болохыг хэмжинэ.
- **Silhouette коэффициент**
 - *cohesion* болон *separation* хослуулдаг
 - *individual points, clusters, clusterings*

$$cohesion(C_i) = \sum_{\substack{\mathbf{x} \in C_i \\ \mathbf{y} \in C_i}} proximity(\mathbf{x}, \mathbf{y})$$

$$separation(C_i, C_j) = \sum_{\substack{\mathbf{x} \in C_i \\ \mathbf{y} \in C_j}} proximity(\mathbf{x}, \mathbf{y})$$



(a) Cohesion.



(b) Separation.

Unsupervised measures: Silhouette Coefficient

- **Individual point, i**


- $a = i$ цэгээс түүний кластер дахь бусад бүх цэгүүд хүртэлх дундаж зайг тооцоол
- $b = \min(i$ цэгээс бусад кластер бүр дэх бүх цэгүүд хүртэлх дундаж зайг тооцоол)
- Тухайн цэгийн ***silhouette coefficient***

$$s = (b - a) / \max(a, b)$$

- Утга нь -1 болон 1 хооронд хэлбэлзэж болно.
- Ихэвчлэн 0 – 1 хооронд байдаг.
- 1-тэй ойр байх тусмаа илүү сайн.

- ***cluster*** эсвэл ***clustering***-н хувьд

- *Кластерын хувьд* кластерын бүх цэгүүдэд ***silhouette coefficient*** тооцоолох шаардлагатай бөгөөд дунджийг авна.
- *Кластерийн багцын хувьд* бүх цэгүүдэд ***silhouette coefficient*** тооцоолох шаардлагатай бөгөөд дунджийг авна.
- Утга нь -1-ээс 1-ийн хооронд байж болох ба утга нь өндөр байх тусам сайн байх болно



Spectral clustering

(Partitioning methods)

Spectral clustering

- Өгөгдлийн шугаман бус нарийн төвөгтэй бүтцийг барьж чадна.
 - Өгөгдлийг хувийн вектор (*eigenvectors*) ашиглан бага хэмжээст орон зайд буулган хувиргана.
 - Анхны шинж чанарын орон зайд салгах боломжгүй кластеруудыг тодорхойлж чадна.
- Янз бүрийн хэлбэртэй өгөгдөлд үр дүнтэй.





Figure 1 Comparison of K-means and spectral clustering

- Шуугиан болон хэвийн бус утга (*outlier*) зэрэгт тэсвэртэй.
 - Бага хэмжээст орон зайд ажилладаг тул шуугиан, хол байгаа өгөгдлийн цэгүүд кластерийн үр дүнд үзүүлэх нөлөөллийг багасгана.

Spectral clustering

1. Ойр байдлын матриц
2. Лапласын матриц
3. Хувийн утга болон хувийн вектор
4. Өгөгдлийн цэгүүдийг кластерт хуваарилах




Spectral clustering

- $\{x_1.. x_n\}$ өгөгдлийн цэгүүдийн багц
- Хос цэгүүдийн *ижил төстэй байдал* (s_{ij}) эсвэл *зайг* (d_{ij}) ашиглан *ижил төстэй байдлын граф* эсвэл *зайн граф* үүсгэж болно.
- Дараах стратегиудын аль нэгийг ашиглаж болно.
 - **ϵ - neighborhood graph**
 - $d_{ij} < \epsilon$ байх бүх v_i болон v_j оройн цэгүүдийг холбох
 - **k-nearest neighbor graph**
 - V_i -г хамгийн ойрын k хөршүүдтэй нь холбох
 - **Fully connected graph**
 - Бүх хосуудын хувьд s_{ij} ижил төстэй байдлыг ашиглах

Spectral clustering

Unnormalized Graph Laplacian example



Example graph

Adjacency matrix(W)

	1	2	3	4
1	0	1	1	0
2	1	0	1	0
3	1	1	0	1
4	0	0	1	0

Degree matrix (D)

	1	2	3	4
1	2	0	0	0
2	0	2	0	0
3	0	0	3	0
4	0	0	0	1


Laplacian ($L=D-W$)

	1	2	3	4
1	2	-1	-1	0
2	-1	2	-1	0
3	-1	-1	3	-1
4	0	0	-1	1

Лапласын матрицын төрлүүд


- Unnormalized Laplacian
- Normalized Laplacian
- Symmetric normalized Laplacian

Spectral clustering



Spectral clustering

- Илүү бага хэмжээст төлөөллийг бий болгох
 - $Y = [v_1, v_2, \dots, v_k]$
 - Энэ матриц нь $n \times k$ хэмжээстэй байх ба n нь өгөгдлийн цэгүүдийн тоо, k нь хүссэн кластеруудын тоо юм.
- Clustering
 - Y матрицын мөрүүдэд кластерийн алгоритмыг хэрэглэнэ.
 - Жишээ нь: K-means
 - Энэ алхам нь өгөгдлийн цэгүүдийн бага хэмжээст орон зай дахь дүрслэлд үндэслэн k кластерт хуваадаг.



БАЯРЛАЛАА

Data mining and machine learning

