

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба
машин сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС





Агуулга

Өгөгдөл олборлолтын үндэс

Өгөгдөл олборлолтын сорилтууд

Өгөгдөл олборлолтын даалгаврууд



Их хэмжээний өгөгдлийн эрин үе

"We are living in the information age"

"We are actually living in the data age"

Бид мэдээллийн эрин үед биш, харин **өгөгдлийн эрин үед** амьдарч байна. Өнөөдөр бидний үйлдэж буй бүх үйлдэл өгөгдөл үүсгэж, цуглуулж байна.

Их хэмжээний өгөгдөл

Өгөгдлийн асар их өсөлт

Өгөгдлийн хэмжээ терабайтаас петабайт хүртэл өсч байна. Энэ нь өгөгдөл цуглуулах автомат хэрэгслүүд, өгөгдлийн сангийн системүүд, компьютержсэн нийгмийн үр дүн юм.

Их хэмжээний өгөгдлийн гол эх сурвалжууд

- **Бизнес:** Веб, цахим худалдаа, гүйлгээ, хувьцааны зах зээл
- **Шинжлэх ухаан:** Алсын мэдрэгч, биоинформатик, шинжлэх ухааны симуляци
- **Нийгэм:** Мэдээ, дижитал камер, сошиал медиа

❑ **Гол асуудал:** Өгөгдөлд живж байгаа боловч мэдлэгээр дутагдаж байна. Их өгөгдлөөс хэрэгцээтэй мэдээллийг гаргаж авах автоматжуулсан хэрэгслүүд маш их хэрэгцээтэй болсон.


Unit	Value
Kilobytes (KB)	1,000 bytes
Megabytes (MB)	1,000 Kilobytes
Gigabytes (GB)	1,000 Megabytes
Terabytes (TB)	1,000 Gigabytes
Petabytes (PB)	1,000 Terabytes




Cyber Security




E-Commerce




Traffic Patterns



Social Networking: Twitter



Sensor Networks



Computational Simulations

Өгөгдөл олборлолтын шаардлага

Их хэмжээний өгөгдлийн цуглуулга бий болсон нь **өгөгдөл олборлолт** (Data Mining) гэсэн шинэ салбарыг бий болгоход хүргэсэн.

Өгөгдөл олборлолт гэж юу вэ?


Их хэмжээний өгөгдлийн цуглуулгыг мэдлэг болгон хувиргах автоматжуулсан шинжилгээ юм.

Энэ нь залуу, эрчимтэй хөгжиж буй салбар бөгөөд бизнес, шинжлэх ухаан, нийгмийн олон салбарт ашиглагдаж байна.

Гол санаа

Data mining - өгөгдлөөс мэдлэг хайх (searching for knowledge/interesting patterns in data).

"The world is data rich but information poor" - Дэлхий өгөгдлөөр баялаг боловч мэдээллээр ядуу.



Нийгэмд тулгарч буй томоохон асуудлуудыг шийдвэрлэх боломжууд


Өгөгдөлд мэдээлэл ил тод харагдахгүй, ихэвчлэн "нуугдсан" байдаг. Өгөгдлийн ихэнхийг огт шинжилдэггүй.

Өгөгдөл олборлолт нь эдгээр асуудлуудыг шийдвэрлэхэд тусалдаг.



Эрүүл мэндийн тусламж

Үйлчилгээг сайжруулах,
зардлыг бууруулах



Уур амьсгалын өөрчлөлт

Нөлөөллийг урьдчилан
таамаглах



Ногоон эрчим хүч

Эрчим хүчний эх үүсвэр
хайх



Хөдөө аж ахуй

Үйлдвэрлэл нэмэгдүүлэх,
өлсгөлөн бууруулах

Өгөгдөл олборлолт гэж юу вэ?



Олон тодорхойлолт байдаг

Өгөгдлөөс **далд, урьд өмнө мэдэгдээгүй, ашиг тустай** байж болох сонирхолтой загвар эсвэл мэдлэгийг гаргаж авах

Их хэмжээний өгөгдлөөс **утга бүхий загварууд, хэрэгцээтэй мэдээллийг** гаргаж авахын тулд автомат эсвэл хагас автомат аргаар хайх, дүн шинжилгээ хийх

Өөр нэршил

- **DM** = Knowledge mining from data
- **DM** = Knowledge discovery from data (KDD)

Эдгээр нэр томъёо нь ижил утгатай бөгөөд өгөгдлөөс ашигтай мэдлэг, мэдээллийг олж авах үйл явцыг илэрхийлдэг.

Өгөгдөл олборлолт гэж юу вэ?

Мэдээллийг илрүүлэх бүх ажлыг өгөгдөл олборлолт гэж үздэггүй. Энэ нь чухал ялгаа юм.

Өгөгдөл олборлолт БИШ жишээ

Өгөгдлийн сангийн хайлт

Өгөгдлийн сан удирдах систем ашиглан бүртгэл хайх

Интернет хайлт

Хайлтын системд асуулга ашиглан тодорхой веб хуудсуудыг олох

Лавлах үйлчилгээ

Утасны лавлахаас утасны дугаарыг хайж олох

Эдгээр нь өгөгдөл *хайлт* боловч *олборлолт* биш. Шинэ мэдлэг, хэв маяг илрүүлдэггүй.



Information Retrieval

Өгөгдөл олборлолтын жишээ

Нэрийн түгээлт

Зарим нэрс АНУ-ын тодорхой байршилд илүү түгээмэл байдаг.

Жишээ нь:


O'Brien, O'Rurke, O'Reilly...
Boston хотод илүү түгээмэл.

Баримт бүлэглэх

Хайлтын системээс буцаасан ижил төстэй баримт бичгүүдийг агуулгын дагуу бүлэглэх, хэв маягийг илрүүлэх.

Эдгээр нь өгөгдлөөс **шинэ хэв маяг, хамаарал** илрүүлж байна.

Өгөгдөл олборлолт



Өгөгдөл олборлолт



Өгөгдлөөс мэдлэг илрүүлэх үйл явц нь дараах үе шатуудаас бүрддэг. Энэ Энэ нь давтагдах процесс бөгөөд үе шат бүр өмнөх үе шатанд буцах шаардлагатай байж болно.

1

Домэйнийг ойлгох

Асуудлын салбар, зорилго тодорхойлох

2

Өгөгдлийг бэлтгэх

Цэвэрлэх, нормчлох, дутуу утгыг шийдэх

3

Шинж чанар боловсруулах

Feature engineering & selection

4

Олборлолт хийх

Алгоритм сонгох, гүйцэтгэл үнэлэх

5

Үнэлгээ

Үр дүнг тайлбарлах, хэрэглэх

Өгөгдөл олборлолтын гарал үүсэл

Өгөгдлийн дараах шинж чанаруудаас болж уламжлалт арга техник нь тохиромжгүй байж болно:




Судлаачид төрөл бүрийн өгөгдөлтэй ажиллах боломжтой илүү үр ашигтай, өргөтгөх боломжтой хэрэгслүүдийг хөгжүүлэхэд анхаарлаа хандуулж эхэлсэн. Эдгээр нь өмнө нь хэрэглэж байсан арга зүй, алгоритм дээр суурилсан.

Statistics

Тоон мэдээлэлд дүн шинжилгээ хийх статистик аргууд. Өгөгдлийн багц доторх хэв маяг, чиг хандлага, харилцааг тодорхойлоход тусалдаг.

Machine Learning/AI

Өгөгдлөөс автоматаар суралцах технологи. Pattern recognition - Хэв маяг таних аргууд.



Өгөгдөл олборлолтод хамаарах бусад салбарууд

Бусад салбарууд

Databases


Үүрэг: Efficient storage, indexing, and query processing - Өгөгдлийг үр ашигтай хадгалах, индексжүүлэх, асуулга боловсруулах

Parallel Computing

Үүрэг: Өндөр гүйцэтгэлтэй компьютерийн техникүүд. Өгөгдлийн багцын асар том хэмжээг шийдэх.

Distributed Computing

Үүрэг: Өгөгдлийг нэг байршилд цуглуулах боломжгүй үед тархсан системүүдээр дамжуулан өгөгдөл боловсруулах.



Database Technology, Parallel Computing, Distributed Computing

Өгөгдөл олборлолтод хамаарах бусад салбарууд

Өгөгдөл олборлолт нь дээрх ойлголт, аргуудад тулгуурласан **олон талт салбар** юм.

Эдгээр бүрэлдэхүүн хэсгүүдийн нэгдмэл байдал нь өгөгдөл олборлогчдод асар том, нарийн төвөгтэй өгөгдлийн багцаас үнэ цэнэтэй мэдлэгийг гаргаж авах боломж олгодог.

Өгөгдөл олборлолтын даалгаврууд

Өгөгдлийг олборлох даалгавар нь зорилгоосоо хамааран хоёр үндсэн төрөлд хуваагддаг. Энэ ангилал нь өгөгдөл олборлолтын бүх үйл ажиллагааг тодорхойлдог суурь хүрээ юм.

Урьдчилан таамаглах аргууд

Prediction Methods


Түүхэн өгөгдөлд тулгуурлан ирээдүйн үйл явдал, чиг хандлагын талаар үнэн зөв таамаглал гаргах явдал юм.

Бусад шинж чанаруудын утгууд дээр үндэслэн тодорхой шинж чанарын утгыг урьдчилан таамаглах.

- **Classification** - Ангилал
- **Regression** - Регресс

Таамаглагдаж буй хувьсагчийг: *зорилтот* эсвэл *хамааралтай хувьсагч* гэнэ.

Таамаглалыг гаргахад хэрэглэгдсэн хувьсагчийг: *тайлбарлагч* эсвэл *биеэ даасан хувьсагч*



Дүрслэлийн аргууд


Description Methods

Өгөгдлийг дүрсэлсэн, хүний тайлбарлаж болох загварыг олох. Өгөгдлийн доторх хэв маяг, холбоо, шинж чанарыг нэгтгэн дүгнэхэд чиглэдэг.

- **Clustering** - Бүлэглэх
- **Association Rules** - Холбоо хамаарлын дүрэм
- **Anomaly Detection** - Хазайлт илрүүлэх

Өгөгдөл олборлолтын үндсэн даалгаврууд

Энэ бүлэгт бид өгөгдөл олборлолтын үндсэн даалгавруудыг авч үзэх болно. Даалгавар бүр өөрийн гэсэн зорилго, хэрэглээтэй. Зарим нь ирээдүйг таамаглахад, зарим нь өгөгдлийн бүтцийг ойлгоход чиглэдэг.



Predictive Modeling - Урьдчилан таамаглах загварчлал

Predictive Modeling нь өгөгдлийн загварыг бий болгож, энэ загварыг ашиглан шинэ өгөгдөлд урьдчилан таамаглал гаргах үйл явц юм.

Predictive Modeling гэж юу вэ?

Түүхэн өгөгдлөөс суралцаж, ирээдүйн үйл явдлыг таамаглах загвар бүтээх. Энэ нь **supervised learning** (хяналттай сургалт) гэж нэрлэгддэг.

Үндсэн ойлголтууд

- **Training data:** Загварыг сургахад ашигладаг түүхэн өгөгдөл
- **Features:** Таамаглахад ашигладаг шинж чанарууд
- **Target variable:** Таамаглагдаж буй хувьсагч
- **Model:** Шинж чанар болон зорилтот хувьсагчийн хоорондын харилцааг илэрхийлсэн загвар



Зорилго нь зорилтот хувьсагчийн таамагласан болон бодит утгуудын хоорондох алдааг багасгах загварыг сурах явдал юм.

Predictive Modeling: Төрлүүд

Урьдчилан таамаглах загварчлалын хоёр үндсэн төрлийн даалгавар байдаг. Зорилтот хувьсагчийн төрлөөс хамаарч ялгаатай аргууд ашиглагддаг.

Classification - Ангилал

Веб хэрэглэгч онлайн номын дэлгүүрээс худалдан авалт хийх эсэхийг урьдчилан таамаглах.

Зорилтот хувьсагч: Хоёртын утгатай (discrete target variables, тасралттай). Жишээ нь: Тийм/Үгүй, Ангилал A/B/C.

Жишээ даалгаврууд:

- Имэйл спам эсэхийг тодорхойлох
- Өвчтөнд өвчин байгаа эсэхийг оношлох
- Зээлийн төлбөрийн чадварыг үнэлэх

Regression - Регресс

Хувьцааны ирээдүйн үнийг урьдчилан таамаглах.

Зорилтот хувьсагч: Тасралтгүй тоон утга (continuous target variables). Жишээ нь: Үнэ, температур, хувь хэмжээ.

Жишээ даалгаврууд:

- Орон сууцны үнийг таамаглах
- Борлуулалтын хэмжээг урьдчилан харах
- Температурын өөрчлөлтийг таамаглах

Classification vs Regression: Үндсэн ялгаа



Гаралтын төрөл

Classification: Тасралттай ангиллын шошго (spam/not spam, positive/negative)

Regression: Тасралтгүй тоон утга (байшингийн үнэ, борлуулалтын хэмжээ)

Даалгаврын мөн чанар

Classification: Урьдчилан тодорхойлсон категориудад тохиолдлуудыг хуваарилах

Regression: Тоон утгыг таамаглах, тооцоолох

Үнэлгээний арга

Classification: Нарийвчлал (accuracy), precision, recall, эсвэл F1 F1 score

Regression: Mean squared error (MSE) эсвэл mean absolute error (MAE)

Clustering - Бүлэглэх

Одоо бид дүрслэлийн аргуудруу шилжиж байна. Clustering нь өгөгдлийн бүтцийг илрүүлэх чухал арга юм.


Clustering гэж юу вэ?

Объектуудын бүлгийг олох үйл явц. Бүлэг дэх объектууд нь хоорондоо ижил төстэй (эсвэл холбоотой), бусад бүлгийн объектуудаас ялгаатай (эсвэл хамааралгүй) байна.

Хоорондоо нягт холбоотой бүлгүүдийг олохыг эрэлхийлдэг. Энэ нь **unsupervised learning** (хяналтгүй сургалт) гэж нэрлэгддэг.

Үндсэн зарчим

- **Intra-cluster similarity:** Нэг бүлэг доторх объектууд ижил төстэй байх
- **Inter-cluster dissimilarity:** Өөр бүлгийн объектууд ялгаатай байх



Clustering: Хэрэглээ

Ойлголт




Өгөгдлийн бүтцийг ойлгоход тусалдаг:

- **Баримт бичгийн бүлэглэл:** Холбогдох баримт бичгүүдийг үзэхийн тулд бүлэглэх
- **Био-информатик:** Ижил үйл ажиллагаатай ген болон уургуудыг бүлэглэх
- **Санхүү:** Ижил үнийн хэлбэлзэлтэй хувьцаануудыг бүлэглэх

Дүгнэлт

Их хэмжээтэй өгөгдлийн багцуудын хэмжээг бууруулах:

- **Өгөгдлийн шахалт:** Кластерын төлөөлөгч утгыг ашиглах
- **Хялбарчлал:** Нарийн төвөгтэй өгөгдлийг ойлгомжтой болгох



Жишээ: Генийн илэрхийллийн өгөгдлийн кластер шинжилгээ (Courtesy: Michael Eisen)

Association Rules - Холбоо хамаарлын дүрэм

Association rule нь их хэмжээний өгөгдөл дахь хувьсагчдын хоорондын холбоо, хамаарлыг илрүүлэх арга юм.



Association Rule гэж юу вэ?

Бусад зүйлсийн тохиолдол дээр үндэслэн тухайн зүйл тохиолдохыг урьдчилан таамаглах хамаарлын дүрмийг гаргах арга.

Жишээ: Кассын цэг дээрх борлуулалтын мэдээлэл

Хэрэглэгч хамт худалдаж авдаг бараанууд хоорондын хамаарлыг олох:

1

$\{\text{Diaper}\} \rightarrow \{\text{Milk}\}$

Живх худалдаж авбал сүү авах магадлал өндөр

2

$\{\text{Milk}\} \rightarrow \{\text{Coke}\}$

Сүү авбал кока-кола авах магадлал өндөр

3

$\{\text{Diaper, Milk}\} \rightarrow \{\text{Beer}\}$

Живх болон сүү хамт авбал шар айраг авах магадлал өндөр

Association Rules: Хэрэглээнүүд

Холбоо хамаарлын дүрэм нь олон төрлийн салбарт ашиглагддаг. Энэ нь нуугдсан хэв маягийг илрүүлэх хүчирхэг хэрэгсэл юм.



Зах зээлийн сагсны шинжилгээ

Борлуулалтыг дэмжих, тавиурын менежмент, бараа материалын менежментэд дүрмүүдийг ашигладаг. Ямар бараа хамт зарагддагийг мэдэх нь маркетинг, дэлгүүрийн зохион байгуулалтад тусалдаг.



Цахилгаан холбооны дохиоллын оношилгоо

Ижил хугацаанд байнга тохиолддог дохиоллуудын хослолыг олоход дүрмүүдийг ашиглагддаг. Сүлжээний асуудлыг урьдчилан таних, шийдвэрлэхэд тусалдаг.



Эмнэлгийн мэдээлэл зүй

Тодорхой өвчинтэй холбоотой өвчтөний шинж тэмдэг, шинжилгээний үр дүнгийн хослолыг олоход дүрмийг ашигладаг. Оношлогоо, эмчилгээг сайжруулахад тусалдаг.

Anomaly Detection - Хазайлт илрүүлэх

Anomaly Detection гэж юу вэ?

Шинж чанар нь бусад өгөгдлөөс эрс ялгаатай ажиглалтыг тодорхойлох ажил юм. Эдгээр хэвийн бус цэгүүдийг *anomalies*, *outliers*, эсвэл *exceptions* гэж нэрлэдэг.

Яагаад чухал вэ?

Хэвийн бус өгөгдлийн цэгүүд нь ихэвчлэн:

- Ямар нэгэн сонирхолтой, чухал үйл явдлыг илтгэдэг
- Асуудал, буруу өгөгдлийг илэрхийлдэг
- Ердийн өгөгдлөөс илүү үнэ цэнэтэй мэдээлэл агуулдаг



▢ "One person's noise is another person's signal" - Нэгний хувьд шуугиан нь нөгөөгийн хувьд чухал дохио байж болно.

Anomaly Detection: Хэрэглээнүүд



Зээлийн картын залилан илрүүлэх

Хэвийн бус гүйлгээний хэв маягийг илрүүлэх. Жишээ нь: хэт их зардал, ердийн бус байршил, ердийн бус цаг.



Сүлжээний халдлагыг илрүүлэх

Компьютерийн сүлжээнд хэвийн бус үйл ажиллагааг илрүүлэх. Кибер халдлага, вирус, хакерын үйл ажиллагааг таних.



Мэдрэгчийн сүлжээ

Хяналт, тандалт хийх зорилгоор мэдрэгчийн сүлжээнээс хэвийн бус үйлдлийг тодорхойлох. Байгаль орчны хяналт, үйлдвэрийн аюулгүй байдал.



Байгаль орчны хяналт

Дэлхийн ойн бүрхэвчийн өөрчлөлтийг илрүүлэх. Хиймэл дагуулын зургаас ой сэргэлт, ойн хомсдолыг илрүүлэх.

Дүгнэлт:



Юу сурсан бэ?

1 Өгөгдөл олборлолтын үндэс

Их хэмжээний өгөгдлөөс мэдлэг олж авах үйл явц. Өгөгдлөөр баялаг боловч мэдлэгээр дутагдаж байна.

2 Сорилтууд

Scalability, өндөр хэмжээст байдал, нэг төрлийн бус өгөгдөл, тархсан өгөгдөл зэрэг сорилтууд.

3 Даалгаврууд

Үндсэн даалгавар: Predictive Modeling, Clustering, Association Association Rules, Anomaly Detection.

4 Хэрэглээ

Бизнес, шинжлэх ухаан, нийгмийн олон салбарт өргөн хэрэглээтэй.

БАЯРЛАЛАА

Data mining and machine learning

