

DATA MINING & MACHINE LEARNING

Өгөгдөл олборлолт ба машин
сургалт
S.DMM213

Б.Золзаяа, Ph.D
Мэдээллийн технологийн тэнхим
МХТС, ШУТИС





Агуулга

01

Атрибут болон объектууд

Өгөгдлийн үндсэн бүрэлдэхүүн хэсгүүдийг ойлгох

02

Өгөгдлийн төрлүүд

Янз бүрийн өгөгдлийн төрлүүд болон тэдгээрийн онцлог

03

Өгөгдлийн статистикийн үндсэн тодорхойлолтууд

Өгөгдөл судлах болон шинжлэх аргууд

Өгөгдөл гэж юу вэ?

Өгөгдөл бол өдөр тутмын үйл ажиллагаагаар үүсэж байгаа баримт, мэдээнүүд.

Өгөгдөл нь **объектууд** болон түүний **атрибутуудын** цуглуулга юм.

Атрибутууд (Attributes)

Attribute бол объектуудын шинж чанар. Жишээ нь: хүний нүүр царай, температур гэх мэт.

- *variable, field, characteristic, dimension, feature*

Объектууд (Objects)

Object нь тухайн объектын шинж чанарыг илэрхийлэх атрибутуудын цуглуулга.

- *record, point, case, sample, entity, instance*

Өгөгдлийн багц (Data set)

Өгөгдлийн объектуудын цуглуулга юм.

Attributes

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Objects

[illegible]

Хувьсагчдыг ялгаатай ангилал руу тэмдэглэхэд ашиглагддаг хуваарь юм.

- **Үсний өнгө:** хар, хүрэн, шар, улаан, саарал, цагаан
- **Гэрлэлтийн байдал:** ганц бие, гэрлэсэн, салсан, бэлэвсэн

Нэрлэсэн атрибутын утга "юмны нэр" байдаг ч үүнийг тоогоор илэрхийлэх боломжтой (хар – 0, хүрэн – 1...).

Гэвч ийм тохиолдолд тоонууд нь тоон хэлбэрээр ашиглахад зориулагдаагүй.

Атрибутын төрлүүд: Хоёртын (Binary)

Хоёртын атрибут

Хоёртын атрибут нь зөвхөн хоёр ангилал буюу төлөвтэй нэрлэсэн атрибут (nominal) юм: 0 эсвэл 1, true эсвэл false.

Тэгш хэмтэй (Symmetric)

Хоёртын атрибут нь хоёр төлөв нь ижил жинтэй байвал **ТЭГШ ХЭМТЭЙ** байна.

Тэгш хэмт бус (Asymmetric)

Хоёртын атрибут нь мөн **ТЭГШ ХЭМТ БУС** шинж чанартай байдаг.

Атрибутын төрлүүд: Дараалсан (Ordinal)

Дараалсан атрибутын тодорхойлолт

Хувьсагч бүрийн хоорондын ялгаанаас гадна дарааллыг харуулахад ашигладаг хэмжүүрийн хуваарь.

Утгуудын хооронд утга учиртай дараалал (order) эсвэл зэрэглэл (rank) байдаг боловч дараалсан утгуудын хоорондох хэмжээ нь тодорхойгүй байна.

Жишээнүүд

- Дүн: A, A-, B+, B, B-, C+, C...
- Албан тушаал: Туслах, багш, ахлах багш, дэд профессор, профессор

Чанарын атрибутууд (Qualitative)

Nominal, binary, ordinal attributes нь **qualitative** буюу чанарын шинж чанартай байдаг.


Чанарын шинж чанартай атрибутууд нь бодит хэмжээ эсвэл тоо хэмжээг өгөхгүйгээр объектын шинж чанарыг тодорхойлдог.

Ийм чанарын шинж чанаруудын утгууд нь ихэвчлэн категориудыг төлөөлдөг үгс юм.

Жишээ: Үйлчилгээний сэтгэл ханамжийн судалгаа

Асуулт: Манай үйлчилгээнд хэр сэтгэл хангалуун байна вэ?

1. Маш сэтгэл ханамжгүй
2. Сэтгэл ханамжгүй
3. Төвийг сахисан
4. Сэтгэл ханамжтай
5. Маш сэтгэл ханамжтай



Тоон атрибутууд (Numeric Attributes)

Тоон шинж чанар

Numeric attribute нь **quantitative** буюу тоон хэмжээстэй.

Энэ нь бүхэл тоогоор эсвэл бодит утгаар илэрхийлэгдсэн хэмжигдэхүйц хэмжигдэхүүн юм.

Интервалын хуваарь

Interval-scaled атрибутууд нь зэргэлдээх цэгүүдийн хооронд тэнцүү хэмжээний интервалтай масштабээр хэмжигддэг.

Харьцааны хуваарь

Ratio-scaled атрибутууд нь жинхэнэ тэг цэг бүхий тоон шинж чанар юм.

Интервалын хуваарьтай атрибут (Interval-Scaled)

Утгууд: Дараалсан, эерэг, 0, эсвэл сөрөг байж болно.

Ийм шинж чанарууд нь утгуудын зэрэглэлийг (rank) өгөхөөс гадна утгуудын хоорондын ялгааг харьцуулж, тоон байдлаар тодорхойлох боломжийг олгодог.

Жишээнүүд

Температур: 20°C болон 15°C -ийн зөрүү нь 5°C

Хуанлийн огноо: 2002 болон 2010 оны хооронд 8 жилийн зөрүү

 **Анхааруулга:** Цельсийн болон Фаренгейтийн температурт жинхэнэ тэг цэг байдаггүй. 0°C эсвэл 0°F нь "температургүй" гэсэн үг биш юм. Утгыг харьцаагаар ярьж болохгүй.

Харьцааны хуваарьтай атрибут (Ratio-Scaled)



Жинхэнэ тэг цэг

Харьцааны хуваарьтай шинж чанар нь **жинхэнэ тэг цэг** бүхий тоон шинж чанар. Хэмжилт нь харьцаагаар хэмжигддэг.



Эрэмбэлэгдсэн

Утгууд нь эрэмбэлэгдсэн бөгөөд утгуудын ялгаа, mean, median, mode зэргийг тооцоолох боломжтой.



Үржвэр боломжтой

Утга нь өөр утгын үржвэр байж болно. Бүх тооны үйлдлүүд хүчин төгөлдөр.

Кельвин (K) температурын хуваарь:
 $0^{\circ}\text{K} = -273.15^{\circ}\text{C}$

- **Count attributes:** ажлын туршлагын жил, баримт бичиг дэх үгийн тоо
- **Хэмжилтийн атрибутууд:** жин, өндөр, мөнгөн дүн

Дискрет атрибут (Discrete Attribute)

Үндсэн тодорхойлолт



Дискрет атрибут нь ихэвчлэн бүхэл тоогоор илэрхийлэгдэх боловч заавал тоон утгатай байх албагүй. Ийм атрибутууд нь салангид, тоолж болохуйц утгуудыг авдаг.

Тоон биш утга



Дискрет атрибут нь тоон биш утгатай байж болно. Жишээлбэл, *hair color*, *medical test result* зэрэг нь боломжит утгуудын тоо хязгаарлагдмал тул дискрет шинж чанарт тооцогдоно.

Тоон утга



Хоёртын атрибутууд: 0 ба 1. Нас атрибут: 0-110 хүртэлх утгууд.

Тоолж болохуйц хязгааргүй



Дискрет атрибут нь **хязгаарлагдмал** эсвэл **тоолж болохуйц хязгааргүй** (*countably infinite*) олон утгатай байж болно. Тоолж болохуйц хязгааргүй гэдэг нь боломжит утгуудын багц хязгааргүй боловч тэдгээрийг натурал тоонуудтай нэг нэгээр нь харгалзуулах боломжтойг илэрхийлнэ. (Жишээ нь: customer ID, Zip code).

Үргэлжилсэн атрибут (Continuous Attribute)

Тодорхойлолт

Өгөгдсөн мужийн дотор хязгааргүй олон утгыг авч болох хувьсагч. Ихэвчлэн бодит тоон хувьсагч байдлаар дүрслэгддэг.

Жишээнүүд

- Температур (temperature)
- Өндөр (height)
- Жин (weight)

❏ **Практикт анхаарах зүйл:** Бодит утгыг хэмжих, хадгалахдаа хязгаарлагдмал нарийвчлалтайгаар хэмжиж, дүрсэлдэг боловч онолын хувьд тэдгээр нь үргэлжилсэн шинж чанартай хэвээр байна.

Өгөгдлийн багцын төрлүүд




Бичлэг өгөгдөл (Record)

Өгөгдлийн матриц, баримт бичгийн өгөгдөл (term-frequency vector), гүйлгээний өгөгдөл



График ба сүлжээ (Graph/Network)

Веб хуудас, молекулын бүтэц



Дараалсан өгөгдөл (Ordered)

Видео өгөгдөл, цаг хугацааны цуваа, дараалсан өгөгдөл, генетик дараалал

Бичлэг өгөгдөл (Record Data)

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Үндсэн шинж чанар

Өгөгдөл нь бичлэгүүдийн цуглуулга-с бүрдэнэ.


Энэ нь өгөгдлийн хамгийн түгээмэл төрөл бөгөөд ихэнх өгөгдлийн сан болон хүснэгтүүдэд ашиглагддаг бүтэц юм.

	team	coach	play	ball	score	game	win	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0

Граф өгөгдөл (Graph Data)

Граф өгөгдлийн жишээнүүд


- Ерөнхий граф: оройнууд болон ирмэгүүд
- Молекул: атомууд болон холбоосууд
- Веб хуудас: хуудас болон холбоосууд



Жишээ: Бензений молекул



Бензений молекул нь 6 нүүрстөрөгчийн атом болон 6 устөрөгчийн атомаас бүрдэнэ. Энэ нь граф өгөгдлийн сонгодог жишээ юм.



Useful Links: • Bibliography • Other Useful Web sites ◦ ACM SIGKDD ◦ KDnuggets ◦ The Data Mine	Knowledge Discovery and Data Mining Bibliography (Gets updated frequently, so visit often!) • Books • General Data Mining
Book References in Data Mining and Knowledge Discovery Usama Fayyad, Gregory Piatetsky-Shapiro, Padhraic Smyth, and Ramasamy uthurasamy, "Advances in Knowledge Discovery and Data Mining", AAAI Press/the MIT Press, 1996. J. Ross Quinlan, "C4.5: Programs for Machine Learning", Morgan Kaufmann Publishers, 1993. Michael Berry and Gordon Linoff, "Data Mining Techniques (For Marketing, Sales, and Customer Support)", John Wiley & Sons, 1997.	General Data Mining Usama Fayyad, "Mining Databases: Towards Algorithms for Knowledge Discovery", Bulletin of the IEEE Computer Society Technical Committee on data Engineering, vol. 21, no. 1, March 1998. Christopher Matheus, Philip Chan, and Gregory Piatetsky-Shapiro, "Systems for knowledge Discovery in databases", IEEE Transactions on Knowledge and Data Engineering, 5(6):903-913, December 1993.

Дараалсан өгөгдөл (Ordered Data): Үндсэн ойлголт

Дараалсан өгөгдлийн тодорхойлолт

Өгөгдлийн доторх элементүүдийн дараалал чухал утгатай байдаг, тодорхой мэдээллийг дамжуулдаг өгөгдлийн багц юм.

Дарааллын ач холбогдол

Энэ төрлийн өгөгдөлд байрлал, дараалал өөрчлөгдвөл утга нь өөр болно.

Генетик дарааллын өгөгдөл
ДНХ-ийн дараалал:
аденин (A), тимин (T),
цитозин (C), гуанин (G)

```
GGTTCCGCCTTCAGCCCCGCGCC  
CGCAGGGCCCCGCCCCGCGCCGTC  
GAGAAGGGCCCGCCTGGCGGGCG  
GGGGGAGGCGGGGCGCCCGAGC  
CCAACCGAGTCCGACCAGGTGCC  
CCCTCTGCTCGGCCTAGACCTGA  
GCTCATTAGGCGGCAGCGGACAG  
GCCAAGTAGAACACGCGAAGCGC  
TGGGCTGCCTGCTGCGACCAGGG
```

Цаг хугацааны цуваа өгөгдөл (Temporal Data)


Тодорхойлолт ба онцлог

Цаг хугацааны дарааллаар цуглуулсан өгөгдлийг temporal data буюу time-series data гэнэ.

- Ийм өгөгдөл нь timestamp буюу хугацааны тэмдэглэгээтэй байдаг.
- **Салбарууд:** санхүү, цаг уур, анагаах ухаан

Үүнийг шинжлэхэд дараах аргууд түгээмэл хэрэглэгдэнэ:

1. Time-Series Analysis (Цаг хугацааны цувааны шинжилгээ)
2. Forecasting (Урьдчилан таамаглах)
3. Trend Detection (Чиг хандлага тодорхойлох)



Өгөгдлийн урьдчилсан судалгаа (Data exploration)

Өгөгдлийн урьдчилсан судалгаа

Хүмүүсийн хэв маягийг таних чадварыг ашиглан өгөгдлийн шинж чанарыг илүү сайн ойлгох үйл явц юм.

Хоёр үндсэн арга

Энэ хүрээнд бид дараах 2 зүйлсийг авч үзнэ:

- Статистикийн хураангуй (Summary statistics)
- Визуализаци (Visualization)

Статистикийн үндсэн аргуудын ангилал

01

Төвийн хандлагыг хэмжих

Mean, median, mode, midrange

02

Өгөгдлийн тархалт

Variance, standard deviation, range, quantiles

03

График - Өгөгдлийг нүдээр шалгах

Boxplot, histogram, scatter plot, quantile plot

Төвийн хандлагыг хэмжих

Х атрибут – цалин: $\{x_1, x_2, x_3, \dots, x_n\}$

Өгөгдлийн жишээ: 30, 36, 47, 50, 52, 52, 56, 60, 63, 70, 70, 110 (мянган доллар)

Асуулт

Хэрэв цалингийн талаарх ажиглалтыг графикаар дүрслэн харвал ихэнх утга хаана байрлах вэ?

Энэ нь өгөгдлийн төвийн чиг хандлагын талаархи ойлголтыг өгдөг.

Төвийн хандлагын хэмжүүрүүд

- Mean (Дундаж)
- Median (Медиан)
- Mode (Мод)
- Midrange (Дундаж муж)

Өгөгдлийн тархалтыг хэмжих

Тоон өгөгдлийн тархалтыг үнэлэх арга:

1

Boxplot


5 тооны хураангуйг ашиглах.
Outlier утгуудыг тодорхойлоход тустай.

2

Variance & Standard Deviation

Вариация болон стандарт хазайлт нь
өгөгдлийн тархалтын хэмжүүр юм.

5 тооны хураангуй ба Boxplot



5 тооны хураангуй

Тархалтын 5 тооны хураангуй нь дараах утгуудаас бүрдэнэ:

1. Minimum (Хамгийн бага)
2. Q1 (Эхний квартил)
3. Median/Q2 (Медиан)
4. Q3 (Гуравдагч квартил)
5. Maximum (Хамгийн их)

Boxplots нь тархалтыг дүрслэн харуулах түгээмэл арга юм.

Outlier тодорхойлох дүрэм

- Дээд outlier: $Q3 + 1.5 \times IQR$ -ээс их утга
- Доод outlier: $Q1 - 1.5 \times IQR$ -ээс бага утга

Вариаци ба Стандарт хазайлт

Үндсэн ойлголт

Вариаци болон стандарт хазайлт нь өгөгдлийн тархалтын хэмжүүр юм.

- Бага стандарт хазайлт: өгөгдлийн утгууд дундажтай ойрхон бөөгнөрсөн байна.
- Өндөр стандарт хазайлт: өгөгдлийн утгууд дунджаас алслагдсан, өргөн хүрээнд тархсан байна.

Томъёо

$X \{x_1, x_2, x_3, \dots, x_n\}$ тоон шинж чанарын хувьд:

Вариаци (σ^2): Өгөгдлийн цэгүүд дунджаас хэр зайтай байгааг хэмжинэ

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

Стандарт хазайлт (σ): Вариациаас квадрат язгуур авна. Энэ нь анхны өгөгдөлтэй ижил хэмжих нэгжтэй байдаг тул илүү ойлгомжтой.

График арга: Нэг хувьсагчийн тархалт

График нь өгөгдлийг нүдээр шалгахад тустай. Дараах графикууд нь өгөгдлийн багцын үндсэн статистик шинж чанарыг нүдээр дүгнэж, тайлбарлах үр дүнтэй хэрэгсэл юм.



Quantile plots

Нэг атрибуттай өгөгдлийн тархалтыг харах



Quantile-quantile plots

Тархалтуудыг харьцуулах буюу хоёр өгөгдлийн багцыг харьцуулах



Histograms

Давтамжийн тархалтыг харуулах




Scatter plots

Хоёр хувьсагчийн хамаарлыг харуулах

Quantile Plot

Нэг хувьсагчтай өгөгдлийн тархалтыг харах энгийн бөгөөд үр дүнтэй арга юм.

- Тоон мэдээллийг зурдаг
- Өгөгдсөн атрибутын бүх өгөгдлийг харуулдаг




$$f_i = \frac{i - 0.5}{N}.$$
$$i = 1, \dots, n$$

<i>Unit price</i> (\$)	<i>Count of</i> <i>items sold</i>
40	275
43	300
47	250
—	—
74	360
75	515
78	540
—	—
115	320
117	270
120	350

Quantile-Quantile Plot (Q-Q Plot)

Нийтлэг тархалттай популяциас хоёр өгөгдлийн багц ирсэн эсэхийг тодорхойлох график арга юм.



Жишээ: Салбаруудын харьцуулалт

- Q_1 : Салбар-1 зарагдсан барааны нэгж үнэ Салбар-2-оос бага зэрэг бага байна (Салбар-1: $\$60 \leq$, Салбар-2: $\$64 \leq$)
- Q_2 : Салбар-1 дээр $\$78 \leq$, Салбар-2 дээр $\$85 \leq$
- Дүгнэлт: Салбар-1 үнэ $<$ Салбар-2 үнэ


Гистограмм (Histogram)

Давтамжийн гистограмм

Нэг хувьсагчийн өгөгдлийн цэгүүдийн давтамжийн тархалтыг илэрхийлэхэд ашигладаг график.

Хязгаарлалт


Гистограммыг өргөн ашигладаг ч нэг хувьсагчтай ажиглалтын бүлгүүдийг харьцуулахдаа quantile график, q-q график, boxplot графикийн аргууд шиг үр дүнтэй байдаггүй.



Scatter Plot: Хоёр хувьсагчийн хамаарал


Үндсэн шинж чанар

Хоёр тоон шинж чанарын хооронд хамаарал байгаа эсэхийг тодорхойлох хамгийн үр дүнтэй график аргуудын нэг юм.



Юу харах вэ?



- Цэгүүдийн кластер
- Outliers (хэвийн бус утгууд)
- Корреляцийн хамаарал (эерэг эсвэл сөрөг)



Scatter plot-г атрибутуудын хооронд (a) эерэг эсвэл (b) сөрөг хамаарлыг олоход хэрэглэдэг.


Scatter Plot: Хамаарлын төрлүүд

Өгөгдлийн багц тус бүрийн хувьд хоёр атрибутын хооронд хамаарал ажиглагдаагүй тохиолдлууд.



Корреляци (Correlation)

Корреляци нь хоёр хувьсагчийн хоорондын **шугаман хамаарлыг** хэмждэг статистикийн хэмжүүр юм.



БАЯРЛААА

Data mining and machine learning

