



**МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН
ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ**
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

KOICA
Korea International
Cooperation Agency

Машин сургалт: Удирдлагагүй сургалт

Лабораторийн удирдамж №
Компьютерын ухааны салбар

This e-learning content was developed by the support of KOICA



Дэд профессор, док (PhD), Д.Золзая /email: zolzaya@must.edu.mn/
Компьютерын ухааны салбар



Лабораторийн дасгал



- Өгөгдлийн төстэй байдлыг хэмжих аргачлалуудыг ойлгох.
- Төстэй байдлын хэмжүүрүүдийг (similarity metrics) ашиглан өгөгдөл дээр шинжилгээ хийх.
- Euclidean, Cosine, Jaccard зэрэг түгээмэл хэмжүүрүүдийг бодит өгөгдөлд хэрэгжүүлэх.





Лабораторийн дасгал



Даалгавар: Jaccard Similarity ашиглах (MovieLens Dataset)

- MovieLens Dataset-ийг ачаалж боловсруулах

```
import pandas as pd
```

```
# MovieLens өгөгдөл ачаалах
```

```
url = "https://files.grouplens.org/datasets/movielens/ml-latest-small.zip"
```

```
movies = pd.read_csv("ml-latest-small/movies.csv")
```

```
ratings = pd.read_csv("ml-latest-small/ratings.csv")
```

```
# Хэрэглэгчийн үнэлгээг матриц хэлбэрт оруулах
```

```
user_movie_matrix = ratings.pivot(index='userId', columns='movieId',
```

```
values='rating').fillna(0)
```

```
print(user_movie_matrix.head())
```





Лабораторийн дасгал



Jaccard Similarity тооцоолох

```
from sklearn.metrics import jaccard_score

# Хоёр хэрэглэгчийн хоорондын Jaccard Similarity
user1 = user_movie_matrix.iloc[0]
user2 = user_movie_matrix.iloc[1]

similarity = jaccard_score(user1 > 0, user2 > 0)
print(f"Jaccard Similarity: {similarity}")
```





Кластерчлал (Clustering)



- Кластерчлалын үндсэн ойлголт, ач холбогдлыг ойлгох.
- Төрөл бүрийн кластерчлалын алгоритмуудыг ашиглан өгөгдлийг бүлэглэх чадвар эзэмших.
- Python хэл дээр sklearn сан ашиглан кластерчлалын алгоритмуудыг хэрэгжүүлэх.





Лабораторийн дасгал



- Кластерчлал нь хяналтгүй сургалтын (unsupervised learning) нэг төрөл бөгөөд өгөгдлийг төстэй шинж чанараар нь бүлэглэхэд ашиглагддаг.
- Кластерчлалын алгоритмуудын төрөл:
 - K-Means
 - Hierarchical Clustering
 - DBSCAN
- Кластерчлалын хэрэглээ:
 - Зах зээл сегментчлэл
 - Зургийн танилт
 - Мэдээллийн хайлт





Лабораторийн дасгал



```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
from sklearn.datasets import make_blobs

# Өгөгдөл үүсгэх
X, y = make_blobs(n_samples=300, centers=4, random_state=42, cluster_std=0.6)

# K-Means загвар
kmeans = KMeans(n_clusters=4, random_state=42)
kmeans.fit(X)

# Урьдчилсан таамаглал
labels = kmeans.labels_

# Кластерын төвүүд
centroids = kmeans.cluster_centers_

# График дүрслэл
plt.scatter(X[:, 0], X[:, 1], c=labels, cmap='viridis', s=50)
plt.scatter(centroids[:, 0], centroids[:, 1], c='red', marker='X', s=200)
plt.title("K-Means Clustering")
plt.show()
```





Кластерчлал (Clustering)



Даалгавар 1: K-Means кластерчлал

1. Өгөгдөл үүсгэх: Python-ийн `make_blobs` функц ашиглан 3 өөр кластер үүсгэ.
 - Өгөгдлийн хэмжээ: 500
 - Кластерын тоо: 3
2. K-Means алгоритм ашиглах
 - K-Means алгоритмыг ашиглан өгөгдлийг 3 бүлэгт хуваа.
 - Кластерын төвүүдийг болон үр дүнг график дүрслэлээр харуул.
3. Дасгал
 - Кластерын тоог 2 болон 4 болгож өөрчилж, үр дүнг харьцуулан тайлбарла.
 - Кластерчлалын төвүүд хэрхэн өөрчлөгдөж байгааг тодорхойл.





Кластерчлал (Clustering)



Даалгавар 2: PCA (Principal Component Analysis) ашиглах

1. Өгөгдөл бэлдэх: sklearn.datasets-ээс Iris Dataset-ийг ачаалж, 4 хэмжээст өгөгдлийг ашиглана.
2. PCA хэрэгжүүлэх
 - PCA алгоритмыг ашиглан өгөгдлийн хэмжээсийг 2 болгож бууруул.
 - PCA-гийн 2 хэмжээст өгөгдлийг дүрслэн харуул.
3. Дасгал
 - PCA-гийн гол бүрэлдэхүүнүүдийн хувьсагчийн мэдээллийг тайлбарла.
 - Хэмжээс бууруулалтын дараах өгөгдлийн кластерчлалын утгыг хэрхэн тайлбарлахыг хэлнэ үү.





Кластерчлал (Clustering)



Даалгавар 3: DBSCAN ашиглах

1. Нягтаршлын өгөгдөл үүсгэх: Python-ийн `make_moons` функцийг ашиглан саран хэлбэртэй 2 кластер үүсгэ.
2. DBSCAN алгоритм ашиглах
 - `eps` болон `min_samples` параметрийн утгыг тохируулан DBSCAN алгоритмыг хэрэгжүүл.
 - Алгоритмын үр дүнг график дүрслэлээр харуул.
3. Дасгал
 - `eps`-ийн утгыг 0.2 болон 0.8 болгож өөрчилж, үр дүнг харьцуул.
 - DBSCAN алгоритм кластерын тоог автоматаар сонгож чадаж байгааг тайлбарла.

