



**МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН
ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ**
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

KOICA
Korea International
Cooperation Agency

Машин сургалт: Удирдлагагүй сургалт

Лекц № 9

Компьютерын ухааны салбар

This e-learning content was developed by the support of KOICA



Дэд профессор, док (PhD), Д.Золзая /email: zolzaya@must.edu.mn/
Компьютерын ухааны салбар



Хичээлийн агуулга



- Хичээлийн зорилго, ач холбогдол
- ML Удирдлагагүй сургалт гэж юу вэ?
- ML Удирдлагагүй сургалтын үндсэн процесс
- Төсөөтэй хэмжигдэхүүн
- ML Удирдлагагүй сургалтын төрлүүд
- ML Удирдлагагүй сургалтын хэрэглээ
- ML Удирдлагагүй сургалтын асуудлууд
- Дүгнэлт





Хичээлийн зорилго, ач холбогдол




- Оюутанд шошгогүй өгөгдлөөс бүтэц, загвар, хамаарлыг илрүүлэх алгоритмуудыг сургаж, өгөгдлийн нуугдмал бүтэц, бүлэглэл, хэв шинжийг олж илрүүлэх чадвар эзэмшүүлэх.
- Хичээлийн ач холбогдол
 - Өгөгдлийн дүн шинжилгээ хийх чадвар
 - Өгөгдлийн хэт их хэмжээтэй нөхцөлд үр ашигтай
 - Бодит хэрэглээнд нэвтрэх боломж
 - Ажлын байрны боломжууд
 - Автомат ойлголт үүсгэх чадвартай болно





Удирдлагагүй сургалт гэж юу вэ?

Удирдлагагүй сургалт нь оролтын өгөгдлөөс хамааралтай бүтэц, хэв шинжийг автоматаар илрүүлэх зорилготой. Энэ төрлийн сургалтад өгөгдөл нь шошгогүй (label-free) байдаг бөгөөд алгоритм нь өгөгдлийн хамаарал, бүлэглэл, түгээмэл байдал зэргийг тодорхойлдог.





Удирдлагагүй сургалт гэж юу вэ?



Жишээ өгөгдөл: Хэрэглэгчийн худалдан
зан төлвийн өгөгдөл

User_ID	Total_Visits	Avg_Spend (₮)	Products_Viewed	Days_Since_Last_Visit
1001	12	34,000	8	3
1002	4	85,000	3	14
1003	20	18,500	15	1
1004	7	55,000	6	7

Хэрэглэгчдийг зан төлвөөр нь кластерлах →
маркетингийн сегмент үүсгэх

Жишээ өгөгдөл: Мэдээний өгөгдөл


Article_ID	Text
1	"Эдийн засгийн өсөлт энэ улиралд 4.5 хувьд хүрэв"
2	"Шинэ технологийн компаниуд IPO-д бэлтгэж байна"
3	"Улсын аварга шалгаруулах тэмцээн Улаанбаатарт эхэллээ"
4	"Цахилгаан машины зах зээл дэлхийд тэлж байна"

Сэдэв (topics)-ийг автоматаар илрүүлэх,
бичвэрийг сэдвээр бүлэглэх (Topic Modeling)

Ижил төстэй байдлын хэмжүүр нь кластер хийх, гажиг илрүүлэх, хэмжээст байдлыг багасгахад чухал үүрэг гүйцэтгэдэг. Эдгээр хэмжигдэхүүнүүд нь өгөгдлийн цэгүүд хоорондоо хэр төстэй эсвэл өөр болохыг хэмждэг. Төрөл бүрийн өгөгдлийн дунд түгээмэл хэрэглэгддэг ижил төстэй хэмжүүрүүдийг доор харуулав.

Зайнд суурилсан хэмжигдэхүүн

- Euclidean Distance
- Manhattan Distance
- Minkowski Distance
- Cosine Similarity
- Jaccard Similarity





Төсөөтэй хэмжүүр



- Өгөгдлийн шинжилгээнд кластерлах алгоритмыг ашиглан өгөгдөл нь аль бүлэгт хамаарахыг тодорхойлсноор өгөгдлүүдээс зарим чухал утгыг олж авах боломжтой.
- Ижил төстэй өгөгдлийн объектуудыг нэгтгэх ижил төстэй байдлын хэмжүүр дээр үндэслэн кластержуулалтыг хийдэг.
- Төсөөтэй хэмжүүр нь хоёр өгөгдлийн цуглуулга, объект, эсвэл векторуудын хоорондох төстэй байдлыг тооцоолох аргуудыг хэлнэ.
- Эдгээр хэмжүүрүүд нь олон төрлийн өгөгдлийн төрлүүд дээр, ялангуяа массив, вектор, текст эсвэл зургийн өгөгдөл дээр хэрэглэгддэг.






Евклидийн зайн арга

- Евклидийн алслал нь хоёр векторын хоорондох шулуун шугамын зай юм. X ба Y гэсэн хоёр векторын хувьд үүнийг дараах байдлаар тооцоолно.
- Тогтмол биш хувьсагчуудад илүү тохиромжтой. Евклидийн алслал нь масштабаар хэмжигдэхүйц биш тул зайг тооцоолохын өмнө өгөгдлийг хэмжинэ.

$$EUC(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$


- x_i ба y_i — хоёр өгөгдлийн цэгийн координатууд.



Манхэттэний зайн арга

Евклидийн зайнаас ялгаатай нь Манхэттэнгийн зай бөгөөд үүнийг 'cityblock' гэж нэрлэдэг бөгөөд нэг вектороос нөгөөд хүрэх зай юм. Манхэттэний зайг бид дараах байдлаар тооцоолно.

$$Manhattan\ distance = \sum_{i=1}^n |x_i - y_i|$$






Косинусын өнцөг зайн арга

Косинусын өнцөг үндсэн арга нь харьцуулах 2 өгөгдлийн өнцгийн хэмжээг олж өнцгийн хэмжээ хоорондоо дөхөх тусам харилцан хамааралтай гэж үздэг аргачлал юм.

$$\text{cosine}(x, y) = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$$



- A ба B — хоёр вектор
- $A \cdot B$ — векторын дотоод бүтээгдэхүүн (dot product)
- $\|A\|, \|B\|$ — векторын урт (magnitude)





Жаккард зайн арга

Жаккард зайны арга (заримдаа Jaccard-ийн ижил төстэй коэффициент гэж нэрлэдэг) нь хоёр багцын гишүүдийг харьцуулж, аль гишүүд нь хуваагдаж, юу нь ялгаатай болохыг харуулна. Энэ нь 0% -аас 100% хоорондох хоёр өгөгдлийн хувьд ижил төстэй хэмжүүр юм. Хувь хэмжээ өндөр байх тусам энэ хоёр популяци ижил төстэй болно. Индексийг олох томьёо нь:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

- A ба B — хоёр бүлэг (set)
- $|A \cap B|$ — бүлгүүдийн хөндлөн хэсгийн хэмжээ (intersection)
- $|A \cup B|$ — бүлгүүдийн нийлбэр хэсгийн хэмжээ (union)

Жаккард индекс = (хоёр багц дахь тоо) / (аль алинд нь байгаа тоо) * 100







Төсөөтэй хэмжүүр



Кластержуулалт	Хэрэглэдэг төсөөтэй хэмжүүр
K-Means	Euclidean Distance
Hierarchical Clustering	Euclidean, Manhattan, Cosine, Jaccard
DBSCAN	Any distance metric (default: Euclidean)
Spectral Clustering	Cosine Similarity, Gaussian Kernel
Agglomerative Clustering	Customizable: Euclidean, Cosine гэх мэт







Удирдлагагүй сургалтын төрлүүд



- Бүлэглэл (Clustering)
- Хэмжээс багасгах (Dimensionality Reduction)
- Холбоосын дүрэм (Association Rule Mining)



Centroid-Based Clustering

- K-Means (Uses Euclidean Distance)


Өгөгдлийг k хуваах ба кластерын төв хүртэлх квадрат зайны нийлбэрийг багасгах замаар k кластер.

Хэмжээнээс болон эхлэлийн хэсэг нь мэдрэмтгий.

- K-Medoids (Uses Manhattan Distance or Euclidean Distance)

K-Means-тай төстэй боловч центроидуудын оронд бодит өгөгдлийн цэгүүдийг (медоид) ашигладаг.

Хэт өндөр үзүүлэлтүүдэд илүү бат бөх.






Кластерлалт

K-means


Алхам

1. К тооны кластер сонгоно
2. Санамсаргүйгээр төвүүдийг эхлүүлнэ
3. Өгөгдлийн цэг бүрийг хамгийн ойрын төв рүү онооно
4. Шинэ төвүүдийг тооцоолно
5. Хувиарлалт өөрчлөгдөхөө больтол давтана



Density-Based Clustering:

- DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
 - Евклидийн зай (анхдагч) эсвэл бусад зайны хэмжигдэхүүнийг ашигладаг.
 - Шуугианыг тодорхойлохдоо нягтрал дээр тулгуурлан цэгүүдийг бөөгнөрүүлэх (outlier).
- OPTICS (Ordering Points To Identify the Clustering Structure)
 - DBSCAN-тай төстэй боловч хувьсах нягтралд дасан зохицдог.
 - Олон ялгаатай нягтралтай кластерууд-ыг нэг дор таних, илүү уян хатан бүтэцтэй бүлэглэл хийх.






Бүлэглэл (Clustering)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise):

- Нягтралд суурилсан бүлэглэл, өгөгдлийн бөөгнөрөлийг тодорхойлдог.
- Бөөгнөрөл илрүүлэх, хөндий газрыг ялгах.
- Давуу тал: Хэлбэлзэл ихтэй өгөгдөлд сайн ажилладаг.
- Сул тал: Бүлгийн хэлбэрийн талаарх таамаглалаас хамаарна.
- Жишээ: Дуу таних, Газрын зураг дээрх нягтралын судалгаа





Бүлэглэл (Clustering)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise):

1. Хоёр үндсэн параметрийг тохируулна
 - Цэг бүрийн ϵ радиус дотор хэдэн хөрш цэг байгааг шалгана.
 - minPts – нэг цэгийн эргэн тойронд байх ёстой хамгийн бага хөрш цэгийн тоо
2. Цэг бүрийн хөршүүдийг тооцно
 - Цэг бүрийн ϵ радиус дотор хэдэн хөрш цэг байгааг шалгана.
3. Цэгүүдийг ангилна.

Төрөл	Тайлбар
Core point	ϵ радиус дотор $\geq \text{minPts}$ хөрштэй цэг
Border point	Өөрийнх нь хөрш цөөн ч, core point-д ойр байгаа
Noise point (Outlier)	Ямар ч core point-д харьяалагддаггүй цэг


4. Кластер үүсгэх

- a. Core цэгээс эхэлж, ϵ радиустай хөрш бүх цэгийг нэг кластер болгож өргөтгөнө.
- b. Core цэгийн хөршүүд нь цааш шинэ core байж болно.
- c. Энэ байдлаар нэгтгэсээр бүх кластер үүснэ.



Hierarchical Clustering

- Энэ алгоритм нь өгөгдлийг мод бүтэц (дендрограм) хэлбэрээр харуулдаг.
- Өгөгдлийг шаталсан бүтэц үүсгэн бүлэглэдэг.
- Бүлгүүдийн хоорондын шат дараалсан хамаарлыг харуулах.
- Давуу тал: Бүлгийн тоог урьдчилан тохируулах шаардлагагүй.
- Сул тал: Том хэмжээний өгөгдөлд удаан ажилладаг. Жишээ: генетикийн өгөгдлийн ангилал, хэрэглэгчдийн зан төлөвийн судалгаа





Hierarchical Clustering


Алхам

1. Өгөгдөл бүрийг тус тусдаа бүлэг гэж үзнэ
2. Бүх цэгийн хоорондын зайг тооцоолно
3. Хамгийн ойр 2 бүлгийг нэгтгэнэ
4. Зайны матрицыг шинэчилнэ
5. Дахин хамгийн ойр хоёр кластерыг нэгтгэнэ
6. Дендрограм (Dendrogram) гаргана


Холбогч метрикс

- Single linkage – хамгийн ойрын хоёр цэгийн зай
- Complete linkage – хамгийн хол хоёр цэгийн зай
- Average linkage – бүх цэгийн хоорондын дундаж зай
- Ward's method – вариацийг багасгах


Single linkage




Complete linkage



Average linkage





Ward's method



GMM Based Clustering:

- Кластер бүр нь нэг Гауссын тархалт (Normal distribution) гэж үзнэ
- Бүх өгөгдөл: тэдгээр Гауссын нэгтгэсэн (mixture) model болдог.
- Давуу тал:
 - Илүү уян хатан — Кластерууд нь зөвхөн дугуй биш, эллипс хэлбэртэй байж болно (ковариацийг харгалзана)
 - Магадлалт ангилалт — Нэг өгөгдөл хэд хэдэн кластерт хамаарах магадлал-тай байна
- Сул тал
 - Тооцоолол төвөгтэй — EM алгоритм итераци ашигладаг, удаан ажилладаг
 - Gaussian таамаглал — Бүх бүлэг Gaussian тархалттай байх ёстой гэсэн нөхцөл тавьдаг






Хэмжээс багасгах (PCA)

Principal Component Analysis (PCA):

- Өгөгдлийг тодорхой тооны бүлэгт (k) хуваадаг алгоритм.
- Өгөгдлийг хоорондоо төстэй бүлэгт хуваах.
- Давуу тал: Хялбар, хурдан.
- Сул тал: Бүлгийн тоог урьдчилан тохируулах шаардлагатай.
- Жишээ: зах зээлийн сегментчлэл, зураг эсвэл текстийн бүлэглэл.





Хэмжээс багасгах (PCA)



Алхам 1: Өгөгдлийг стандартчлах

Бүх багануудыг дундаж = 0, стандарт хазайлт = 1 болгох

$$Z = \frac{X - \mu}{\sigma}$$

Учир нь өөр өөр нэгжтэй баганууд PCA-д нөлөө харилцан адилгүй үзүүлдэг.

Алхам 2: Ковариацийн матриц байгуулах

Хос хосоороо баганууд хэрхэн хамт өөрчлөгдөж байгааг илтгэнэ. X өгөгдөл n шинжтэй.

$$\text{Cov}(X) = \frac{1}{n-1} Z^T Z$$

Матрицын хэмжээ: $n \times n$

Алхам 3: Eigenvector, Eigenvalue-г олох

Eigenvector → Шинэ тэнхлэгийн чиглэл (PCA)

Eigenvalue → Тэр чиглэлд байгаа вариацийн хэмжээ

$$\text{Cov}(X) \cdot v = \lambda \cdot v$$

- v = eigenvector (principal component)
- λ = eigenvalue (variance along that component)

Алхам 4: Eigenvalue-гаар эрэмблэх

Аль чиглэл хамгийн их вариаци агуулж байгааг тогтооно.

I.e.,

Eigenvalues: [5.2, 2.3, 0.8]

→ Choose top 2: keep dimensions with highest variance





Хэмжээс багасгах (PCA)

Алхам 5: Топ k PCA сонгох


Ер нь 90-95% вариацийг хадгалах хэмжээг сонгоно

Тухайн eigenvector-уудыг нэг матриц (W_k) болгож хадгална

Алхам 6: Шинэ орон зайд төсөөлөх (projection)

$$X_{\text{шинэ}} = X \cdot W_k$$

Өгөгдөл маань одоо k хэмжээсрүү шилжлээ.





Холбоосын дүрэм (Association Rule Mining)

- Association Rule Mining нь өгөгдөл дундах бараа бүтээгдэхүүн, үйл явдлын хам орших хандлага, хээ, хамаарлыг илрүүлдэг удирдлагагүй сургалтын арга юм.
- Жишээ: “Хэрэв хүн талх авбал, цөцгийн тос авах магадлалтай”
- Өгөгдөл дотроос хэрэгтэй, давтагддаг хослолууд (itemset) болон тэдгээрийн логик дүрмийг тодорхойлох

$$\text{Support}(A \Rightarrow B) = P(A \cap B)$$

$$\text{Confidence}(A \Rightarrow B) = P(B | A) = \text{Support}(A \cap B) / \text{Support}(A)$$

$$\text{Lift}(A \Rightarrow B) = \text{Confidence}(A \Rightarrow B) / \text{Support}(B)$$

Ойлголт	Тайлбар
Itemset	Барааны багц (жишээ: {талх, сүү})
Support	Хэр олон удаа тухайн itemset гарсан хувь (давтамж)
Confidence	A байвал B ч байгаа байх магадлал
Lift	A ба B хамт байх нь түгээмэл байдлаас давсан эсэх

- Давтамж ихтэй боловч утгагүй холбоос үүсэх магадлалтай
- Itemset олшироход тооцооллын хүндрэл гардаг





Холбоосын дүрэм (Association Rule Mining)

Transaction ID	Items
1	талх, сүү
2	талх, цөцгийн тос
3	талх, сүү, өндөг
4	сүү, цөцгийн тос

Apriori алгоритмаар тооцоолъё.

талх $\Rightarrow$ сүү

- Support = $2/4 = 0.5$
- Confidence = $2/3 = 0.67$
- Lift = $0.67 / 0.75 = 0.89$ (доогуур $\rightarrow$ сул хамаарал)

Алгоритм	Онцлог
Apriori	Support $\geq$ minSupport хослолыг шаталсан байдлаар хайдаг
ECLAT	Itemset-г босоо вектороор харж хурдан тооцдог
FP-Growth	FP Tree ашиглан санах ой хэмнэдэг, илүү хурдан





Удирдлагагүй сургалтын хэрэглээ



- Өгөгдлийн бүлэглэл (Customer Segmentation):
 - Хэрэглэгчдийг зан төлөвөөр нь бүлэглэх.
- Хэмжээс багасгах (Data Visualization):
 - Өгөгдлийн бүтэц, хэв маягийг хялбарчилж харах.
- Холбоосын дүрэм (Recommendation Systems):
 - Хэрэглэгчдэд тохирох бараа, үйлчилгээг санал болгох.
- Аномали илрүүлэлт (Anomaly Detection):
 - Санхүүгийн луйвар, үйлдвэрлэлийн асуудлыг илрүүлэх.





Удирдлагагүй сургалтын асуудлууд



- Сургалтын өгөгдөлд ямар ч шошго (label) байхгүй тул үнэлгээ хийхэд хэцүү.
- Кластерийн тоог урьдчилан мэдэх шаардлагатай. Буруу K сонгосноор хэт их эсвэл хэт бага бүлэг гарч болзошгүй.
- Эллипс, суналттай эсвэл нягтрал өөр гэх мэт онцлог кластеруудыг буруу ангилж болзошгүй.
- Ховор тохиолдол, гаж өгөгдөл нь бүлэглэл гажуудуулах магадлалтай.
- Удирдлагагүй өгөгдөл дээр үнэлэхэд ашиглах үнэн зөв “ground truth” үгүй.





Дүгнэлт



- Удирдлагагүй машин сургалт нь өгөгдлийг урьдчилан шошгололгүйгээр шинжлэх арга бөгөөд өгөгдлийн дотоод бүтэц, бүлэглэл, хамаарлыг автоматаар илрүүлдэг.
- Энэ нь голчлон clustering буюу бүлэглэлт (жишээ нь: K-means, Hierarchical Clustering, DBSCAN, GMM), болон dimensionality reduction буюу хэмжээ бууруулах (жишээ нь: PCA, t-SNE) аргуудаар хэрэгждэг.
- Удирдлагагүй сургалт нь өгөгдлийн шинжилгээ, хэв маяг илрүүлэлт, outlier таних, өгөгдөл шахах зэрэгт өргөн хэрэглэгддэг.
- Мөн хяналттай сургалтын өмнөх шатны өгөгдөл боловсруулалт, мэдлэг нээх эхний алхам болдог.
- Энэхүү сургалтын арга нь өгөгдлийн гүн утгыг ойлгож, шошгогүй мэдээллийг үнэ цэнтэй болгож, өгөгдлийн нууцлаг хандлагыг илрүүлэхэд чухал үүрэгтэй.

