



**МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН
ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ**
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

KOICA
Korea International
Cooperation Agency

Машин сургалт: Удирдлагатай сургалт

Лекц № 8

Компьютерын ухааны салбар

This e-learning content was developed by the support of KOICA



Дэд профессор, док (PhD), Д.Золзая /email: zolzaya@must.edu.mn/
Компьютерын ухааны салбар



Хичээлийн агуулга



- Хичээлийн зорилго, ач холбогдол
- ML Удирдлагатай сургалт гэж юу вэ?
- ML Удирдлагатай сургалтын төрлүүд
- ML Удирдлагатай сургалтын үнэлгээ
- ML Удирдлагатай сургалтын хэрэглээ
- ML Удирдлагатай сургалтын асуудлууд
- Дүгнэлт





Хичээлийн зорилго, ач холбогдол



Энэ хичээлийн зорилго нь суралцах өгөгдөл болон гаралтын хоорондын хамаарлыг шошготой өгөгдлийн тусламжтайгаар суралцах машин сургалтын аргуудын онол, алгоритм, хэрэгжүүлэлтийг судалж, ангилал болон регрессийн бодит хэрэглээнд ашиглах чадвар эзэмших.

Ач холбогдол

- Таамаглал хийх боломж
- Автомат шийдвэр гаргалт
- Олон салбарт өргөн хэрэглээтэй
- Бодит өгөгдлийг үр ашигтай ашиглана
- Тайлбарлах боломжтой загвар бүтээдэг





Удирдлагатай сургалт гэж юу вэ?



- Шошготой оролтын өгөгдөл (Labeled Data) нь гаралтын хариулттай хосолсон байдаг.
- Жишээ нь:


Өвчтөний шинж чанар	Онош (Label)
[40 нас, цусны даралт 150, BMI 30]	Өндөр даралт (Yes)
[25 нас, цусны даралт 110, BMI 22]	Өндөр даралт (No)

Талбай (м²)	Өрөө	Байршил	Үнэ (Label)
80	3	БЗД	180 сая
120	4	ХУД	280 сая
55	2	ЧД	140 сая
80	3	ХУД	350 сая
94	3	СБД	450 сая





Удирдлагатай сургалтын үндсэн процесс






Удирдлагатай сургалтын алхмууд





- Өгөгдөл бэлтгэх:
 - Өгөгдлийг цэвэрлэх, ангилах, урьдчилан боловсруулах.
- Сургалтын өгөгдөл ба шалгалтын өгөгдөлд хуваах:
 - Өгөгдлийн 70%-80%-ийг сургалтанд, үлдсэнийг шалгалтад ашиглах.
- Загвар сургалт:
 - Алгоритмыг өгөгдөл ашиглан сургах.
 - Hyperparameter tuning
- Загвар шалгах:
 - Загварын үнэн зөвийг шалгалтын өгөгдлөөр үнэлэх.
- Таамаглал гаргах:
 - Загварыг шинэ өгөгдөл дээр ашиглах.



Удирдлагатай сургалтын төрлүүд

- Ангилал (Classification):
 - Оролтыг тодорхой категориудад ангилах
 - Ангилал бол оролт өгөгдлийг тодорхой бүлэгт хуваах, тасралттай ангиллын шошгыг таамаглах машин сургалтын асуудал юм.
 - Жишээ: Эмчийн өгөгдөл → “Өвчтэй” эсвэл “Эрүүл”
Имэйл → “Спам” эсвэл “Жирийн”
- Регресс (Regression):
 - Тоон утгыг таамаглах
 - Регресс нь оролт өгөгдлийн үндсэн дээр тасралтгүй тоон утга (гарц) таамаглах машин сургалтын асуудал юм.
 - Жишээ: Орон сууцны байрны үнэ, Температур хэд байх вэ, Хувьцааны ирээдүйн ханш





Ангилал (Classification)



- Шийдвэрийн мод (Decision Tree)
- Санамсаргүй ой (Random Forest)
- k-хөршийн арга (k-Nearest Neighbors, k-NN)
- Дэмжих вектор машин (Support Vector Machine, SVM)
- Наив Байесийн арга (Naïve Bayes)





Регресс (Regression)



- Шугаман регресс (Linear Regression)
- Олон хувьсагчтай шугаман регресс (Multiple Linear Regression)
- Логистик регресс (Logistic Regression)





Логистик регресс

Логистик функц (Sigmoid) буюу логистик функцийн дугуй:


Логистик регресс нь сигмойд функц (sigmoid function) ашиглан шууд гаргалгаа хийдэг. Энэ нь 0 ба 1 хооронд орших утгыг өгдөг

$$P(y = 1|x) = \frac{1}{1 + e^{-z}}$$

z- шугаман регрессийн функц буюу

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

e- тоон үндэс (Euler's number)



Sigmoid функц нь хариу үр дүнг 0 ба 1 хооронд шилжүүлж, тэрхүү утгыг тодорхой бүлэгт ангилах боломжийг олгодог. Логистик регресс нь хоёр ангилалын асуудалд хэрэглэгддэг бөгөөд үндсэн зорилго нь өөрийн өгөгдлийн сетийг харгалзах ангилалд хуваах юм.






Шугаман регресс (Linear Regression)



Нэг хувьсагчтай шугаман регресс:

$$y = mx + b$$



y - Урьдчилан таамаглах хувьсагч (target)


x - Оролтын хувьсагч (feature)

m - Шугамын налуу буюу коэффициент (slope)

b – Ттэнхлэг огтлох утга (intercept)


Олон хувьсагчтай шугаман регресс:

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$





Шийдвэрийн мод



Өгөгдлийн тодорхойгүй байдлыг (uncertainty) хэмждэг. Утга нь холимог байх тусам энтропи өндөр.

$$\text{Entropy}(D) = - \sum_{i=1}^C p_i \cdot \log_2(p_i)$$

- D : өгөгдлийн багц (dataset)
- C : ангиллын тоо
- p_i : D багц дахь ангилал i -н магадлал

Ямар нэг шинж чанараар (feature) өгөгдлийг хуваасны дараа энтропи хэр багасаж байна вэ?

$$\text{InformationGain}(D, A) = \text{Entropy}(D) - \sum_{v \in \text{Values}(A)} \frac{|D_v|}{|D|} \cdot \text{Entropy}(D_v)$$

- A : өгөгдлийг хуваах шинж (attribute)
- $\text{Values}(A)$: шинжийн боломжит утгууд (жишээ нь "Yes", "No")
- D_v : $A = v$ гэсэн нөхцөлтэй subset
- $|D_v|/|D|$: тухайн subset-ийн хувь





Шийдвэрийн мод



Outlook, Temperature, Humidity, Windy шинжүүдийн аль нь хамгийн өндөр Information Gain өгч байна вэ гэдгийг тооцоолж модны эхний зангилааг сонгоно.

Play ? yes, no

Outlook	Temperature	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rain	Mild	High	False	Yes
Rain	Cool	Normal	False	Yes
Rain	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rain	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rain	Mild	High	True	No

Target (Play?): 14 өгөгдөл

- Yes: 9

- No: 5

$$\text{Entropy}(D) = - \left(\frac{9}{14} \log_2 \frac{9}{14} + \frac{5}{14} \log_2 \frac{5}{14} \right) = -(0.643 \cdot \log_2 0.643 + 0.357 \cdot \log_2 0.357) \approx 0.940$$

Outlook	Нийт	Yes	No	Entropy
Sunny	5	2	3	$-[0.4 \log_2 0.4 + 0.6 \log_2 0.6] = 0.971$
Overcast	4	4	0	0.000
Rain	5	3	2	$-[0.6 \log_2 0.6 + 0.4 \log_2 0.4] = 0.971$

$$IG(\text{Outlook}) = 0.940 - \left(\frac{5}{14} \cdot 0.971 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0.971 \right) = 0.940 - (0.694) = 0.246$$





Шийдвэрийн мод

Temp	Нийт	Yes	No	Entropy
Hot	4	2	2	1.000
Mild	6	4	2	0.918
Cool	4	3	1	0.811

$$IG(\text{Temperature}) = 0.940 - \left(\frac{4}{14} \cdot 1 + \frac{6}{14} \cdot 0.918 + \frac{4}{14} \cdot 0.811 \right) = 0.940 - 0.911 = 0.029$$

Humidity	Нийт	Yes	No	Entropy
High	7	3	4	0.985
Normal	7	6	1	0.591

$$IG(\text{Humidity}) = 0.940 - \left(\frac{7}{14} \cdot 0.985 + \frac{7}{14} \cdot 0.591 \right) = 0.940 - 0.788 = 0.152$$






Шийдвэрийн мод

Windy	Нийт	Yes	No	Entropy
True	6	3	3	1.000
False	8	6	2	0.811

$$IG(Windy) = 0.940 - \left(\frac{6}{14} \cdot 1 + \frac{8}{14} \cdot 0.811 \right) = 0.940 - 0.892 = 0.048$$

Шинж	IG
Outlook	0.246 ✓
Humidity	0.152
Windy	0.048
Temperature	0.029





Байесийн ангилал



Байесийн онол

$$P(C | X) = \frac{P(X | C) \cdot P(C)}{P(X)}$$

- C : ангилал (class, жишээ нь "спам", "эрүүл")
- X : шинж чанарууд (features)
- $P(C | X)$: өгөгдөл X орсон үед C ангилал байх магадлал (posterior)
- $P(X | C)$: тухайн ангилалд шинжүүд илэрсэн магадлал (likelihood)
- $P(C)$: тухайн ангиллын урьдчилсан магадлал (prior)
- $P(X)$: шинжүүд гарч ирэх нийт магадлал (бүх ангилалд хамаарах)

Хэрвээ толгой өвдсөн ба халуурсан бол ханиадтай байх магадлал хэд вэ?

Байесийн ангилал нь магадлалын онолд суурилсан ангиллын арга бөгөөд, Байесийн теорем ашиглан шилдэг ангиллыг сонгодог. Наад зах нь хамгийн түгээмэл хэрэглээ нь Naive Bayes classifier юм.

Байесийн ангиллын төрөл	Тайлбар
Gaussian Naive Bayes	Тоон өгөгдөл (шинжүүд Normal тархалттай)
Multinomial Naive Bayes	Текст, үг тоолол дээр (Bag of Words)
Bernoulli Naive Bayes	Binary өгөгдөл (0/1, Тийм/Үгүй)
Bayesian Network Classifier	Хамааралтай шинжүүдтэй сүлжээ ашигладаг





Байесийн ангилал

Байесийн теорем дээр суурилсан ангилал бөгөөд шинжүүд бие даан (naively independent) гэж үздэг.

Өдөр	Толгой өвдөх	Халуурах	Ханиад (Label)
1	Тийм	Үгүй	Үгүй
2	Тийм	Тийм	Тийм
3	Үгүй	Тийм	Тийм
4	Тийм	Тийм	Үгүй

Ангилал	Байес оноо (unnormalized)	
Тийм	0.25	Posterior магадлал тэнцүү тул хариу "тодорхойгүй".
Үгүй	0.25	

Prior probability

$$P(\text{Ханиад}=\text{Тийм}) = 2/4 = 0.5$$

$$P(\text{Ханиад}=\text{Үгүй}) = 2/4 = 0.5$$

Likelihood тооцох

$$P(\text{Толгой}=\text{Тийм} \mid \text{Ханиад}=\text{Тийм}) = 1/2 = 0.5$$

Ханиадтай байх магадлал

$$P(\text{Тийм} \mid X) \propto P(X \mid \text{Тийм}) \cdot P(\text{Тийм}) = 0.5 \cdot 1.0 \cdot 0.5 = 0.25$$

Үгүй тохиолдлыг мөн тооцно

$$P(\text{Үгүй} \mid X) \propto 1.0 \cdot 0.5 \cdot 0.5 = 0.25$$






Тулгуур векторын машин (SVM)

SVM бол ангилал (classification) болон регресс (regression) хийхэд хэрэглэгддэг хүчирхэг удирдлагатай машин сургалтын алгоритм юм.

- Өгөгдлийг ангиллын дагуу ялгах
- Ялгах шийдвэрийн шугам (decision boundary) буюу гипер хавтгай (hyperplane) олох
- Хоёр ангиллын хооронд хамгийн их зайнд байрлах шугамыг сонгох






Тулгуур векторын машин (SVM)



Жин (г)	Үнэ (₮)
100	800
120	850
140	900
160	950
180	1000
200	1050



$$x_{\text{scaled}} = \frac{x - \mu}{\sigma}$$

Жишээлбэл:

- Жингийн дундаж (mean): 150
- Жингийн стандарт хазайлт (std): 34.64 (тооцоологдсон)

$$\text{Жин}_{\text{scaled}} = \frac{170 - 150}{34.64} \approx 0.577$$

$$y = w \cdot x + b$$

$$\hat{y}_{\text{scaled}} = w \cdot 0.577 + b$$

$$\text{Үнэ}_{\text{original}} = \hat{y}_{\text{scaled}} \cdot \sigma + \mu$$

$$\text{Үнэ} = 0.536 \cdot 87 + 925 \approx 971.6$$

SVM ба SVR нь feature-үүдийг нэг ижил хэмжээст орон зайд оруулахыг шаарддаг тул StandardScaler ашиглан жинг болон үнийг стандартаар хувиргасан.


170 гр жимсний таамагласан үнэ: 971.6₮



k-Nearest Neighbors буюу ойролцоох k хөршийн арга нь маш энгийн, гэхдээ хүчтэй ангиллын болон регрессийн машин сургалтын алгоритм юм.

Шинэ өгөгдлийг ангилахдаа:

- Өгөгдлийн сан дахь хамгийн ойр k хөрш өгөгдлийг олж,
- Тэдгээрийн ангиллыг олонхийн саналаар (classification), дундаж утгаар (regression) тооцож шинэ өгөгдлийг ангилна.



Давуу тал	Сул тал
Энгийн ойлгомжтой	Том дата дээр удаан
Параметрийн шаардлагагүй	Шинжийн хэмжээ их байвал сайн ажиллахгүй
Олон төрлийн өгөгдөл дээр ажилладаг	Хэмжээст багасгалт шаарддаг





k-Nearest Neighbors

Цэг	x	y	Ангилал
A	1	1	Улаан
B	2	1	Улаан
C	4	3	Ногоон
D	5	4	Ногоон

Цэг X = (x=3, y=2) нь ямар ангилалд хамаарах вэ?

Бид k = 3 гэж авъя.

Цэг X = (x=3, y=2) → Улаан

Euclidean Distance: $\text{dist}(x_1, x_2) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$

Цэг	x	y	Зай (X=(3,2) ↔ Цэг)	Ангилал
A	1	1	$\sqrt{((3-1)^2 + (2-1)^2)} = \sqrt{5} \approx 2.24$	Улаан
B	2	1	$\sqrt{((3-2)^2 + (2-1)^2)} = \sqrt{2} \approx 1.41$	Улаан
C	4	3	$\sqrt{((3-4)^2 + (2-3)^2)} = \sqrt{2} \approx 1.41$	Ногоон
D	5	4	$\sqrt{((3-5)^2 + (2-4)^2)} = \sqrt{8} \approx 2.83$	Ногоон

Зайгаар эрэмбэлэх:

1. B (1.41, Улаан)
2. C (1.41, Ногоон)
3. A (2.24, Улаан)

→ k = 3 хөрш: **B, C, A**

	Ангилал	Хөршүүдийн тоо
→	Улаан	2
	Ногоон	1






Санамсаргүй ой

Random Forest нь олон Decision Tree (шийдвэрийн мод)-ийн нийлбэрээс бүрдсэн ансамбль арга юм. Шинэ өгөгдөл дээр мод бүр ангилал хийж, олонхийн саналаар (classification) эсвэл дундажаар (regression) хариуг гаргадаг.

Санамсаргүй модыг үүсгэх:

- Bagging (Bootstrap Aggregation) —
Өгөгдлийн санамсаргүй сонголт
 - Мод бүр сургалтад оролцох өгөгдлөө random байдлаар сонгодог.
- Random Subset of Features —
Шинжүүдийн санамсаргүй сонголт
 - Модны зангилаа (node) бүр дээр, бүх feature-ийг бус, зөвхөн subset-ийг л ашиглаж хуваагдлыг шийддэг.



Давуу тал	Сул тал
Overfitting бууруулна	Хүнд (олон мод боловсруулна)
Feature importance гаргаж чадна	Тайлбарлахад Decision Tree-ээс төвөгтэй
Classification & Regression аль алинд	
Noise-д мэдрэмж багатай	





Санамсаргүй ой



ID	Нас	Орлого	Худалдан авах уу?
1	25	50k	Үгүй
2	30	60k	Үгүй
3	45	80k	Тийм
4	35	120k	Тийм
5	22	30k	Үгүй
6	50	90k	Тийм

Шинэ хүн: **Нас = 40, Орлого = 70k** → Худалдан авалт хийх үү?

Эцсийн шийд: Үгүй

3 мод үүсгэнэ ($n_estimators = 3$)
Dataset бүр модонд random subset (жишээ: bagging) болон шинжүүдийн subset-ийг сонгоно.

Мод 1

Нас	Худалдан авах уу?
25	Үгүй
45	Тийм
22	Үгүй

Модны шийдвэр:
 $Нас \geq 35 \rightarrow$ Тийм,
эсвэл Үгүй

40 нас → Тийм

Мод 2

Орлого	Худалдан авах уу?
30k	Үгүй
60k	Үгүй
120k	Тийм

→ Орлого $\geq 100k \rightarrow$
Тийм, бусад → Үгүй
70k → **Үгүй**

Мод 3

Нас	Орлого	Худалдан авах уу?
50	90k	Тийм
30	60k	Үгүй
35	120k	Тийм

→ Орлого $\geq 80k \rightarrow$
Тийм, бусад → Үгүй
70k → **Үгүй**





Удирдлагатай сургалтын үнэлгээ



Classification

Метрик	Тайлбар
Accuracy	Зөв таамаглалын хувь (correct / total)
Precision	Зөв таамагласан Positive-уудын хувь ($TP / (TP + FP)$)
Recall (Sensitivity)	Бодит Positive-уудыг зөв олсон хувь ($TP / (TP + FN)$)
F1-Score	Precision ба Recall-ийн дунджаар (harmonic mean)
ROC-AUC	Төрөл хооронд ялгах чадвар ($AUC > 0.5$ сайн загвар)
Log Loss	Бодит ангилалд хэр итгэлтэй байсанг хэмждэг (probabilistic metric)
Confusion Matrix	TP, TN, FP, FN 4 хэмжээст үнэлгээ

Regression

Метрик	Тайлбар
MAE (Mean Absolute Error)	Дундаж абсолют алдаа: $ y - \hat{y} $
MSE (Mean Squared Error)	Дундаж квадрат алдаа: $(y - \hat{y})^2$
RMSE (Root Mean Squared Error)	MSE-ийн язгуур: том алдаанд илүү мэдрэмтгий
R^2 Score (R-squared)	Тайлбарласан хэлбэлзлийн хувь (0–1 хооронд, их бол сайн)
MAPE (Mean Absolute Percentage Error)	Дундаж хувь алдаа: $MAE / \text{бодит утга} \times 100\%$





Hyperparameter tuning

Hyperparameter tuning гэдэг нь загварын тохируулгад нөлөөлөх гаднах параметруудийг оновчлох үйл явц юм.

Model доторх гараар тохируулдаг утгууд бөгөөд суралцах явцад автоматаар өөрчлөгддөггүй.

Жишээ:

- Decision Tree: max_depth, min_samples_split
- SVM: kernel, C, gamma
- KNN: k

- Grid Search: Нэг бүрчлэн шалгах (combinatorial)
- Random Search: Санамсаргүй параметруудийн хослолыг турших
- Bayesian Optimization: Интеллект алгоритм ашиглан оновчлох
- Automated tools: Optuna, Ray Tune, Scikit-learn's GridSearchCV



Hyperparameter tuning



Parameter	Possible Values
n_estimators	[100, 200, 300]
max_depth	[5, 10, 15, None]
min_samples_split	[2, 5, 10]

```
from sklearn.model_selection import  
GridSearchCV  
from sklearn.ensemble import  
RandomForestClassifier
```

```
param_grid = {  
    'n_estimators': [100, 200],  
    'max_depth': [10, 20],  
    'min_samples_split': [2, 5]  
}
```

```
grid = GridSearchCV(RandomForestClassifier(),  
param_grid, cv=5)  
grid.fit(X_train, y_train)
```

```
print("Best Parameters:", grid.best_params_)  
print("Best Score:", grid.best_score_)
```

Тодорхойлолт	Model Selection	Hyperparameter Tuning
Юу сонгох вэ?	Аль загвар хамгийн сайн ажиллах вэ?	Сонгосон загварын аль тохиргоо дээр сайн вэ?
Үндсэн хэрэгсэл	Cross-validation, Bias-Variance	Grid Search, Random Search, Optuna
Үр дүн нь	Загварын төрөл (SVM, Tree, NN гэх мэт)	Загварын нарийвчлал сайжирна



Удирдлагатай сургалтын хэрэглээ



Салбар	Жишээ хэрэглээ
Эрүүл мэнд	Зурган дээр хавдар байна уу/байхгүй юу?
Спам илрүүлэлт	Имэйл спам уу, жирийн үү?
Аюулгүй байдал	Камерийн дүрс дээр зөвшөөрөгдсөн хүн үү?
NLP	Сэтгэгдэл эерэг/сөрөг эсэх
Санхүү	Картын гүйлгээ луу / луйвар уу?
Автомашин	Сенсороос орж ирсэн өгөгдлөөр аюултай нөхцөл эсэх

Салбар	Жишээ хэрэглээ
Үл хөдлөх хөрөнгө	Байрны үнийн таамаг (орон сууцны үнэ)
Санхүү	Хувьцааны үнэ ирээдүйд хэд болохыг таамаглах
 Үйлдвэрлэл	Машины эвдрэх цаг/магадлал таамаглах
Цаг уур	Температур, хур тунадас хэр байхыг таамаглах
Худалдаа	Ирэх 7 хоногт борлуулалтын тоо хэмжээ
Зам тээвэр	Автобусны ирэх хугацаа (ETA), зорчигчдын тоо





Удирдлагатай сургалтын асуудал



1. Шошготой өгөгдлийн хомсдол

- Олон салбарт (эмнэлэг, хуулийн баримт, Монгол хэл гэх мэт) гаралтын шошгыг гар аргаар тэмдэглэх шаардлагатай.
- Шошго үүсгэх нь цаг их зарцуулдаг, өртөг өндөртэй.

2. Ангиллын тэнцвэргүй байдал (Imbalanced classes)

- Зарим ангилал (e.g. өвчтэй / луйварчид) маш цөөн байдаг.
- Энэ нь загвар олонхын ангилал руу хазайх аюултай → Precision, Recall муудна.

3. Overfitting (Хэт сургалт)

- Загвар сургалтын өгөгдөл дээр хэт тохирсон байвал шинэ өгөгдөлд муу ажиллана.
- Гүн мод, нейрон сүлжээнд нийтлэг тохиолддог.

4. Underfitting (Дутуу сургалт)

- Загвар хэт энгийн байснаас болж өгөгдлийн хандлагыг олж чадахгүй.
- Жишээ: Linear model нь муруй харилцан хамаарлыг илрүүлж чадахгүй.





Удирдлагатай сургалтын асуудал



5. Өгөгдлийн чанар, шум (noise)

- Хэт их алдаатай, зөрчилтэй өгөгдөл → Загвар буруу хамаарлыг сурна.
- Outlier буюу онцгой утга таамаглалд сэргөөр нөлөөлнө.

6. Шинж чанарын боловсруулалт (Feature engineering)

- Хэрэгтэй шинжүүдийг гаргаж ирэх нь амаргүй.
- Хэт их шинж (high-dimensional data) → “Curse of Dimensionality”.

7. Дамжуулалт муутай загвар (Poor generalization)

- Зарим загвар зөвхөн нэг өгөгдлийн орчинд сайн ажиллаж, шинэ орчинд муу таамаглана.
- e.g., Нэг улсын хэрэглэгчдээр сурсан model → нөгөө улсад таарахгүй

8. Сургалт, шалгалтын дата хольсон (Data leakage)

- Шалгалтын өгөгдлийн мэдээлэл сургалтад алдаатайгаар орсон бол бодит гүйцэтгэлийг буруу хэмжинэ.





Дүгнэлт



- Удирдлагатай сургалт бол шошготой өгөгдөлд үндэслэн оролт ба гаралтын хоорондын хамаарлыг суралцдаг машин сургалтын үндсэн арга юм.
- Удирдлагатай сургалтын загварын үнэлгээг үр дүнтэй хийх нь зөв алгоритм сонгох, илүү оновчтой таамаглал хийхэд тусалдаг.
- Энэ аргаар шинэ өгөгдөлд хариуг таамаглах боломжтой бөгөөд хоёр үндсэн төрөлтэй: ангилал (classification) ба тоон утга таамаглалт (regression) юм.
- Ангиллын хувьд өгөгдлийг тодорхой ангилалд хуваарилах бол, регрессийн хувьд тасралтгүй тоон утгыг таамаглана.
- Энэ арга нь ихэнх салбарт (жишээлбэл, эрүүл мэнд, санхүү, маркетинг, байгаль орчин) өргөн хэрэглэгддэг бөгөөд таамаглал, автомат шийдвэр гаргалт хийхэд гол үүрэг гүйцэтгэдэг.

